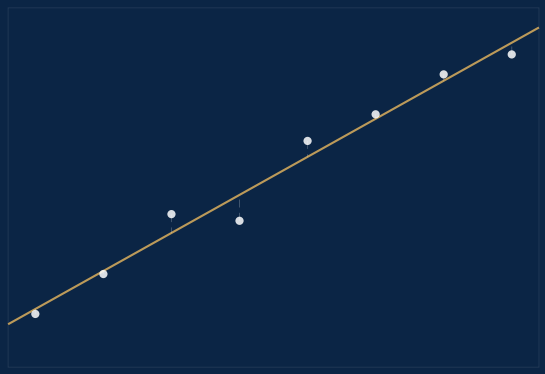
机器学习 · 讲义系列

线性回归

从最小二乘到正则化



Linear Regression

第 一 讲

本 讲 涵 盖

最小二乘与正规方程 · 正交投影 · 高斯 MLE 与先验 MAP · 岭回归与 Lasso · 模型诊断

https://github.com/CyArk-fs/MLnote

目　录

导读 **1**

1　从数据到模型 **2**

1.1　一个具体的问题 2

1.2　「线性」究竟指什么 3

1.3　写成矩阵 3

1.4　截距该怎么处理 4

1.5　本讲路线 4

2　最小二乘 **4**

2.1　为什么是残差平方和 4

2.2　推导：三步得到正规方程 5

2.2.1　第一步：展开成二次型 5

2.2.2　第二步：求梯度 5

2.2.3　第三步：令梯度为零 6

2.2.4　别忘了二阶条件 6

2.3　例：把数代进去 6

2.4　几何：解是一次正交投影 7

2.5　秩、伪逆与最小范数解 8

2.6　数值实现：公式不等于算法 9

2.6.1　复杂度 9

2.6.2　条件数被平方 10

3　概率视角：MLE 与 MAP **10**

3.1　高斯噪声下的极大似然 10

3.2　高斯先验下的 MAP：岭回归登场 12

3.3　拉普拉斯先验下的 MAP：Lasso 13

3.4　两张对照表 13

3.5　补充：为什么拉普拉斯先验偏爱零 14

4　正则化 **14**

4.1　过拟合是怎样发生的 14

4.2　岭回归：把参数往原点拉 15

4.2.1　闭式解 15

4.2.2　SVD 视角：每个方向被收缩多少 15

4.2.3　有效自由度 16

4.2.4　几何图像 17

4.3　Lasso：把参数压到零 17

4.3.1 目标与最优性条件 . . . 17
4.3.2 正交设计下的闭式解：软阈值 . . . 17
4.3.3 为什么 L_1 能产生稀疏解 . . . 18
4.3.4 实践中的几个坑 . . . 19
4.4 Elastic Net：两者折中 . . . 19
4.5 实施清单 . . . 20
5 评估、推断与诊断 . . . 20
5.1 训练误差不是答案 . . . 20
5.2 回归的常用指标 . . . 21
5.3 系数的可信度 . . . 22
5.3.1 Gauss–Markov 定理 . . . 22
5.3.2 标准误与 t 检验 . . . 22
5.3.3 整体 F 检验 . . . 22
5.4 残差诊断 . . . 23
5.5 交叉验证 . . . 23
6 线性回归之后 . . . 24
6.1 换特征：基函数展开 . . . 24
6.2 加一层非线性：从回归到分类 . . . 25
6.3 多叠几层：神经网络 . . . 25
7 小结 . . . 25
7.1 五句话 . . . 26
7.2 一张图 . . . 26
7.3 接下来 . . . 26
习题 . . . 26
A 矩阵求导速查 . . . 28
B 延伸阅读 . . . 29

导　读

为什么值得在这样一个「简单」的模型上花掉一整讲？

因为线性回归是机器学习里的果蝇：结构足够简单，几页纸就能走完全部环节；但它身上出现的每一个概念，都会在后面的模型里以更复杂的形式重演——损失函数、闭式解、几何投影、极大似然、贝叶斯先验、正则化、偏差与方差、条件数。把这一讲的每一处「为什么」都问清楚，后面读到岭回归、逻辑回归乃至神经网络时，很多结论可以直接迁移。

读完这一讲，你应当能够

1. 写出线性回归的矩阵形式，并从零推导出正规方程；
2. 说清最小二乘的三种身份：代数上的驻点、几何上的正交投影、统计上的极大似然；
3. 解释 Ridge 与 Lasso 的差别，并给出「L1 为何产生稀疏解」的两种论证；
4. 判断什么时候可以直接用闭式解、什么时候必须改用 QR 或 SVD；
5. 知道如何评估一个线性模型，以及初学者最常踩的五个坑。

预备知识

- **线性代数**：矩阵乘法与转置、秩、可逆、二次型；了解「向量空间与子空间」即可，投影的概念本讲会重讲一遍。
- **微积分**：多元函数的驻点与二阶条件。矩阵求导不要求熟练，附录 A 有一页速查表，正文也给了不依赖矩阵求导的替代推导。
- **概率统计**：条件分布、独立性、正态分布、极大似然估计。贝叶斯公式会用即可。

记号约定

本讲严格区分向量与标量：**粗体**表示向量或矩阵，斜体表示标量；上标 (j) 表示「第 j 维特征」，**不是**幂次。

记号	含义	记号	含义
N	样本数	$\mathbf{X} \in \mathbb{R}^{N\times D}$	设计矩阵（默认已增广）
D	参数个数（含截距）	$\mathbf{y} \in \mathbb{R}^{N}$	标签向量
$\mathbf{x}_i \in \mathbb{R}^{D}$	第 i 个样本（$\mathbf{X}$ 的第 i 行）	$\mathbf{w} \in \mathbb{R}^{D}$	参数向量
$x_i^{(j)}$	第 i 个样本的第 j 维取值	λ	正则化强度
ϵ_i	第 i 个观测的噪声	σ^2	噪声方差
$\hat{\mathbf{w}}$	估计值	σ_0^2	参数的先验方差

三种读法

- **只想知道公式怎么来**：读 §2.2 与 §2.3，其余略过。
- **想弄懂正则化**：先看 §3.4 的对照表，再从头读第 4 节。
- **想动手**：读 §2.6 与 §5.5，然后完成习题 C 组。

1　从数据到模型

1.1　一个具体的问题

我们从一个真实到有点无聊的场景开始。八位同学记录了期末复习的时长与考试成绩：

表 1　复习时长与期末成绩

编号	1	2	3	4	5	6	7	8
学习时长 x / 小时	1	2	3	4	5	6	7	8
考试成绩 y / 分	52	58	67	66	78	82	88	91

把八个数对画在平面上，点大致沿着一条向右上方的直线分布。于是自然产生两个问题：

(A) 某位同学复习了 4.5 小时，他大概能考多少分？

(B) 平均而言，每多复习一小时，成绩会提高几分？

这两个问题看起来是一回事，其实对模型的要求并不相同。问题 (A) 只需要一个能输出的函数：预测得准就行，系数具体是多少无所谓。问题 (B) 要的恰恰是那个系数本身：它必须能被解释、被赋予量纲、甚至被赋予因果含义。

前者关心**预测精度**，后者关心**参数解释**。同一个模型可以同时服务两种目的，但评估手段完全不同：前者用均方误差与交叉验证（§5.2、§5.5），后者用标准误与置信区间（§5.3）。初学者最常见的错误，是用预测的指标去支持解释的结论。

> **注意　|　系数不是因果**
>
> 「每多学一小时，成绩提高 5.7 分」是一个相关性陈述。只有当学习时长与所有未被观测的因素（基础、专注度、题目难度）都不相关时，它才可以被读成因果关系。线性回归本身不会替你完成这一步论证。

1.2 「线性」究竟指什么

定义 1.1 | 线性模型

给定特征向量 $\mathbf{x} \in \mathbb{R}^D$，称

$$f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b \tag{1}$$

为线性模型，其中 $\mathbf{w} = (w_1, \dots, w_D)^\top$ 称为**权重**，b 称为**偏置**或**截距**。

定义里有一个容易被读漏的地方：这里的「线性」是对**参数** $\mathbf{w}$ 而言的，不是对输入 $\mathbf{x}$ 而言的。

这个区别不是文字游戏。它决定了模型能表达什么、以及为什么还能有闭式解。看四个例子：

模型	是线性回归吗	理由
$y = w_0 + w_1 x + w_2 x^2$	是	令 $z_1 = x$, $z_2 = x^2$，即对 (z_1, z_2) 线性
$y = w_0 + w_1 x_1 x_2$	是	令 $z = x_1 x_2$，对 (x_1, z) 线性
$y = w_0 + \sin(w_1 x)$	否	对 w_1 非线性
$y = w_0 + w_1^2 x$	否	对 w_1 非线性（尽管画出来是直线）

最后一行值得多看两眼：它的图像确实是一条直线，但它不是线性模型。反过来，第一行画出来是抛物线，却是标准的线性回归。**「线性回归」约束的是参数的进入方式，不是曲线的形状。**

补充 | 为什么非要「对参数线性」

因为只有对参数线性，平方损失才是参数的二次函数，驻点条件才是一组线性方程，才可能有闭式解 $\hat{\mathbf{w}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$。一旦参数以非线性方式进入（比如 $\sin(w_1 x)$），同一个平方损失就变成非凸或非二次的问题，只能迭代求解——这正是第 6 节要讲的故事。

1.3 写成矩阵

把 N 个样本摞起来。记

$$\mathbf{X} = \begin{pmatrix} 1 & x_1^{(1)} & \cdots & x_1^{(D-1)} \\ 1 & x_2^{(1)} & \cdots & x_2^{(D-1)} \\ \vdots & \vdots & & \vdots \\ 1 & x_N^{(1)} & \cdots & x_N^{(D-1)} \end{pmatrix} \in \mathbb{R}^{N \times D}, \qquad \mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix} \in \mathbb{R}^N, \tag{2}$$

其中第一列全是 1，是为截距预留的位置。于是 $\mathbf{X}\mathbf{w}$ 的第 i 个分量恰好是 $\mathbf{w}^\top \mathbf{x}_i$，整个数据集上的模型可以写成一行：

$$\mathbf{y} = \mathbf{X}\mathbf{w} + \boldsymbol{\epsilon}. \tag{3}$$

养成一个习惯：写完矩阵式先对一遍维度。这里 $\mathbf{X}$ 是 $N\times D$，$\mathbf{w}$ 是 $D\times 1$，乘出来是 $N\times 1$，与 $\mathbf{y}$ 同型，通过。这个检查能在考试和写代码时救回大量错误。

1.4 截距该怎么处理

式 (1) 里显式写了 b，式 (3) 里它不见了——因为被吸收进了 $\mathbf{w}$ 的第一个分量。两种写法各有用途：推导时用增广形式最省事，解释结果时要记得把第一个分量翻译回「截距」。

> **补充 | 为什么不惩罚截距**
>
> 后面讲正则化时，我们只惩罚 $w_1,\dots,w_{D-1}$，不惩罚截距。三条理由：
>
> **其一，平移不变性。**如果把所有成绩都加 10 分，最优模型应当只是截距加 10，斜率分毫不动。可一旦惩罚截距，「把截距压小」就会与「拟合数据」冲突，加常数会改变最优斜率——模型结果依赖于 y 的原点选在哪里，这显然不合理。
>
> **其二，残差零均值。**含截距的最小二乘解满足 $\sum_i \hat{e}_i = 0$（证明见习题 A2）。惩罚截距会破坏这个性质，预测就带上了系统偏差。
>
> **其三，没有先验理由。**权重的量纲由特征决定，「靠近零更好」尚可辩解；截距的量纲由标签决定，特征整体平移就会任意改变它的大小，说「截距应该小」没有意义。
>
> **做法。**要么先把 $\mathbf{X},\mathbf{y}$ 中心化再惩罚（此时截距可由 $\bar{y}-\hat{\mathbf{w}}^{\top}\bar{\mathbf{x}}$ 还原），要么把惩罚矩阵写成 $\mathbf{\Lambda}=\mathrm{diag}(0,\lambda,\dots,\lambda)$。两种做法等价。

1.5 本讲路线

接下来的四节沿着四条不同的路径走向同一个解，每条路都会照亮前面那条路的暗角：

- §2：**代数与几何**。把损失写成二次型，求驻点；再把解解释成投影。
- §3：**概率**。把平方损失读成高斯噪声下的极大似然，把正则项读成先验。
- §4：**约束**。给参数加上预算，看 L1 与 L2 两种预算如何分别带来稀疏与收缩。
- §5：**评估**。解出来只是开始，还要知道它有多可信。

2 最小二乘

2.1 为什么是残差平方和

模型定好了，接下来的问题是：怎样才算「拟合得好」？

对任意一组参数 $\mathbf{w}$，第 i 个样本的偏差是残差

$$e_i(\mathbf{w}) \;=\; y_i - \mathbf{w}^{\top}\mathbf{x}_i, \tag{4}$$

它可正可负。我们希望所有残差都尽量小，但「小」需要先定义。三种常见的度量：

- **残差和** $\sum_i e_i$：正负抵消。更糟的是，只要模型含截距，$\sum_i e_i = 0$ 就自动成立，这个目标函数恒等于零，毫无用处。
- **残差绝对值和** $\sum_i |e_i|$：合理且稳健，但在 $e_i = 0$ 处不可微，没有闭式解。
- **残差平方和** $\sum_i e_i^2$：可微、凸、有闭式解；代价是对大残差惩罚过重。

我们选第三种，理由有三层，后面每一节会各展开一层：

(1) **几何**：它是欧氏距离的平方，于是「最小化距离」可以用投影的语言说清楚（§2.4）；

(2) **概率**：它恰好是噪声服从高斯分布时的极大似然估计（§3.1）；

(3) **计算**：它是参数的二次型，驻点条件是一组线性方程，可以直接解出来。

> **注意 | 平方的代价**
>
> 平方会放大离群点的影响：一个残差为 10 的点贡献 100，而两个残差为 1 的点加起来只贡献 2。所以最小二乘的解可能被单个异常观测整个拉走。如果你的数据里混着录入错误，先清洗，或者改用 L_1 损失（§3.1 的补充）。

于是目标函数取

$$L(\mathbf{w}) \;=\; \sum_{i=1}^{N} \big(\mathbf{w}^{\top}\mathbf{x}_i - y_i\big)^2 \;=\; \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2. \tag{5}$$

2.2 推导：三步得到正规方程

第一步：展开成二次型 把范数写成内积：

$$\begin{aligned} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2 &= (\mathbf{X}\mathbf{w} - \mathbf{y})^{\top}(\mathbf{X}\mathbf{w} - \mathbf{y}) \\ &= \mathbf{w}^{\top}\mathbf{X}^{\top}\mathbf{X}\mathbf{w} - \mathbf{w}^{\top}\mathbf{X}^{\top}\mathbf{y} - \mathbf{y}^{\top}\mathbf{X}\mathbf{w} + \mathbf{y}^{\top}\mathbf{y}. \end{aligned} \tag{6}$$

中间两项看起来不一样，其实相等：$\mathbf{w}^{\top}\mathbf{X}^{\top}\mathbf{y}$ 是一个**标量**，标量的转置等于自身，即

$$\mathbf{w}^{\top}\mathbf{X}^{\top}\mathbf{y} = \big(\mathbf{w}^{\top}\mathbf{X}^{\top}\mathbf{y}\big)^{\top} = \mathbf{y}^{\top}\mathbf{X}\mathbf{w}. \tag{7}$$

这是初学者在这一步最常出错的地方——忘记标量可以自由转置，于是把两项留到最后，得不到干净的二次型。合并后：

$$L(\mathbf{w}) = \mathbf{w}^{\top}\mathbf{X}^{\top}\mathbf{X}\mathbf{w} - 2\,\mathbf{w}^{\top}\mathbf{X}^{\top}\mathbf{y} + \mathbf{y}^{\top}\mathbf{y}. \tag{8}$$

第二步：求梯度 对 (8) 关于 $\mathbf{w}$ 求梯度。第一项是二次型 $\mathbf{w}^{\top}\mathbf{A}\mathbf{w}$（其中 $\mathbf{A} = \mathbf{X}^{\top}\mathbf{X}$ 对称），梯度为 $2\mathbf{A}\mathbf{w}$；第二项是线性项，梯度为 $-2\mathbf{X}^{\top}\mathbf{y}$；第三项与 $\mathbf{w}$ 无关。因此

$$\nabla_{\mathbf{w}} L(\mathbf{w}) = 2\mathbf{X}^{\top}\mathbf{X}\mathbf{w} - 2\mathbf{X}^{\top}\mathbf{y}. \tag{9}$$

第三步：令梯度为零

$$2\mathbf{X}^\top\mathbf{X}\hat{\mathbf{w}} - 2\mathbf{X}^\top\mathbf{y} = \mathbf{0} \quad\Longleftrightarrow\quad \boxed{\mathbf{X}^\top\mathbf{X}\hat{\mathbf{w}} = \mathbf{X}^\top\mathbf{y}} \tag{10}$$

这组方程称为**正规方程**（normal equations）。若 $\mathbf{X}^\top\mathbf{X}$ 可逆，立刻得到

$$\hat{\mathbf{w}} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}. \tag{11}$$

别忘了二阶条件 「令导数为零」只给出驻点，并不自动是极小点。补上这一步才算证明完整：L 的 Hessian 是

$$\nabla_{\mathbf{w}}^2 L(\mathbf{w}) = 2\mathbf{X}^\top\mathbf{X} \succeq 0, \tag{12}$$

半正定，故 L 是凸函数，**任何驻点都是全局最小点**。进一步，若 $\mathbf{X}$ 列满秩，则 $\mathbf{X}^\top\mathbf{X}$ 正定，L 严格凸，最小点唯一。

> **补充 | 不会矩阵求导怎么办**
>
> 完全可以绕开。直接对第 k 个分量求偏导：
>
> $$\frac{\partial L}{\partial w_k} = \sum_{i=1}^{N} 2\big(\mathbf{w}^\top\mathbf{x}_i - y_i\big)\cdot\frac{\partial(\mathbf{w}^\top\mathbf{x}_i)}{\partial w_k} = 2\sum_{i=1}^{N}\big(\mathbf{w}^\top\mathbf{x}_i - y_i\big)\,x_i^{(k)}. \tag{13}$$
>
> 把它按 $k = 1,\dots,D$ 摞成向量。注意到 $\sum_i(\mathbf{w}^\top\mathbf{x}_i - y_i)\mathbf{x}_i$ 正是「以残差为权重、对样本向量加权求和」，而 $\mathbf{X}^\top\mathbf{r}$ 的第 k 个分量恰好是 $\sum_i r_i x_i^{(k)}$，于是
>
> $$\nabla_{\mathbf{w}} L = 2\mathbf{X}^\top(\mathbf{X}\mathbf{w} - \mathbf{y}), \tag{14}$$
>
> 与 (9) 一致。整段推导只用到链式法则和「求和可以写成矩阵乘法」。

2.3 例：把数代进去

用表 1 的数据走一遍。此时 $N = 8$，$D = 2$，且

$$\mathbf{X}^\top\mathbf{X} = \begin{pmatrix} N & \sum_i x_i \\ \sum_i x_i & \sum_i x_i^2 \end{pmatrix} = \begin{pmatrix} 8 & 36 \\ 36 & 204 \end{pmatrix}, \qquad \mathbf{X}^\top\mathbf{y} = \begin{pmatrix} \sum_i y_i \\ \sum_i x_i y_i \end{pmatrix} = \begin{pmatrix} 582 \\ 2859 \end{pmatrix}. \tag{15}$$

二阶行列式 $\det = 8\times 204 - 36^2 = 336$，故

$$(\mathbf{X}^\top\mathbf{X})^{-1} = \frac{1}{336}\begin{pmatrix} 204 & -36 \\ -36 & 8 \end{pmatrix}, \tag{16}$$

$$\hat{\mathbf{w}} = \frac{1}{336}\begin{pmatrix} 204\times 582 - 36\times 2859 \\ -36\times 582 + 8\times 2859 \end{pmatrix} = \frac{1}{336}\begin{pmatrix} 15804 \\ 1920 \end{pmatrix} = \begin{pmatrix} 47.04 \\ 5.71 \end{pmatrix}. \tag{17}$$

于是 $\hat{y} = 47.04 + 5.71x$。对 §1.1 的两个问题：复习 4.5 小时，预测成绩约 72.8 分；平均每多复习一小时，成绩提高约 5.7 分。

补充 | 与统计学课本里的公式对得上

一元情形常写成 $\hat{w}_1 = S_{xy}/S_{xx}$，$\hat{w}_0 = \bar{y} - \hat{w}_1\bar{x}$，其中

$$S_{xy} = \sum_i (x_i - \bar{x})(y_i - \bar{y}), \qquad S_{xx} = \sum_i (x_i - \bar{x})^2. \tag{18}$$

代入数据：$S_{xy} = 2859 - 8 \times 4.5 \times 72.75 = 240$，$S_{xx} = 204 - 8 \times 4.5^2 = 42$，故 $\hat{w}_1 = 240/42 = 5.71$，$\hat{w}_0 = 72.75 - 5.71 \times 4.5 = 47.04$。两条路给出同一个数——矩阵形式只是把「中心化后的协方差除以方差」写得更紧凑。

2.4 几何：解是一次正交投影

现在换一副眼镜看同一个解。

关键观察是：$\mathbf{Xw}$ 落在 $\mathbf{X}$ 各列的线性组合里。也就是说，不论 $\mathbf{w}$ 取什么值，模型能给出的所有预测都铺成 $\mathbb{R}^N$ 中的一个子空间：

$$\mathrm{Col}(\mathbf{X}) = \mathrm{Span}\{\mathbf{x}^{(1)}, \ldots, \mathbf{x}^{(D)}\} \subseteq \mathbb{R}^N, \tag{19}$$

称为 $\mathbf{X}$ 的**列空间**。最小化 $\|\mathbf{y} - \mathbf{Xw}\|$ 就是在这张「平面」上找一个离 $\mathbf{y}$ 最近的点。

最近点的刻画很朴素：如果 $\hat{\mathbf{y}} = \mathbf{X}\hat{\mathbf{w}}$ 已经最近，那么沿着平面内任何方向挪动一点都不会更近。也就是说，残差 $\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}$ 与平面内每个方向都垂直：

$$\mathbf{X}^\top \mathbf{e} = \mathbf{X}^\top(\mathbf{y} - \mathbf{X}\hat{\mathbf{w}}) = \mathbf{0} \quad \Longleftrightarrow \quad \mathbf{X}^\top\mathbf{X}\hat{\mathbf{w}} = \mathbf{X}^\top\mathbf{y}. \tag{20}$$

一句话记住三种说法

「残差与列空间正交」$\Longleftrightarrow$「正规方程成立」$\Longleftrightarrow$「梯度为零」——它们是同一件事的几何、代数与微积分表述。

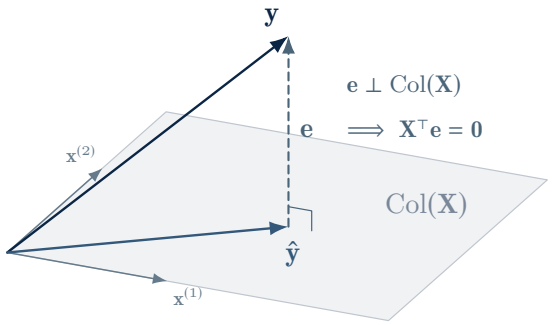


图 1 最小二乘的几何图像。所有可能的预测 $\mathbf{Xw}$ 铺成 $\mathbb{R}^N$ 中的一个平面 $\mathrm{Col}(\mathbf{X})$；$\hat{\mathbf{y}}$ 是 $\mathbf{y}$ 在该平面上的正交投影，残差 $\mathbf{e}$ 垂直于平面。

图 1 把这个关系画了出来。由于投影由 $\mathbf{y}$ 唯一确定，可以把它写成一个线性算子：

$$\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}, \qquad \mathbf{H} = \mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top. \tag{21}$$

$\mathbf{H}$ 把观测 $\mathbf{y}$ 变成拟合值 $\hat{\mathbf{y}}$，像给 $\mathbf{y}$ 戴了顶帽子，故称**帽子矩阵**。它的性质几乎都可以从「投影」二字读出来：

性质	式子	解释
对称	$\mathbf{H}^\top = \mathbf{H}$	正交投影是自伴的
幂等	$\mathbf{H}^2 = \mathbf{H}$	投影两次等于投影一次
秩	$\operatorname{rank}(\mathbf{H}) = D$	投影的像就是 $\operatorname{Col}(\mathbf{X})$
迹	$\operatorname{tr}(\mathbf{H}) = D$	见下
残差算子	$(\mathbf{I}-\mathbf{H})^2 = \mathbf{I}-\mathbf{H}$	$\mathbf{I}-\mathbf{H}$ 也是投影，投向正交补

其中 $\operatorname{tr}(\mathbf{H}) = D$ 值得单独算一遍，因为它后面会变成「有效自由度」。利用迹的轮换性 $\operatorname{tr}(\mathbf{AB}) = \operatorname{tr}(\mathbf{BA})$：

$$\operatorname{tr}(\mathbf{H}) = \operatorname{tr}\big(\mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\big) = \operatorname{tr}\big((\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{X}\big) = \operatorname{tr}(\mathbf{I}_D) = D. \tag{22}$$

这句结论可以这样读：帽子矩阵的迹等于「模型实际用掉的参数个数」。第 4 节会看到，岭回归把 $\mathbf{H}$ 换成 $\mathbf{H}_\lambda$，迹就从 D 连续地缩到 0——那正是「模型复杂度」的一个可计算的度量。

含截距且 $\mathbf{y}$ 中心化时 $R^2 = \cos^2\theta$。

还有一个小推论。若 $\mathbf{y}$ 已中心化、模型含截距，则 $\mathbf{y}$ 与残差正交，勾股定理给出

$$\|\mathbf{y}\|^2 = \|\hat{\mathbf{y}}\|^2 + \|\mathbf{e}\|^2, \tag{23}$$

两边同除 $\|\mathbf{y}\|^2$，得 $R^2 = \|\hat{\mathbf{y}}\|^2/\|\mathbf{y}\|^2 = \cos^2\theta$。所以 R^2 的几何意义是「$\mathbf{y}$ 与它的投影之间夹角的余弦平方」——这也解释了为什么 R^2 永远在 $[0,1]$ 内（含截距时）。

2.5 秩、伪逆与最小范数解

公式 (11) 里有个逆，而逆不一定存在。把情形分清楚：

情形	条件	$\mathbf{X}^\top\mathbf{X}$	解
列满秩	$\operatorname{rank}(\mathbf{X}) = D \le N$	可逆	唯一，$\hat{\mathbf{w}} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}$
行满秩	$\operatorname{rank}(\mathbf{X}) = N < D$	奇异	无穷多；最小范数解 $\mathbf{X}^\top(\mathbf{X}\mathbf{X}^\top)^{-1}\mathbf{y}$
降秩	$\operatorname{rank}(\mathbf{X}) < \min(N, D)$	奇异	无穷多；用伪逆 $\mathbf{X}^+\mathbf{y}$

> **注意 | 「无解」是个误称**
>
> 很多教材写「$\mathbf{X}^\top\mathbf{X}$ 不可逆，正规方程无法求解」，容易被读成「最小二乘问题无解」。这是不对的：正规方程**永远有解**。理由一行就够——$\mathbf{X}^\top\mathbf{y}$ 属于 $\mathbf{X}^\top$ 的列空间，而 $\operatorname{range}(\mathbf{X}^\top) = \operatorname{range}(\mathbf{X}^\top\mathbf{X})$，所以右端向量必定落在左端矩阵的值域里。
>
> 真正出问题的是**唯一性**：解有无穷多个，公式里的逆不存在只是这个事实的代数

表现。

多解时该选哪一个？注意所有最小二乘解给出**同一个**拟合值 $\hat{\mathbf{y}}$（它们投影到同一个点），训练误差完全一样——数据无法区分它们。既然无法区分，就选「最简单」的那个，即欧氏范数最小的：

$$\hat{\mathbf{w}} = \arg\min_{\mathbf{w}} \|\mathbf{w}\|_2 \quad \text{s.t.} \quad \mathbf{w} \in \arg\min_{\mathbf{u}} \|\mathbf{X}\mathbf{u} - \mathbf{y}\|_2. \tag{24}$$

这个选择不是随意的：第 4 节会看到，岭回归的解在 $\lambda \to 0^+$ 时恰好收敛到 (24)。换句话说，最小范数解是「正则化强度趋于零」时的极限，而不是另一种人为约定。

一般情形用奇异值分解（SVD）最干净。设

$$\mathbf{X} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top, \tag{25}$$

其中 $\mathbf{U} \in \mathbb{R}^{N\times N}$、$\mathbf{V} \in \mathbb{R}^{D\times D}$ 为正交阵，$\mathbf{\Sigma}$ 为对角（含若干零）。把非零奇异值取倒数、零保持为零，得 $\mathbf{\Sigma}^+$，则

$$\mathbf{X}^+ = \mathbf{V}\mathbf{\Sigma}^+\mathbf{U}^\top, \qquad \hat{\mathbf{w}} = \mathbf{X}^+\mathbf{y} \tag{26}$$

对任意 $\mathbf{X}$（无论秩亏与否）都给出最小范数最小二乘解。这就是伪逆（Moore–Penrose 广义逆）的全部内容。

补充 | 为什么最小范数解「最合理」

把解集写出来会更清楚。若 $\mathbf{w}_0$ 是一个最小二乘解，则全部解构成仿射集 $\mathbf{w}_0 + \ker(\mathbf{X})$：加上任何落在零空间里的方向，拟合值 $\mathbf{X}\mathbf{w}$ 都不变。于是「选哪个」等价于「在解集这个仿射子空间里找离原点最近的点」，而最近点就是 $\mathbf{w}_0$ 在 $\ker(\mathbf{X})$ 的正交补上的投影——它唯一，且垂直于零空间。

这也解释了为什么列相关的特征会让系数「乱跳」：把 w_1 加大、w_2 相应减小，只要方向落在零空间里，预测就完全不变。系数不可辨识，但预测可辨识。

2.6 数值实现：公式不等于算法

教科书停在 (11)，工程上却不能照着写。原因有两个：复杂度，与数值稳定性。

复杂度

方法	主要步骤	复杂度	稳定性由什么决定
正规方程 + Cholesky	组装 $\mathbf{X}^\top\mathbf{X}$，再分解	$\sim ND^2 + D^3/3$	$\kappa(\mathbf{X})^2$
QR 分解	$\mathbf{X} = \mathbf{Q}\mathbf{R}$，解 $\mathbf{R}\mathbf{w} = \mathbf{Q}^\top\mathbf{y}$	$\sim 2ND^2$	$\kappa(\mathbf{X})$
SVD	$\mathbf{X} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top$，用伪逆	$\sim 2ND^2$（常数更大）	$\kappa(\mathbf{X})$，可处理秩亏

三者的量级都是 $O(ND^2)$，在 $N \gg D$ 时差别不大。真正拉开差距的是第二列。

条件数被平方 矩阵的条件数 $\kappa(\mathbf{X}) = \sigma_{\max}/\sigma_{\min}$ 衡量「输入的小扰动会被放大多少倍」。正规方程把这件事弄坏了，因为

$$\kappa(\mathbf{X}^\top\mathbf{X}) = \frac{\sigma_{\max}^2}{\sigma_{\min}^2} = \kappa(\mathbf{X})^2. \tag{27}$$

若 $\kappa(\mathbf{X}) = 10^3$，则 $\kappa(\mathbf{X}^\top\mathbf{X}) = 10^6$。双精度浮点约有 16 位十进制有效数字，解正规方程会白白损失 6 位。$\kappa(\mathbf{X}) = 10^8$ 时，$\mathbf{X}^\top\mathbf{X}$ 在计算机里可能已经「不可逆」了——不是因为数学上奇异，而是因为 $\sigma_{\min}^2$ 被舍入吃掉了。

实践建议

(1) **不要显式求逆。**$(\mathbf{X}^\top\mathbf{X})^{-1}$ 只应出现在公式里；代码里应当「解方程组」，而不是「先求逆再相乘」。

(2) **默认用 SVD 或 QR。**`numpy.linalg.lstsq` 默认走 SVD；`scipy.linalg.lstsq` 可选 `lapack_driver='gelsd'`（SVD）或 `'gelsy'`（QR）。

(3) **特征共线时先想办法。**标准化、删冗余列、加岭项（§4.2，λ 会把条件数压成 $(\sigma_{\max}^2+\lambda)/(\sigma_{\min}^2+\lambda)$），都比硬解正规方程稳妥。

3 概率视角：MLE 与 MAP

第 2 节把平方损失当成一个「合理的选择」。这一节要说明，它其实是一个**假设的推论**：只要假定噪声服从高斯分布，最小二乘就恰好是极大似然估计。再往前一步，给参数加一个先验，正则项就自然出现了。

3.1 高斯噪声下的极大似然

设观测由「真实函数 + 噪声」生成：

$$y_i = \mathbf{w}^\top\mathbf{x}_i + \epsilon_i, \qquad \epsilon_1,\dots,\epsilon_N \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0,\sigma^2). \tag{28}$$

「独立同分布」四个字承载了两条假设：样本之间互不影响；每个样本的噪声来自同一个分布。于是

$$y_i \mid \mathbf{x}_i \;\sim\; \mathcal{N}(\mathbf{w}^\top\mathbf{x}_i,\ \sigma^2), \tag{29}$$

且给定 $\mathbf{X}$ 后各 y_i 条件独立。

似然函数是「把观测到的 $\mathbf{y}$ 当作 $\mathbf{w}$ 的函数」：

$$p(\mathbf{y}\mid\mathbf{X},\mathbf{w}) = \prod_{i=1}^{N}\frac{1}{\sqrt{2\pi}\,\sigma}\exp\!\left(-\frac{(y_i-\mathbf{w}^\top\mathbf{x}_i)^2}{2\sigma^2}\right). \tag{30}$$

连乘不好处理，取对数把它变成求和：

$$\ell(\mathbf{w}) = \log p(\mathbf{y} \mid \mathbf{X}, \mathbf{w}) = -\frac{N}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^{N}(y_i - \mathbf{w}^\top \mathbf{x}_i)^2. \tag{31}$$

现在看 (31) 的结构：第一项与 $\mathbf{w}$ 无关，第二项是残差平方和乘上一个负常数。于是

$$\arg\max_{\mathbf{w}} \ell(\mathbf{w}) = \arg\max_{\mathbf{w}} \left[-\frac{1}{2\sigma^2}\sum_{i}(y_i - \mathbf{w}^\top \mathbf{x}_i)^2\right] = \arg\min_{\mathbf{w}} \sum_{i}(y_i - \mathbf{w}^\top \mathbf{x}_i)^2. \tag{32}$$

结论

在高斯噪声假设下，**极大似然估计与最小二乘估计是同一个估计**。σ^2 的具体取值不影响 $\hat{\mathbf{w}}$——它只是一个缩放因子，而最大化一个负的平方和不依赖于缩放多少。

顺便把 σ^2 也估出来。对 (31) 关于 σ^2 求导并令其为零，得

$$\hat{\sigma}^2_{\text{MLE}} = \frac{1}{N}\sum_{i=1}^{N}\hat{e}_i^2. \tag{33}$$

这个估计是**有偏**的：分母是 N 而不是 $N - D$。原因不神秘——残差 $\hat{e}_i$ 不是独立信息，它们被 D 个正规方程约束住了（等价地，$\hat{\mathbf{y}}$ 落在 D 维子空间里，只剩 $N - D$ 维自由度）。无偏估计是

$$\hat{\sigma}^2 = \frac{1}{N - D}\sum_{i=1}^{N}\hat{e}_i^2, \tag{34}$$

它后面会出现在系数的标准误里（§5.3）。对本讲例题，$\hat{\sigma}^2 = 34.07/(8-2) = 5.68$，$\hat{\sigma} = 2.38$ 分。

补充 | 这条等价关系的反面更有用

既然「平方损失 ⇔ 高斯噪声」，那么噪声不是高斯时，平方损失就不再是 MLE。若噪声服从拉普拉斯分布（尖峰厚尾），对应的 MLE 是最小化残差绝对值之和：

$$\hat{\mathbf{w}}_{\text{LAD}} = \arg\min_{\mathbf{w}} \sum_{i=1}^{N}|y_i - \mathbf{w}^\top \mathbf{x}_i|, \tag{35}$$

称为**最小绝对偏差**回归。它估计的是条件中位数而非条件均值，对离群点稳健得多。

所以「为什么用平方损失」这个问题的完整答案是：*因为你默认了高斯噪声*。这个默认在多数场合够用，但你应当知道它何时失效。

3.2 高斯先验下的 MAP：岭回归登场

极大似然只用了数据。若我们对 $\mathbf{w}$ 事先有看法——比如「系数大概不会太离谱」——就该把它写进先验，改用最大后验估计。由贝叶斯公式，

$$p(\mathbf{w} \mid \mathbf{y}) \;\propto\; p(\mathbf{y} \mid \mathbf{w})\, p(\mathbf{w}), \tag{36}$$

取负对数后，「最大化后验」变成「最小化负对数后验」：

$$\hat{\mathbf{w}}_{\text{MAP}} = \arg\min_{\mathbf{w}} \Big[-\log p(\mathbf{y} \mid \mathbf{w}) - \log p(\mathbf{w}) \Big]. \tag{37}$$

取零均值、各分量独立同方差的高斯先验

$$\mathbf{w} \sim \mathcal{N}(\mathbf{0}, \sigma_0^2 \mathbf{I}), \qquad -\log p(\mathbf{w}) = \frac{1}{2\sigma_0^2} \|\mathbf{w}\|_2^2 + \text{const.} \tag{38}$$

代回目标函数（常数略去）：

$$\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2 + \frac{1}{2\sigma_0^2} \|\mathbf{w}\|_2^2. \tag{39}$$

两边同乘 $2\sigma^2$（不改变最优点），得到

$$\hat{\mathbf{w}}_{\text{MAP}} = \arg\min_{\mathbf{w}} \Big[\, \|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2 + \underbrace{\frac{\sigma^2}{\sigma_0^2}}_{\lambda} \|\mathbf{w}\|_2^2 \, \Big]. \tag{40}$$

这正是岭回归的目标函数，正则化强度由噪声方差与先验方差之比决定：

$$\boxed{\lambda = \frac{\sigma^2}{\sigma_0^2}} \tag{41}$$

情形	λ	直觉
噪声很大（$\sigma^2 \uparrow$）	变大	数据不可信，多听先验的
先验很宽（$\sigma_0^2 \uparrow$）	变小	对 $\mathbf{w}$ 没什么主见，多听数据的
先验很窄（$\sigma_0^2 \to 0$）	$\to \infty$	坚信 $\mathbf{w} = \mathbf{0}$，无视数据

这张表说明了一件常被忽略的事：λ 不是「玄学超参数」，它有明确的统计含义，是「数据的不确定性」与「先验的确定性」的比值。实践中用交叉验证选 λ（§5.5），本质上是在从数据里估这个比值。

> **注意 | MAP 不是贝叶斯推断**
>
> 最大后验只取后验分布的众数，仍然是一个点估计。完整的贝叶斯做法要对后验积分（预测分布 $p(y_* \mid \mathbf{x}_*) = \int p(y_* \mid \mathbf{x}_*, \mathbf{w}) p(\mathbf{w} \mid \mathbf{y}) \mathrm{d}\mathbf{w}$），得到的不只是点，还有不

确定性。在共轭高斯设定下这个积分有闭式解，那就是**贝叶斯线性回归**——它给出的预测方差会随 $\mathbf{x}_*$ 远离训练数据而增大，这是点估计做不到的。

3.3 拉普拉斯先验下的 MAP：Lasso

把先验换成拉普拉斯分布。它的密度在零点有一个尖峰：

$$p(w_j) = \frac{1}{2b}\exp\left(-\frac{|w_j|}{b}\right), \qquad -\log p(\mathbf{w}) = \frac{1}{b}\|\mathbf{w}\|_1 + \text{const.} \tag{42}$$

同样的流程：负对数后验为 $\frac{1}{2\sigma^2}\text{RSS} + \frac{1}{b}\|\mathbf{w}\|_1$，两边乘 $2\sigma^2$：

$$\hat{\mathbf{w}}_{\text{MAP}} = \arg\min_{\mathbf{w}} \Big[\, \|\mathbf{y}-\mathbf{X}\mathbf{w}\|_2^2 + \underbrace{\frac{2\sigma^2}{b}}_{\lambda}\|\mathbf{w}\|_1 \,\Big]. \tag{43}$$

对称的美感

- 噪声分布决定**损失函数**：高斯 $\to$ 平方和；拉普拉斯 $\to$ 绝对值和。
- 参数先验决定**正则项**：高斯 $\to L_2$；拉普拉斯 $\to L_1$。

两件事各管一头，可以自由组合。这是第 4 节全部内容的骨架。

3.4 两张对照表

表 2 三种估计的假设与结果

估计	假设	目标函数	解的性质
最小二乘 / MLE	高斯噪声	$\|\mathbf{y}-\mathbf{X}\mathbf{w}\|^2$	闭式解，无偏
岭回归 / MAP	高斯噪声 + 高斯先验	$\|\mathbf{y}-\mathbf{X}\mathbf{w}\|^2 + \lambda\|\mathbf{w}\|_2^2$	闭式解，有偏收缩
Lasso / MAP	高斯噪声 + 拉普拉斯先验	$\|\mathbf{y}-\mathbf{X}\mathbf{w}\|^2 + \lambda\|\mathbf{w}\|_1$	无闭式解，稀疏

表 3 噪声模型与先验模型的组合

	无先验（MLE）	高斯先验	拉普拉斯先验
高斯噪声	最小二乘（L_2 损失）	岭回归	Lasso
拉普拉斯噪声	LAD（L_1 损失）	近似 Huber	罕用

表 3 值得多看一会儿，因为它把两个极易混淆的概念分开了：

- L_1 **损失**（左列第二行）：惩罚的是*残差*，用来对付离群点，估计条件中位数。
- L_1 **正则**（右列第一行）：惩罚的是*参数*，用来对付过拟合，产生稀疏解。

两者形式上都带绝对值，作用对象完全不同。笔记里特意提醒过这一点，此处用一个 2×2 表把它钉死：先验管参数，噪声管残差。

3.5 补充：为什么拉普拉斯先验偏爱零

高斯密度在零点光滑、导数为零，像一个圆润的小山包；拉普拉斯密度在零点有尖角，导数从 $-1/b$ 跳到 $+1/b$。这个差别在优化时会被放大：

对于高斯先验，把某个系数从 0 推到 δ，负对数先验只增加 $O(\delta^2)$——一阶几乎免费。对于拉普拉斯先验，增加的是 $O(\delta)$——有固定的「起步价」。

于是只要数据对某个系数的支持不够强（梯度推力小于这个起步价），最优选择就是让它**精确等于零**，而不是「小一点」。这就是稀疏性的来源。第 4 节会把这个直觉写成次梯度条件。

4 正则化

4.1 过拟合是怎样发生的

先把两个误差分清楚。**训练误差**是模型在已经见过的数据上的平均损失；**泛化误差**是它在同分布的新样本上的期望损失。我们真正关心的是后者，但只能观测到前者。

两者可以差得很远，而且差距随模型复杂度单调扩大。线性回归里有一个干净的例子说明这一点：

> **命题 4.1** | $N < D$ **时训练误差可以为零**
>
> 设 $\mathbf{X}\in\mathbb{R}^{N\times D}$ 行满秩且 $N<D$。则方程 $\mathbf{X}\mathbf{w}=\mathbf{y}$ 有解，即存在 $\mathbf{w}$ 使训练误差恰好为零。

证明. $\mathbf{X}$ 行满秩意味着 $\operatorname{rank}(\mathbf{X})=N$，即 $\mathbf{X}$ 的列空间是整个 $\mathbb{R}^N$。既然 $\mathbf{y}\in\mathbb{R}^N=\operatorname{Col}(\mathbf{X})$，它就一定能写成列的线性组合，即存在 $\mathbf{w}$ 使 $\mathbf{X}\mathbf{w}=\mathbf{y}$。这样的 $\mathbf{w}$ 有无穷多个（零空间维数为 $D-N>0$）。 □

这个结论很刺眼：只要特征比样本多，模型就能把训练集背下来，训练误差为零，但对新样本毫无保证。它记住的是噪声，不是规律。

> **补充** | **为什么「参数多」必然带来风险**
>
> 从自由度看最清楚。N 个观测提供了 N 条独立信息；模型有 D 个自由参数。当 D 逼近 N，模型有足够的自由度去迁就每一个观测的随机波动。第 §2.5 节已经看到，此时解甚至不唯一——数据本身无法确定参数。
>
> 反过来，若 $D\ll N$，模型只能捕捉数据中「最主流的」那个方向，随机波动被平

> 均掉，泛化反而稳。

应对过拟合有三条路：

(1) **加数据**：最根本，但往往做不到或太贵；

(2) **降维**：减特征（PCA、特征选择），直接减少 D；

(3) **正则化**：不减特征，而是限制参数的大小，等价于缩小假设空间。

本讲只讲第三条，但请记住它是三条里最「便宜」的一条，因此也是最常被滥用的。

4.2 岭回归：把参数往原点拉

闭式解 在平方损失上加一个二次惩罚：

$$L_\lambda(\mathbf{w}) = \|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2 + \lambda\|\mathbf{w}\|_2^2, \qquad \lambda > 0. \tag{44}$$

求梯度（第一项见 (9)，第二项是 $\lambda\|\mathbf{w}\|^2$，梯度 $2\lambda\mathbf{w}$）：

$$\nabla L_\lambda = 2\mathbf{X}^\top(\mathbf{X}\mathbf{w} - \mathbf{y}) + 2\lambda\mathbf{w}. \tag{45}$$

令其为零：

$$(\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I})\hat{\mathbf{w}}_\lambda = \mathbf{X}^\top\mathbf{y} \quad\Longrightarrow\quad \boxed{\hat{\mathbf{w}}_\lambda = (\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I})^{-1}\mathbf{X}^\top\mathbf{y}} \tag{46}$$

> **命题 4.2** | **岭回归总有唯一解**
>
> 若 $\lambda > 0$，则 $\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I}$ 正定，因而对任意 $\mathbf{X}$（包括秩亏的情形）都可逆。

证明. 设 $\mathbf{u} \neq \mathbf{0}$，则 $\mathbf{u}^\top(\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I})\mathbf{u} = \|\mathbf{X}\mathbf{u}\|_2^2 + \lambda\|\mathbf{u}\|_2^2 \geq \lambda\|\mathbf{u}\|^2 > 0$。正定故可逆。 □

这条副产品值得强调：**岭回归顺带解决了秩亏问题**。哪怕特征完全共线、$\mathbf{X}^\top\mathbf{X}$ 奇异，只要加一个 $\lambda > 0$，就能解出唯一的 $\hat{\mathbf{w}}_\lambda$。而且当 $\lambda \to 0^+$ 时，这个解连续地收敛到 §2.5 的最小范数解。

顺带说明：(46) 与第 3 节的 MAP 解 (40) 是同一个式子，只是走到它的路径不同——那里从「先验 + 似然」出发，这里从「损失 + 惩罚」出发。$\lambda = \sigma^2/\sigma_0^2$ 就是两条路的接头：它把「先验有多确定」翻译成「惩罚有多重」。

SVD 视角：每个方向被收缩多少 把 $\mathbf{X} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top$ 代入 (46)：

$$\begin{aligned}\hat{\mathbf{w}}_\lambda &= \left(\mathbf{V}\mathbf{\Sigma}^2\mathbf{V}^\top + \lambda\mathbf{I}\right)^{-1}\mathbf{V}\mathbf{\Sigma}\mathbf{U}^\top\mathbf{y} = \mathbf{V}(\mathbf{\Sigma}^2 + \lambda\mathbf{I})^{-1}\mathbf{\Sigma}\mathbf{U}^\top\mathbf{y} \\ &= \sum_{j=1}^{r} \frac{d_j}{d_j^2 + \lambda}\left(\mathbf{u}_j^\top\mathbf{y}\right)\mathbf{v}_j \;=\; \sum_{j=1}^{r} \underbrace{\frac{d_j^2}{d_j^2 + \lambda}}_{\text{收缩因子}} \cdot \frac{1}{d_j}\,\mathbf{u}_j^\top\mathbf{y}\;\mathbf{v}_j.\end{aligned} \tag{47}$$

对比最小二乘解 $\hat{\mathbf{w}}_{\mathrm{OLS}} = \sum_j \frac{1}{d_j}(\mathbf{u}_j^\top \mathbf{y})\mathbf{v}_j$，可以看到：**岭回归没有改变方向，只是把每个方向上的系数乘了一个小于 1 的因子。**

- d_j 很大（数据在这个方向上信息充足）：$d_j^2/(d_j^2+\lambda) \approx 1$，几乎不动；
- d_j 很小（这个方向几乎无法从数据中辨识）：因子 $\approx d_j^2/\lambda \approx 0$，被狠狠压向零。

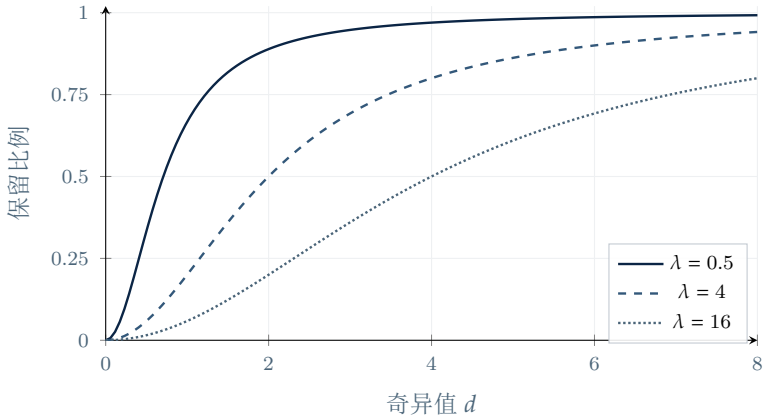


图 2 岭回归的收缩效应。横轴是某个方向上的奇异值，纵轴是该方向保留下来的系数比例。奇异值小的方向（数据几乎无法辨识的方向）被强烈压缩；奇异值大的方向几乎不受影响。λ 越大，整条曲线越靠右，收缩越强。

图 2 是理解岭回归的关键。它解释了为什么岭回归「稳」：**方差大的方向恰恰是 $\mathbf{X}^\top\mathbf{X}$ 小特征值对应的方向**，岭回归选择性地压掉了这些方向，用一点偏差换来了方差的显著下降。这正是偏差—方差权衡的一个具体实现。

有效自由度 把帽子矩阵换成岭回归的版本：

$$\mathbf{H}_\lambda = \mathbf{X}(\mathbf{X}^\top\mathbf{X}+\lambda\mathbf{I})^{-1}\mathbf{X}^\top = \mathbf{U}\,\mathrm{diag}\left(\frac{d_j^2}{d_j^2+\lambda}\right)\mathbf{U}^\top. \tag{48}$$

它的迹给出一个连续变化的「有效参数个数」：

$$\mathrm{df}(\lambda) = \mathrm{tr}(\mathbf{H}_\lambda) = \sum_{j=1}^{r}\frac{d_j^2}{d_j^2+\lambda} \;\in\; (0,\, D]. \tag{49}$$

$\lambda = 0$ 时 $\mathrm{df} = D$，就是普通最小二乘；$\lambda \to \infty$ 时 $\mathrm{df} \to 0$，模型退化为常数。中间的值可以理解为「模型实际用掉了几个参数」。

> **补充 | 有效自由度的用处**
>
> 它把「λ 越大模型越简单」这句定性的话变成了一个可计算的量。给定数据，你可以先画出 $\mathrm{df}(\lambda)$ 曲线，看 λ 取多大时模型的有效复杂度降到期望水平，再去交叉验证微调。

> 注意 $\mathrm{df}(\lambda)$ 随 λ 单调下降（每一项都是 λ 的减函数），所以「更简单的模型」这件事有严格定义，不依赖直觉。

几何图像 (44) 与下面这个带约束的问题是等价的（拉格朗日乘子，λ 与 C 一一对应）：

$$\min_{\mathbf{w}} \|\mathbf{y}-\mathbf{X}\mathbf{w}\|^2 \quad \text{s.t.} \quad \|\mathbf{w}\|_2 \le C. \tag{50}$$

损失函数的等值线是椭圆（因为 $\mathbf{X}^\top\mathbf{X}$ 一般不是单位阵，椭圆会被拉长、旋转），约束区域是一个球。两者相切之处就是解。二维时球是圆，切点通常落在圆周上的任意位置——**两个坐标一般都不为零**。所以在二维图景里，岭回归不产生稀疏解。图 4(b) 会把这两个约束区域并排画出来。

4.3 Lasso：把参数压到零

目标与最优性条件

$$L_\lambda^{\mathrm{L}}(\mathbf{w}) = \|\mathbf{y}-\mathbf{X}\mathbf{w}\|_2^2 + \lambda\|\mathbf{w}\|_1 = \|\mathbf{y}-\mathbf{X}\mathbf{w}\|_2^2 + \lambda\sum_{j=1}^{D}|w_j|. \tag{51}$$

绝对值在 $w_j=0$ 处不可导，于是「梯度为零」要换成「零属于次微分」。记残差 $\mathbf{r}=\mathbf{y}-\mathbf{X}\mathbf{w}$，则

情形	最优性条件
$w_j \neq 0$	$-2(\mathbf{X}^\top\mathbf{r})_j + \lambda\ \mathrm{sign}(w_j) = 0$
$w_j = 0$	$\lvert 2(\mathbf{X}^\top\mathbf{r})_j\rvert \le \lambda$

换个说法会更直观。令 $c_j=(\mathbf{X}^\top\mathbf{r})_j$，它是「第 j 个特征与当前残差的内积」，可以读作两者尚未解释的相关性。条件变成

$$c_j = \frac{\lambda}{2}\,\mathrm{sign}(w_j)\ \ (w_j\neq 0), \qquad |c_j| \le \frac{\lambda}{2}\ \ (w_j = 0). \tag{52}$$

> **Lasso 在做什么**
>
> 在所有被**选入**的特征上，它与残差的相关性被钉在同一个水平 $\lambda/2$ 上；相关系数低于这个阈值的特征，一律被压到零并留在零。所以 λ 直接控制「进入模型的门槛」。

正交设计下的闭式解：软阈值 一般情形下 Lasso 没有闭式解，但有一个特例能看清机制。若 $\mathbf{X}^\top\mathbf{X}=\mathbf{I}$（特征正交且已归一），记 $\mathbf{z}=\mathbf{X}^\top\mathbf{y}$，则 $c_j = z_j - w_j$，条件变为

$$2(z_j - w_j) = \lambda\ \mathrm{sign}(w_j) \ \text{ 或 } \ w_j = 0. \tag{53}$$

逐坐标解出：

$$\boxed{\hat{w}_j = \operatorname{sign}(z_j)\max\left(|z_j| - \frac{\lambda}{2},\, 0\right)} \tag{54}$$

这就是**软阈值**算子。它把每个坐标朝零的方向平移 $\lambda/2$，平移量不够就归零。

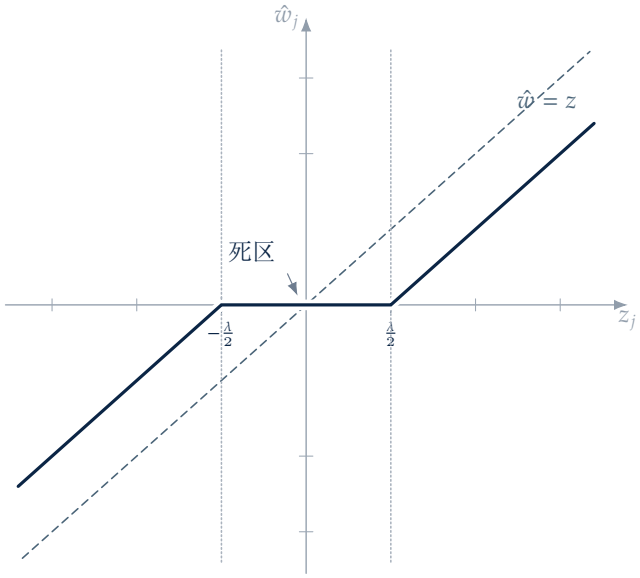


图 3 软阈值（$\lambda = 2$，故阈值为 $\lambda/2 = 1$）。虚线是对角线 $\hat{w} = z$，实线是 Lasso 的解。$|z_j| \le 1$ 的坐标被压成精确的零，这是稀疏性的直接来源。

图 3 把 (54) 画了出来。中间那段平坦的「死区」就是稀疏的产地：只要原始估计 $|z_j|$ 落在阈值内，输出就是零。也请注意这条曲线的形状——它连续，但有一个折点；相比之下，硬阈值（直接截断）是不连续的，这会让估计的方差更大。

为什么 L_1 能产生稀疏解 三条理由，从严格到直观。

其一，推力不随参数衰减 对 L_2 项求导得 $2\lambda w_j$：当 $w_j \to 0$ 时，把它继续往零推的力也趋于零，于是它只能无限接近零，永远到不了。对 L_1 项，次梯度的模长恒为 λ，与 w_j 的大小无关——只要还在动，力就是满的，所以能一口气推到零并停住。

其二，零点的次微分包含原点 L_1 在 0 处的次微分是区间 $[-\lambda, \lambda]$，不是单点。这意味着只要数据给出的梯度落在区间内，$w_j = 0$ 就满足最优性条件。L_2 在 0 处的次微分只有单点 $\{0\}$，要求苛刻得多。

其三，几何上更容易切到顶点 损失等高线是椭圆，约束区域是 $\|\mathbf{w}\|_1 \le C$ 的菱形。菱形有顶点落在坐标轴上，而顶点处更「尖」，切点落在顶点的可能性比落在边上大。

> **注意 | 几何论证只是直觉，不是证明**
>
> 图 4 是二维示意图。它告诉你「为什么可能稀疏」，但没有证明「一定稀疏」或「稀疏多少」：高维情形无法用平面图代替，切点是否落在顶点还取决于 $\mathbf{X}^\top\mathbf{X}$ 的具

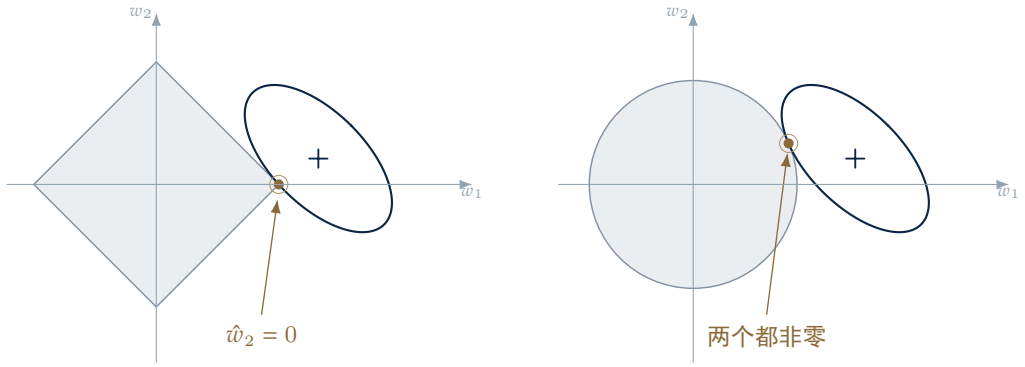


图 4 L_1 与 L_2 约束的几何对比（权重空间的二维截面）。椭圆是损失函数的等值线，十字标出普通最小二乘解 $\hat{\mathbf{w}}_{\text{OLS}}$，圆点是切点。**左**：菱形 $\|\mathbf{w}\|_1 \le C$ 与椭圆相切于顶点 $(1, 0)$，故 $\hat{w}_2 = 0$，解是稀疏的。**右**：圆 $\|\mathbf{w}\|_2 \le C$ 与椭圆相切于一般位置，两个分量都不为零。两图取自同一组 $\mathbf{X}^\top\mathbf{X}$ 与同一个 $\hat{\mathbf{w}}_{\text{OLS}}$，因此差异完全由约束区域的形状造成。

> 体结构。
>
> 严格的结论来自次梯度分析（即上面的「其二」），或者 KKT 条件。把几何图当作记忆的钩子可以，当作论证不行。

实践中的几个坑

(1) **相关特征之间的选择不稳定。**若两个特征高度相关、信息几乎重复，Lasso 往往只保留其中一个，但保留谁带有随机性——换一份样本，可能换成另一个。若你关心「哪一组特征重要」而不是「哪一个」，请用 Elastic Net 或 group Lasso。

(2) **$N < D$ 时的上限。**可以证明（一般位置下），Lasso 至多选出 N 个非零系数。所以从一万个特征里选一千个、而样本只有几百，Lasso 做不到——这是维度决定的硬约束，不是调参能解决的。

(3) **没有闭式解。**除正交设计等特例外，Lasso 要用坐标下降或近端梯度法迭代求解。它的解关于 λ 连续但不可微：在若干临界点上，活跃集（哪些系数非零）会突然改变，因此不能照搬最小二乘那套假设检验。

(4) **λ 的尺度依赖损失函数的写法。**若损失写成 $\frac{1}{2}$RSS 或 $\frac{1}{2N}$RSS，同一个 λ 的含义完全不同。比较不同教材、不同软件的参数时，先对齐约定。

4.4 Elastic Net：两者折中

$$L^{\text{EN}}_{\lambda_1,\lambda_2}(\mathbf{w}) = \|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2 + \lambda_1\|\mathbf{w}\|_1 + \lambda_2\|\mathbf{w}\|_2^2. \tag{55}$$

它同时具备两个正则项的好处：

- 只要 $\lambda_2 > 0$，目标函数**严格凸**，解唯一且连续依赖于数据——补上了 Lasso 在相关特征上的不稳定；
- $\lambda_1 > 0$ 保留了稀疏性，仍能做变量选择；

- 相关特征倾向于一起进入或一起退出（grouping effect），这通常比「随机挑一个」更符合实际需要。

代价是多了一个超参数，调参成本上升。实践中常用的做法是固定 λ_1/λ_2 的比例（如 $1:1$），只调总强度。

4.5 实施清单

做正则化回归之前的六件事

(1) **标准化特征**（减均值、除标准差）。惩罚项作用于系数的绝对大小，量纲不同则惩罚不公平：把「米」换成「厘米」，同一个系数会放大 100 倍，被惩罚得也多 100 倍。

(2) **不惩罚截距**。用中心化或 $\boldsymbol{\Lambda} = \mathrm{diag}(0, \lambda, \ldots, \lambda)$，理由见 §1.4。

(3) **λ 用交叉验证选**，不要用训练误差——它随 λ 减小而单调下降，选出来的永远是 $\lambda = 0$。

(4) **确认 λ 的尺度约定**（损失是否带 $1/2$、是否除以 N），见上面的坑 (4)。

(5) **用路径求解**：从大到小遍历一组 λ，用上一个解作为下一个的初值（warm start），比每个 λ 独立求解快一个量级。

(6) **报告时写清**是否标准化、λ 如何选、在哪个集合上评估——否则结果不可复现。

5 评估、推断与诊断

解出 $\hat{\mathbf{w}}$ 只是拿到一个数。这一节回答三个后续问题：这个数有多准？模型设定对不对？换一批数据还灵不灵？

5.1 训练误差不是答案

图 5 是本讲最重要的一张示意图。它说的是：训练误差可以一直被压低，直到为零；但这毫无意义。真正决定模型好坏的是那条 U 形曲线的最低点。

补充 | 偏差—方差分解

把 U 形曲线拆开，可以看得更细。设真实关系为 $y = f(\mathbf{x}) + \epsilon$，$\mathrm{Var}(\epsilon) = \sigma^2$，用某个模型得到 $\hat{f}$，则在 $\mathbf{x}_0$ 处的期望误差为

$$\mathbb{E}\big[(y - \hat{f}(\mathbf{x}_0))^2\big] = \underbrace{\sigma^2}_{\text{不可约噪声}} + \underbrace{\big(\mathrm{Bias}[\hat{f}(\mathbf{x}_0)]\big)^2}_{\text{偏差}^2} + \underbrace{\mathrm{Var}[\hat{f}(\mathbf{x}_0)]}_{\text{方差}}. \tag{56}$$

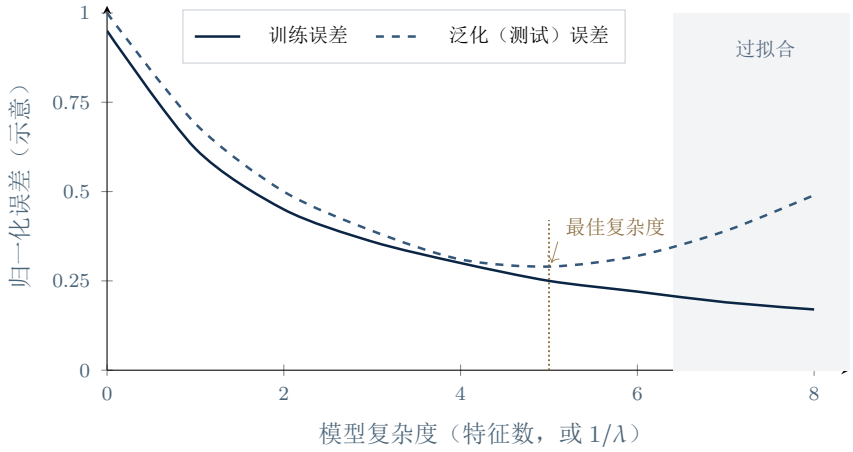


图 5　训练误差与泛化误差随复杂度的变化（示意图，非实测数据）。训练误差单调下降；泛化误差先降后升，呈 U 形。两者的差距随复杂度扩大，这个差距就是过拟合的直接度量。

> 模型越复杂，偏差越小、方差越大。正则化做的事，就是主动引入一点偏差，换取方差的下降——只要方差降得比偏差涨得多，总误差就变小。
>
> 这也解释了岭回归为什么常常「有偏却更好」：它放弃了无偏性（Gauss–Markov 定理的结论），换来了更小的均方误差。

5.2　回归的常用指标

均方误差与平均绝对误差

$$\mathrm{MSE}=\frac{1}{N}\sum_i \hat{e}_i^2,\qquad \mathrm{RMSE}=\sqrt{\mathrm{MSE}},\qquad \mathrm{MAE}=\frac{1}{N}\sum_i |\hat{e}_i|. \tag{57}$$

RMSE 与 y 同量纲，最好解释；MAE 对离群点不敏感。两者差距很大时，说明残差分布有明显厚尾。

决定系数　以「永远预测均值」为基线，看模型减少了多少平方误差：

$$R^2=1-\frac{\mathrm{RSS}}{\mathrm{TSS}},\qquad \mathrm{RSS}=\sum_i \hat{e}_i^2,\quad \mathrm{TSS}=\sum_i (y_i-\bar{y})^2. \tag{58}$$

对本讲例题，$R^2=1-34.07/1405.5=0.9758$，即模型解释了约 97.6% 的平方变异。

调整 R^2

$$R^2_{\mathrm{adj}}=1-\frac{\mathrm{RSS}/(N-D)}{\mathrm{TSS}/(N-1)}. \tag{59}$$

分母 $N-D$ 正是残差自由度（$\hat{\sigma}^2$ 的分母，见 (34)）。例题中 $R^2_{\mathrm{adj}}=1-\frac{34.07/6}{1405.5/7}=0.9717$。

注意 | 三个关于 R^2 的陷阱

(1) **加特征 R^2 不会下降**，哪怕加的是随机噪声。所以比较不同特征数的模型要用 R^2_{adj}（或直接用交叉验证）。

(2) **在测试集上 R^2 可以为负**。此时模型比「直接预测均值」还差——这不是计算错误，是模型真的没用。

(3) **R^2 高不等于模型对**。漏掉关键变量、外推到训练范围之外、数据有泄漏，都可能给出一个漂亮的 R^2。

5.3 系数的可信度

Gauss–Markov 定理

定理 5.1 | Gauss–Markov

在下列假设下，最小二乘估计 $\hat{\mathbf{w}}$ 是**最佳线性无偏估计**（BLUE）：

(i) 模型线性：$\mathbf{y} = \mathbf{X}\mathbf{w} + \boldsymbol{\epsilon}$；

(ii) 误差零均值：$\mathbb{E}[\boldsymbol{\epsilon}] = \mathbf{0}$；

(iii) 同方差且互不相关：$\mathrm{Cov}(\boldsymbol{\epsilon}) = \sigma^2\mathbf{I}$；

(iv) $\mathbf{X}$ 非随机（或误差与 $\mathbf{X}$ 不相关）。

「最佳」的含义要读准：在*所有线性无偏估计*中方差最小。它并没有说 $\hat{\mathbf{w}}$ 是「所有估计中最好的」——有偏的岭估计常常拥有更小的均方误差。这不算违背定理，只是换了一个评价标准。

标准误与 t 检验 在假设 (i)–(iv) 之上再加「误差服从正态分布」，可以推出

$$\mathrm{Cov}(\hat{\mathbf{w}}) = \sigma^2(\mathbf{X}^\top\mathbf{X})^{-1}, \qquad \widehat{\mathrm{se}}(\hat{w}_j) = \hat{\sigma}\sqrt{\left[(\mathbf{X}^\top\mathbf{X})^{-1}\right]_{jj}}, \tag{60}$$

其中 $\hat{\sigma}$ 由 (34) 给出。检验单个系数是否为零：

$$t_j = \frac{\hat{w}_j}{\widehat{\mathrm{se}}(\hat{w}_j)} \;\sim\; t_{N-D} \quad \text{（在原假设} w_j = 0 \text{ 下）}. \tag{61}$$

95% 置信区间为 $\hat{w}_j \pm t_{0.975,\,N-D}\cdot\widehat{\mathrm{se}}(\hat{w}_j)$。

以例题的斜率为例：$\hat{\sigma}^2 = 5.68$，$[(\mathbf{X}^\top\mathbf{X})^{-1}]_{22} = 8/336 = 0.0238$，故 $\widehat{\mathrm{se}}(\hat{w}_1) = \sqrt{5.68\times 0.0238} = 0.368$，$t = 5.714/0.368 = 15.5$。在 t_6 分布下，这个值对应的双侧 p 值远小于 0.001。

整体 F 检验 检验「所有斜率同时为零」：

$$F = \frac{(\mathrm{TSS} - \mathrm{RSS})/(D-1)}{\mathrm{RSS}/(N-D)} \;\sim\; F_{D-1,\,N-D}. \tag{62}$$

一元回归时 $F = t^2$，可以当作一致性检查：例题中 $15.5^2 = 241.5$，与直接算出的 $F = (1405.5 - 34.07)/1 \div (34.07/6) = 241.5$ 吻合。

> **注意 | 这些 p 值有条件**
>
> 它们全部建立在「模型设定正确 + 误差正态 + 同方差」之上，且是在给定这个模型的前提下的推断。变量选择之后再报 p 值（所谓的「先看数据选变量，再做检验」）会严重低估不确定性，p 值偏小、区间偏窄。这在机器学习里叫选择性推断问题，值得警惕。

5.4 残差诊断

拟合值算出来后，最有信息量的不是 R^2，而是残差图：横轴画 $\hat{y}_i$，纵轴画 $\hat{e}_i$。

残差图的形态	通常意味着
随机散布在零线两侧，无形状	设定基本合适
呈 U 形或倒 U 形	漏了非线性项，加 x^2 或变换特征
呈漏斗形（随 $\hat{y}$ 增大而扩散）	异方差；考虑对 y 取对数或加权最小二乘
少数点远离主体	离群点；核对该观测，或改用稳健回归
呈周期性波动	数据有时间/空间结构，独立性假设不成立

多重共线性 若某特征能被其余特征很好地线性预测，$\mathbf{X}^\top\mathbf{X}$ 就接近奇异，$(\mathbf{X}^\top\mathbf{X})^{-1}$ 的对角元很大，标准误随之爆炸。度量指标是方差膨胀因子：

$$\mathrm{VIF}_j = \frac{1}{1 - R_j^2}, \tag{63}$$

其中 R_j^2 是把第 j 个特征对其余特征做回归得到的决定系数。经验上 VIF > 5 就值得注意，> 10 通常认为严重。

症状很典型：整体 F 检验显著，但每个系数的 t 检验都不显著；删掉一个特征后，其余系数剧烈变化甚至变号。

杠杆与影响点 帽子矩阵的对角元 $h_{ii} = [\mathbf{H}]_{ii}$ 度量第 i 个观测在特征空间中的「偏远程度」，平均值为 D/N。h_{ii} 接近 1 的点会把自己的预测拉向自己。结合残差大小，可以用 Cook 距离衡量「删掉这个点，系数会变多少」。

5.5 交叉验证

K 折交叉验证的流程：把数据均分为 K 份，轮流用其中一份做验证、其余做训练，得到 K 个误差，取平均。$K = 5$ 或 10 是常用值。

注意 | 泄漏的三种常见形式

(1) **先标准化再划分**：均值与标准差里已经含了验证集的信息。正确做法是只在训练折上拟合标准化参数，再应用到验证折。

(2) **先选特征再划分**：用全量数据挑出的特征，其「好坏」已经被验证集污染，交叉验证会给出过于乐观的估计。

(3) **用测试集调参**：反复用测试集比较模型，等于把测试集变成了训练集。调参要用验证集，测试集只在最后用一次。

补充 | 嵌套交叉验证

当超参数（如 λ）也要用交叉验证选时，评估性能的交叉验证必须套在选参的交叉验证外面：外层划分用于评估，内层划分用于选参。否则选参用过的数据又用来评估，结果仍然偏乐观。代价是计算量乘以 K，但这是得到无偏性能估计的必要开销。

6 线性回归之后

线性模型有一个天然的短板：它只能表达「各特征线性叠加」的关系。真实世界几乎从不这么听话。克服这一短板的思路大致有三条，恰好对应后来机器学习的三条主线。

6.1 换特征：基函数展开

第一条路最省事：模型不变，把输入换掉。取一组基函数 $\phi_1, \dots, \phi_M$，令

$$\boldsymbol{\phi}(\mathbf{x}) = \big(\phi_1(\mathbf{x}), \dots, \phi_M(\mathbf{x})\big)^\top, \qquad f(\mathbf{x}) = \mathbf{w}^\top \boldsymbol{\phi}(\mathbf{x}). \tag{64}$$

只要 $\mathbf{w}$ 仍是线性进入的，整个第 2 节的推导一字不改，只需把 $\mathbf{X}$ 换成设计矩阵 $\boldsymbol{\Phi} \in \mathbb{R}^{N\times M}$，其第 i 行为 $\boldsymbol{\phi}(\mathbf{x}_i)^\top$：

$$\hat{\mathbf{w}} = (\boldsymbol{\Phi}^\top \boldsymbol{\Phi})^{-1} \boldsymbol{\Phi}^\top \mathbf{y}. \tag{65}$$

多项式回归取 $\phi_j(x) = x^{j-1}$；样条回归取分段多项式基；径向基函数取 $\phi_j(\mathbf{x}) = \exp(-\|\mathbf{x} - \boldsymbol{\mu}_j\|^2 / 2h^2)$。它们把「非线性」全部转移到了特征构造上，求解仍然是线性最小二乘。

代价是 M 变成一个需要选择的复杂度参数。M 太小欠拟合，M 太大会过拟合——第 4 节的正则化在这里同样适用，而且更加必要：多项式基在高次项上极易共线，$\boldsymbol{\Phi}^\top\boldsymbol{\Phi}$ 的条件数会迅速恶化。

6.2 加一层非线性：从回归到分类

第二条路是在线性输出后面接一个非线性函数。最典型的例子是逻辑回归：

$$p(y=1\mid\mathbf{x})=\sigma(\mathbf{w}^{\top}\mathbf{x}),\qquad \sigma(z)=\frac{1}{1+e^{-z}}. \tag{66}$$

这里的 $\mathbf{w}^{\top}\mathbf{x}$ 仍然是一个线性打分，σ 把它压到 $(0,1)$ 区间，于是回归问题变成了分类问题。

但目标函数必须换。若仍用平方损失，$L(\mathbf{w})=\sum_i(y_i-\sigma(\mathbf{w}^{\top}\mathbf{x}_i))^2$ 关于 $\mathbf{w}$ 是非凸的，而且当预测严重错误时 σ 处于饱和区、梯度趋近于零——错得越离谱，学得越慢。改用交叉熵（等价于伯努利似然下的极大似然）：

$$L(\mathbf{w})=-\sum_{i=1}^{N}\Big[y_i\log\sigma(\mathbf{w}^{\top}\mathbf{x}_i)+(1-y_i)\log\big(1-\sigma(\mathbf{w}^{\top}\mathbf{x}_i)\big)\Big], \tag{67}$$

它凸、且梯度形式极简：$\nabla L=\sum_i(\sigma(\mathbf{w}^{\top}\mathbf{x}_i)-y_i)\mathbf{x}_i$。注意这个式子和最小二乘的梯度 $\mathbf{X}^{\top}(\mathbf{X}\mathbf{w}-\mathbf{y})$ 形状完全一致——都是「残差乘特征再求和」，只是「残差」的定义变了。

广义线性模型（GLM）把这件事抽象成一个框架：线性预测子 $\eta=\mathbf{w}^{\top}\mathbf{x}$，加上一个链接函数 g 使得 $\mathbb{E}[y\mid\mathbf{x}]=g^{-1}(\eta)$。线性回归是 g 为恒等映射、噪声高斯的特例；逻辑回归是 g 为 logit、噪声伯努利的特例。两者的求解都可以统一成迭代加权最小二乘。

6.3 多叠几层：神经网络

第三条路是把「线性 + 非线性」这个模块反复叠加：

$$f(\mathbf{x})=\mathbf{w}_2^{\top}\,\sigma\big(\mathbf{W}_1\mathbf{x}+\mathbf{b}_1\big). \tag{68}$$

单看每一层，都是一个线性变换加一个非线性激活；合起来却能逼近相当一般的函数。反向传播做的事，本质上是把第 2 节的链式法则逐层复用。

从这个角度看，线性回归是所有分层模型的最后一层——它负责把学到的表示映射成输出，而且通常保留线性形式，因为线性层的梯度最稳定、最容易优化。

一句话

线性回归不是「简单到可以跳过」的模型，而是所有后续模型的公共底座：换特征就是核方法与前馈网络的雏形，加非线性就是广义线性模型，叠多层就是深度学习。第 2 节那三条推导——二次型展开、驻点条件、正交投影——会在完全不同的模型里反复出现。

7 小结

7.1 五句话

1. **「线性」约束的是参数，不是曲线。**只要 $\mathbf{w}$ 线性进入，模型就能拟合任意弯曲的形状；反过来，$w_1^2 x$ 画出来是直线，却不是线性模型。
2. **最小二乘有三种身份，且彼此等价。**代数上是二次型的驻点，几何上是列空间上的正交投影，统计上是高斯噪声下的极大似然。三种语言各有用途：算的时候用代数，想的时候用几何，判断假设是否成立时用统计。
3. **损失由噪声决定，正则由先验决定。**这两件事各管一头，可以自由组合（表 3）。把「L_1 损失」和「L_1 正则」混为一谈，是这一章最常见的误解。
4. **岭回归收缩，Lasso 稀疏。**差别的根源有两处：约束区域的形状（球 vs 菱形），以及次微分的结构（单点 vs 区间）。几何图给出直觉，次梯度给出证明。
5. **闭式解只是起点。**条件数、多重共线性、过拟合、数据泄漏，没有一个能靠「代入公式」解决。真正的建模工作，大半发生在解出 $\hat{\mathbf{w}}$ 之后。

7.2 一张图

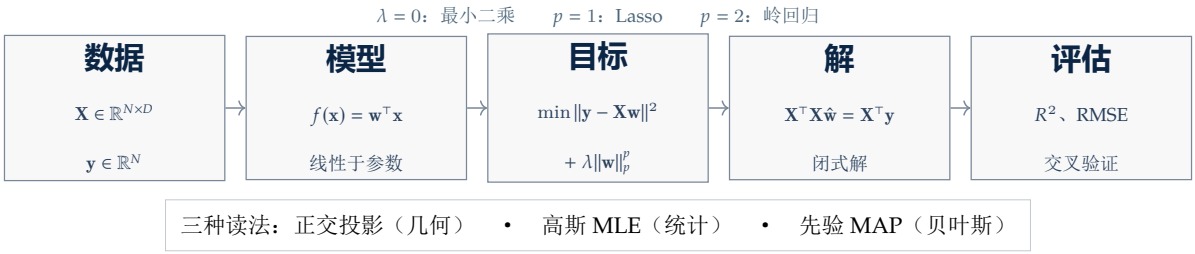


图 6 本讲的知识地图。横向是建模的流水线，纵向是理解同一个目标函数的三副眼镜。

7.3 接下来

第 2 节的推导有两条自然的延长线，正好是本讲义的后续两节：

- **线性分类。**把 $\mathbf{w}^\top \mathbf{x}$ 塞进一个非线性函数，就得到感知机、LDA、逻辑回归、高斯判别分析与朴素贝叶斯。届时第 3 节的「似然」会再次出现，只是分布从高斯换成了伯努利或多项。
- **降维。**当 D 大到 $\mathbf{X}^\top \mathbf{X}$ 无法可靠估计时，与其加正则，不如先找一个低维表示。PCA 做的事，本质上是在 $\mathbf{X}$ 的列空间里再挑一个「最有信息量」的子空间——用的还是 SVD，还是第 2 节那套语言。

习题

A 组•基础

A1. 用表 1 的数据，手算 $\mathbf{X}^\top\mathbf{X}$ 与 $\mathbf{X}^\top\mathbf{y}$，验证 $\hat{\mathbf{w}} = (47.04,\, 5.71)^\top$；再用 S_{xy}/S_{xx} 的公式算一遍，确认两者一致。

A2. 证明：只要模型含截距，最小二乘残差满足 $\sum_i \hat{e}_i = 0$，且拟合值均值等于观测均值 $\bar{\hat{y}} = \bar{y}$。

A3. 一元回归（含截距）的帽子矩阵元素为

$$h_{ij} = \frac{1}{N} + \frac{(x_i - \bar{x})(x_j - \bar{x})}{S_{xx}}. \tag{69}$$

验证 $\operatorname{tr}(\mathbf{H}) = 2$，并解释为什么对角线上的 h_{ii} 可以衡量「第 i 个观测的杠杆」。

A4. 设 $\mathbf{X}^\top\mathbf{X} = \operatorname{diag}(4, 1)$，$\mathbf{X}^\top\mathbf{y} = (8,\, 0.4)^\top$，取 $\lambda = 1$。分别求岭回归解与 Lasso 解，指出哪个解是稀疏的。

A5. 计算例题的 R^2 与调整 R^2，并说明为什么调整 R^2 略小。

B 组•提高

B1. 设 $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top$。证明对任意 $\mathbf{w}$，

$$\|\mathbf{y} - \mathbf{X}\mathbf{w}\|^2 = \|\mathbf{y} - \mathbf{H}\mathbf{y}\|^2 + \|\mathbf{H}\mathbf{y} - \mathbf{X}\mathbf{w}\|^2, \tag{70}$$

从而 $\hat{\mathbf{w}}$ 是全局最小点。（提示：把 $\mathbf{y} - \mathbf{X}\mathbf{w}$ 拆成 $(\mathbf{y} - \mathbf{H}\mathbf{y}) + (\mathbf{H}\mathbf{y} - \mathbf{X}\mathbf{w})$，证明两项正交。）

B2. 证明 $\operatorname{tr}(\mathbf{H}) = D$，并说明为什么它可以被解释为「模型用掉的参数个数」。再证明岭回归的 $\operatorname{tr}(\mathbf{H}_\lambda)$ 随 λ 单调递减。

B3. 证明岭回归的解满足 $\|\hat{\mathbf{w}}_\lambda\|_2$ 关于 λ 单调不增，且 $\lambda \to \infty$ 时 $\hat{\mathbf{w}}_\lambda \to \mathbf{0}$。

B4. 构造一个例子：$\mathbf{X}$ 的两列完全相同。说明此时最小二乘解不唯一，但 $\hat{\mathbf{y}}$ 唯一，并写出全部解的集合。这个例子对「特征工程」有什么启示？

B5. 设 $\mathbf{X}^\top\mathbf{X} = \mathbf{I}$。用次梯度条件证明 Lasso 的解为 $\hat{w}_j = \operatorname{sign}(z_j)\max(|z_j| - \lambda/2,\, 0)$，其中 $\mathbf{z} = \mathbf{X}^\top\mathbf{y}$。

C 组•动手

C1. 用 NumPy 实现最小二乘的两个版本：直接解正规方程、调用 `np.linalg.lstsq`。在例题数据上比较两者的系数差异；再人为把第二列乘以 10^6 制造病态，重新比较，并报告两者的条件数与系数偏差。

C2. 生成 $N = 50$、$D = 60$ 的随机数据（$\mathbf{y}$ 与 $\mathbf{X}$ 独立），做线性回归。验证训练误差约等于零，再用一份独立测试集计算 R^2，解释结果。

C3. 在同一份数据上画出岭回归的系数路径：横轴 $\log\lambda$，纵轴各系数取值，λ 从小到大。观察系数如何随 λ 增大而整体收缩到零，并标出 $\mathrm{df}(\lambda)$ 曲线的对应位置。

提示

- **A2**：$\mathbf{X}$ 的第一列全为 1，故 $\mathbf{X}^\top\hat{\mathbf{e}}$ 的第一个分量就是 $\sum_i \hat{e}_i$。
- **A3**：第一项贡献 1，第二项贡献 $\sum_i (x_i-\bar{x})^2/S_{xx}=1$。
- **A4**：岭回归要解 $(4+1)w_1=8$、$(1+1)w_2=0.4$；Lasso 中 $\mathbf{z}=(2,\,0.4)$，阈值为 $\lambda/2=0.5$。
- **B1**：注意 $\mathbf{Hy}-\mathbf{Xw}\in\mathrm{Col}(\mathbf{X})$，而 $\mathbf{y}-\mathbf{Hy}=(\mathbf{I}-\mathbf{H})\mathbf{y}$ 与 $\mathrm{Col}(\mathbf{X})$ 正交。
- **B3**：用 SVD 写开，逐项看 $d_j/(d_j^2+\lambda)$ 关于 λ 的单调性。
- **B4**：两列相同意味着零空间至少含 $(1,-1,0,\dots)^\top$ 这一方向。
- **B5**：分 $w_j>0$、$w_j<0$、$w_j=0$ 三种情形讨论，注意 $c_j=z_j-w_j$。
- **C2**：训练误差为零不奇怪（$D>N$），关键看测试 R^2 是否接近零甚至为负。

A 矩阵求导速查

本讲用到的矩阵求导规则不多，但每一条都容易被误用。下表默认 $\mathbf{w}\in\mathbb{R}^D$、$\mathbf{A}\in\mathbb{R}^{D\times D}$、$\mathbf{b}\in\mathbb{R}^N$、$\mathbf{B}\in\mathbb{R}^{N\times D}$，且求导结果采用**分母布局**（梯度与 $\mathbf{w}$ 同型，均为列向量）。

表达式	对 $\mathbf{w}$ 的导数	备注
$\mathbf{a}^\top\mathbf{w}$	$\mathbf{a}$	线性项
$\mathbf{w}^\top\mathbf{A}\mathbf{w}$	$(\mathbf{A}+\mathbf{A}^\top)\mathbf{w}$	$\mathbf{A}$ 对称时为 $2\mathbf{A}\mathbf{w}$
$\lVert\mathbf{B}\mathbf{w}-\mathbf{b}\rVert_2^2$	$2\mathbf{B}^\top(\mathbf{B}\mathbf{w}-\mathbf{b})$	本讲用得最多
$\lVert\mathbf{w}\rVert_2^2$	$2\mathbf{w}$	岭项
$\log\det\mathbf{A}$	（对 $\mathbf{A}$）$\mathbf{A}^{-\top}$	本讲未用，备查

三条使用规则：

(1) **先看维度。**$\partial f/\partial\mathbf{w}$ 必须与 $\mathbf{w}$ 同型。若算出的结果维度不对，八成是转置放错了位置。

(2) **标量可以自由转置。**$\mathbf{w}^\top\mathbf{X}^\top\mathbf{y}$ 与 $\mathbf{y}^\top\mathbf{X}\mathbf{w}$ 是同一个数。这条规则在二次型展开时最关键。

(3) **二次型先对称化。**遇到 $\mathbf{w}^\top\mathbf{A}\mathbf{w}$ 且 $\mathbf{A}$ 不对称时，可以先换成 $\frac{1}{2}(\mathbf{A}+\mathbf{A}^\top)$，再套对称情形的公式。

B 延伸阅读

[1] C. M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.

第 3 章：线性回归的贝叶斯视角，含预测分布与证据近似。

[2] T. Hastie, R. Tibshirani, J. Friedman. *The Elements of Statistical Learning*, 2nd ed. Springer, 2009.

第 3 章：最小二乘与岭回归；第 3.4 节：Lasso 与软阈值。

[3] R. Tibshirani. Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B*, 58(1):267–288, 1996.

Lasso 的原始论文，含几何解释与稀疏性的讨论。

[4] A. E. Hoerl, R. W. Kennard. Ridge regression: biased estimation for nonorthogonal problems. *Technometrics*, 12(1):55–67, 1970.

岭回归的原始文献。

[5] H. Zou, T. Hastie. Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society: Series B*, 67(2):301–320, 2005.

Elastic Net，含 grouping effect 的讨论。

[6] G. H. Golub, C. F. Van Loan. *Matrix Computations*, 4th ed. Johns Hopkins University Press, 2013.

第 5 章：最小二乘问题的 QR 与 SVD 解法、条件数分析。

[7] 周志华. 《机器学习》. 清华大学出版社, 2016.

第 3 章：线性模型。中文表述最简洁的一本，与本讲记号接近。

CyArk