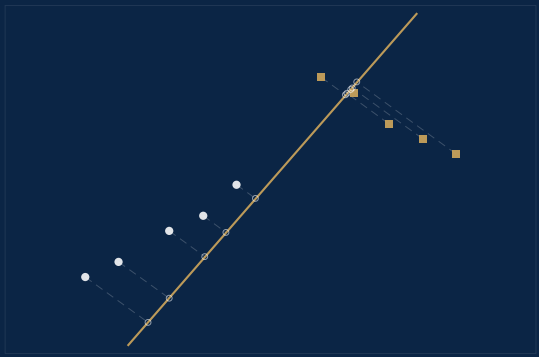
机器学习 · 讲义系列

线性判别分析

从投影方向到分类边界



Linear Discriminant Analysis

第 二 讲

本 讲 涵 盖

投影与 Fisher 准则 · 散布矩阵与广义特征值 · $K-1$ 维上限 · 判别函数与 GDA · 与 PCA 的分野

https://github.com/CyArk-fs/MLnote

目　录

导读 **1**

1　分类不是「回归加阈值」 **2**

1.1　一个具体的问题 2

1.2　为什么不能直接用回归 3

1.3　一个分类器由三件东西组成 4

1.4　在模型地图上的位置 4

2　一个方向：把点压到一条线上 **4**

2.1　投影：一个方向决定一切 5

2.2　好方向长什么样 5

2.3　Fisher 准则 6

2.4　求解：从求导到广义特征值 6

2.5　例题：把数代进去 7

2.6　为什么不是中心连线 8

2.7　阈值切在哪里 9

3　一组方向：二类到 K 类 **10**

3.1　一个方向不够用 10

3.2　三个散布矩阵 11

3.3　目标函数：为什么不能照抄迹比 12

3.4　求解：广义特征值问题 13

3.5　最多只能用 $K-1$ 维 13

4　判定：最近质心、判别函数与 GDA **14**

4.1　三种等价的说法 14

4.2　尺度一致性 16

4.3　从贝叶斯公式到共享协方差 16

4.4　松开假设：QDA 17

4.5　生成式与判别式的分工 17

5　与 PCA 的分野：有监督的降维 **18**

5.1　同一份数据，两个方向 18

5.2　三个区别 19

6　实现、校验与边界 **19**

6.1　五步算法 19

6.2　参考实现 20

6.3　数值校验 20

6.4　复杂度 21

6.5　七条前提与失效场景 21

7　小结 **22**

7.1　五句话 23

7.2　一张图 23

7.3　接下来 23

习题 **24**

A　公式速查 **25**

B　延伸阅读 **26**

导　读

上一讲我们从「一组数」推出了「一个数」。这一讲要做的，是从「一组数」推出「一个类别」。

两者的距离没有想象中远。线性回归与线性判别分析共用同一个骨架：先算一个线性打分 $\mathbf{w}^\top\mathbf{x}$，再决定拿这个分数做什么。回归直接把它当预测值；分类则把它当证据，交给一条规则去翻译成类别。差别只在最后这一步，但恰恰是这一步，决定了整个模型的性格——损失函数、评估方式、失效场景，全都跟着变。

线性判别分析（Linear Discriminant Analysis，LDA）是这一步最经典的翻译方式之一。它的想法朴素到近乎笨拙：**找一个方向，把样本压到一条线上，让同类挤在一起、异类离得远些，然后在这条线上切一刀。**整讲的内容，都是把这句话里的每个词讲清楚：「方向」是什么，「挤在一起」怎么度量，「切一刀」切在哪里，以及——当类别不止两个时，一刀不够了怎么办。

> **补充　|　为什么先学 LDA，而不是先学逻辑回归**
>
> 两者都是线性分类器，但 LDA 多给了一样东西：**一个可以画出来的方向**。「把数据投影到一维再看」这个动作，在数据探索、可视化和特征压缩里天天用到，而 LDA 正是它的有监督版本。先掌握这个几何图像，后面学逻辑回归、感知机、支持向量机时，「决策边界是超平面」这句话才不是一句空话。

读完这一讲，你应当能够

1. 说清为什么不能直接把类别编码成数字做回归；
2. 写出 Fisher 准则，并推出两类情形下的 $\hat{\mathbf{w}} \propto \mathbf{S}_w^{-1}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)$；
3. 解释这个方向为什么不是两类中心连线，以及 $\mathbf{S}_w^{-1}$ 在其中起什么作用；
4. 写出三个散布矩阵，验证 $\mathbf{S}_t = \mathbf{S}_w + \mathbf{S}_b$，并说明为什么要带 N_c 权重；
5. 把多类问题化为广义特征值问题，证明最多只能用 $K-1$ 个方向；
6. 写出线性判别函数 $\delta_c(\mathbf{x})$，并说明它与高斯判别分析是同一个模型；
7. 判断 LDA 在什么数据上必然失效，以及工程上该怎么补救。

预备知识

- **线性代数**：矩阵乘法、转置、秩、正定与半正定、特征值与特征向量。会算 2×2 的逆就够了，正文所有推导都只用二阶例子。
- **概率统计**：条件概率、贝叶斯公式、均值与协方差、多元正态分布的密度函数（不熟也没关系，§4 会重新写一遍）。

- **微积分**：多元函数求极值、拉格朗日乘子。矩阵求导只在 §2.4 用一次，附录 A 给了替代路径。

记号约定

沿用上一讲的习惯：**粗体**表示向量或矩阵，斜体表示标量；上标 (j) 表示「第 j 维特征」，不是幂次。新增的只有类别相关的几个符号。

记号	含义	记号	含义
N	样本总数	D	特征维数
K	类别数	d	投影后的维数（$d \le K-1$）
N_c	第 c 类的样本数	$\bar{\mathbf{x}}_c$	第 c 类的样本均值
$\bar{\mathbf{x}}$	全体样本均值	$\hat{\phi}_c = N_c/N$	类先验（频率估计）
$\mathbf{S}_w$	类内散布矩阵	$\mathbf{S}_b$	类间散布矩阵
$\mathbf{S}_t$	总散布矩阵	$\mathbf{W} \in \mathbb{R}^{D\times d}$	投影矩阵（每列一个方向）
$\mathbf{w}$	单个投影方向	$z = \mathbf{w}^\top \mathbf{x}$	投影后的得分
$\delta_c(\mathbf{x})$	第 c 类的判别函数	$\boldsymbol{\Sigma}$	共享协方差（§4）

注意 N_c 与 N 的区别：前者是类内计数，后者是总数，$\sum_c N_c = N$。后文凡出现 $\sum_{i:y_i=c}$，都表示「只对第 c 类的样本求和」，等价于 $\sum_{i=1}^{N} \mathbb{I}(y_i = c)$。

三种读法

- **只想弄懂方向怎么来的**：读 §2.1–§2.5，然后看图 2。
- **想知道这个方向为什么合理**：§2.6 的白化 + §4.3 的概率解释，两页纸讲的是同一件事。
- **要应付多分类与考试推导**：§3 全读，重点是 §3.3 的反例与 §3.5 的秩论证。
- **要动手实现**：直接看 §6，再回头看 §2.4 与 §3.4 的公式。

1　分类不是「回归加阈值」

1.1　一个具体的问题

十朵鸢尾花，两个品种，两个测量指标：花瓣长度与花瓣宽度（单位 cm）。数据如表 1。

> **注意　|　关于这份数据**
>
> 真实鸢尾花数据集中，这两个品种的花瓣长在 3–7 cm、宽在 1–2.5 cm，本表按这个范围构造了 10 个样本，为的是让每一步都能手算。真实数据的结论与这里一致，只是数字不那么整齐。第 6 节会用 180 个样本、4 个类别、10 维特征做一次

表 1　两类鸢尾花的花瓣测量（教学用简化数据）

编号	1	2	3	4	5	6	7	8	9	10
花瓣长 $x^{(1)}$	4.6	4.1	5.0	4.3	4.8	5.9	5.5	6.3	5.7	6.1
花瓣宽 $x^{(2)}$	1.4	1.1	1.7	1.2	1.5	2.1	2.4	1.9	2.3	2.0
品种 y	变色鸢尾（记为类 1）					维吉尼亚鸢尾（记为类 2）				

> 完整校验。

把十个数对画在平面上，可以看到两类点各自聚成一团，沿右上方向排开（图 2 上半部分就是这个形状）。现在的问题是——

> 给你一朵新的花，只告诉你花瓣多长多宽，你判断它是哪个品种。

最直接的想法是：画一条线，把两团分开；来一朵新花，看它落在线的哪一侧。可是平面上的「一条线」有无穷多条都能把这两团分开。**选哪一条？**这个看似随意的问题，正是 LDA 要回答的。

1.2　为什么不能直接用回归

一个常见的偷懒做法：把类别编码成 0 和 1，然后做线性回归，预测值大于 0.5 就判为一类。这个模型有个名字，叫线性概率模型。它在实践中能用，但有三个绕不过去的毛病。

其一，输出没有边界。最小二乘的解是使平方误差最小的那条直线，它不知道 y 只能取两个值。当某个样本的特征很极端时，预测值可以是 1.7 或 -0.3。这些数字不是概率，却被当作概率用，阈值 0.5 也就失去了依据。

其二，类别编号的数值大小没有意义。二分类时编成 0/1 尚可辩解（只差一个单调变换），多分类就彻底不行了。若把三个品种编成 $1, 2, 3$，模型会认为「第 3 类与第 2 类的距离」等于「第 2 类与第 1 类的距离」，还会认为「第 1 类加第 3 类等于两倍的第 2 类」。这些说法在生物学上毫无意义，却实实在在地约束了拟合结果。

其三，损失函数关心错了地方。平方损失惩罚的是 $\|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2$，它希望每个样本的预测值都贴近标签。可对分类来说，一个已经离边界很远的样本，被推得更远没有任何收益。把力气花在这些样本上，等于让少数靠近边界的、真正决定边界的样本失去话语权。

> **补充　|　分类任务的损失应该是什么**
>
> 理想的是 0–1 损失：判错记 1，判对记 0。但它不连续、不可导，优化起来极难。于是实际做法是找一个*代理损失*：逻辑回归用交叉熵，支持向量机用合页损失，LDA

> 则干脆绕开损失，直接从分布假设出发（§4）。三条路殊途同归，都在逼近同一个目标：把边界放对。

1.3　一个分类器由三件东西组成

初学者容易把「模型」等同于「打分公式」，其实任何一个分类器都要回答三个问题：

部件	作用	LDA 的做法	备注
打分	给每个类别一个实数	$\delta_c(\mathbf{x}) = \mathbf{w}_c^\top \mathbf{x} + b_c$	分数大小只在类间比较时有意义
决策	把分数变成类别	$\hat{y} = \arg\max_c \delta_c(\mathbf{x})$	平局时需另定规则
评估	判断好坏	准确率、混淆矩阵	不平衡数据要换指标

这三件事可以独立替换。比如把打分换成一个二次函数，决策规则不变，就得到二次判别分析（§4.4）；把决策规则换成「分数超过阈值才判正类」，就得到代价敏感的分类器。分清楚这三层，读别的模型时就不会乱。

1.4　在模型地图上的位置

分类模型通常按三个维度分类。LDA 在每一维上的位置都很明确：

- **硬分类还是软分类**：LDA 输出的是类别，属于硬分类。但它离软分类只有一步——§4 会说明，δ_c 加上归一化就是后验概率 $p(y = c \mid \mathbf{x})$。
- **生成式还是判别式**：LDA 从「每类长什么样」出发（假设类条件密度），再用贝叶斯公式反推，属于生成式。这是它与逻辑回归最本质的差别。
- **线性还是非线性**：决策边界是超平面，属于线性方法。它的非线性扩展（QDA、核 LDA）都建立在同一套散布矩阵语言上。

一句话

LDA 做的事，是先找一个最好的观察角度，再在这个角度上做最简单的判定。这个「先降维再分类」的结构，让它既是一个分类器，也是一个有监督的降维方法——这两重身份会在 §5 与 PCA 的对比中再次出现。

2　一个方向：把点压到一条线上

2.1　投影：一个方向决定一切

给定方向 $\mathbf{w} \in \mathbb{R}^D$，把样本 $\mathbf{x}$ 投影到这条方向上的得分是

$$z = \mathbf{w}^\top \mathbf{x}. \tag{1}$$

若约定 $\|\mathbf{w}\| = 1$，z 就是 $\mathbf{x}$ 在 $\mathbf{w}$ 上的有符号长度；不约定也无妨，因为后面所有的判定只依赖 z 的相对大小。

这里有一个必须说清的性质：**把 $\mathbf{w}$ 换成 $c\mathbf{w}$（$c > 0$），所有样本的得分同时放大 c 倍，排序不变，判定不变。**把 $\mathbf{w}$ 换成 $-\mathbf{w}$，排序完全颠倒，但只需把两个类别的标签对调，判定同样不变。所以 LDA 求出的「方向」天生带一个正标量的不确定性——这既是它只能定方向、不能定尺度的原因，也是后面许多「尺度约定」麻烦的根源。

> **补充　|　为什么不用角度而用向量**
>
> 平面上「方向」可以用角度 θ 表示，但到了 D 维就没有单一的「角度」了。用向量表示方向，代价是要随时提醒自己「长度无关紧要」。习惯之后会发现这更方便：投影、内积、协方差都能直接用矩阵语言写出来，不必分情况讨论。

2.2　好方向长什么样

回到鸢尾花的例子。图 1 画了同一份数据上的三个方向，以及把它们各自的投影结果摊平之后的样子。

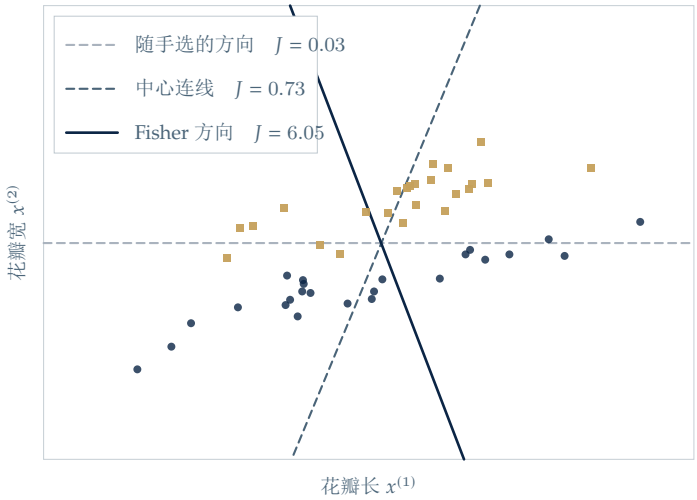


图 1　同一份数据、三个候选方向。J 是后面定义的 Fisher 准则：类间散布与类内散布之比。三个数值相差两个数量级，说明「选方向」这件事不是无关紧要的细节。注意中心连线的 J 竟不如随手选的横轴——因为这两团数据沿 18° 方向被拉得很长，沿中心连线看过去，类内的散布同样很大。

两个愿望可以写得很具体：

(P1) **类内要挤**。同一类的样本投影后应当聚得紧，也就是投影后类内方差小。

(P2) **类间要开**。两类的中心投影后应当离得远，也就是投影后类间均值差大。

这两个愿望是矛盾的：把方向转到类间差最大的地方，往往类内也最散。于是需要一个把两者放在一起的量。

2.3 Fisher 准则

记两类均值 $\bar{\mathbf{x}}_1, \bar{\mathbf{x}}_2$，类内散布矩阵

$$\mathbf{S}_w = \sum_{c=1}^{2} \sum_{i:y_i=c} (\mathbf{x}_i - \bar{\mathbf{x}}_c)(\mathbf{x}_i - \bar{\mathbf{x}}_c)^\top. \tag{2}$$

投影后，类内平方和变成 $\mathbf{w}^\top \mathbf{S}_w \mathbf{w}$，类间均值差变成 $\mathbf{w}^\top(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)$，其平方为 $\mathbf{w}^\top(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)^\top \mathbf{w}$。若定义

$$\mathbf{S}_b = (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)^\top, \tag{3}$$

则二者之比为

$$J(\mathbf{w}) = \frac{\mathbf{w}^\top \mathbf{S}_b \mathbf{w}}{\mathbf{w}^\top \mathbf{S}_w \mathbf{w}} = \frac{\left(\mathbf{w}^\top(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)\right)^2}{\mathbf{w}^\top \mathbf{S}_w \mathbf{w}}. \tag{4}$$

这就是 **Fisher 准则**。它是两个数的比：分子是投影后的类间散度，分母是投影后的类内散度。J 越大，两类在投影轴上分得越开。

> **补充　|　为什么分子不除以样本数**
>
> $\mathbf{S}_b$ 与 $\mathbf{S}_w$ 都用*平方和*而非方差。这样定义的好处是二者可以直接相加（§3.2 的分解），比值也不受影响——分子分母同乘一个常数，J 不变。真正的量纲问题在 §3.7 会专门交代。

> **注意　|　J 不是准确率**
>
> J 只度量「分得开不开」，不度量「分得对不对」。J 大意味着两类中心在投影轴上隔得远，但如果两类的形状差异极大（比如一类是长条、一类是圆团），或者样本严重不平衡，J 大并不保证错误率低。§7 会回到这一点。

2.4 求解：从求导到广义特征值

第一条路：直接求导。把 (4) 看成 $\mathbf{w}$ 的函数，令梯度为零。记 $N(\mathbf{w}) = \mathbf{w}^\top \mathbf{S}_b \mathbf{w}$，$D(\mathbf{w}) = \mathbf{w}^\top \mathbf{S}_w \mathbf{w}$，则

$$\nabla J = \frac{2\mathbf{S}_b\mathbf{w}\, D(\mathbf{w}) - N(\mathbf{w}) \cdot 2\mathbf{S}_w\mathbf{w}}{D(\mathbf{w})^2} = 0 \quad \Longrightarrow \quad \mathbf{S}_b\mathbf{w} = \frac{N(\mathbf{w})}{D(\mathbf{w})}\,\mathbf{S}_w\mathbf{w}. \tag{5}$$

右边那个比例系数正是 $J(\mathbf{w})$ 本身，记作 λ，于是

$$\mathbf{S}_b\mathbf{w} = \lambda\,\mathbf{S}_w\mathbf{w}. \tag{6}$$

这就是一个**广义特征值问题**。在 $\mathbf{S}_w$ 可逆时，两边左乘 $\mathbf{S}_w^{-1}$，得 $\mathbf{S}_w^{-1}\mathbf{S}_b\mathbf{w} = \lambda\mathbf{w}$。

而 $\mathbf{S}_b$ 是外积矩阵，值域只有 $\mathrm{Span}\{\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2\}$ 一个方向，秩为 1。因此它只有一个非零特征值，对应的特征向量必然与 $\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2$ 平行。代入 (6) 立刻得到

$$\boxed{\hat{\mathbf{w}} \;\propto\; \mathbf{S}_w^{-1}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)} \tag{7}$$

比例常数任取（习惯上取单位向量）。这个式子短得让人怀疑，但它是整讲的中心：**Fisher 最优方向 = 类内散布矩阵的逆，乘以两类中心差。**

第二条路：瑞利商。换个视角可以看得更透。$\mathbf{S}_w$ 正定时可以开平方，令 $\mathbf{u} = \mathbf{S}_w^{1/2}\mathbf{w}$，则

$$J(\mathbf{w}) = \frac{\mathbf{u}^\top \left(\mathbf{S}_w^{-1/2}\mathbf{S}_b\mathbf{S}_w^{-1/2}\right)\mathbf{u}}{\mathbf{u}^\top\mathbf{u}}, \tag{8}$$

这是实对称半正定矩阵 $\mathbf{S}_w^{-1/2}\mathbf{S}_b\mathbf{S}_w^{-1/2}$ 的瑞利商。它的最大值等于该矩阵的最大特征值，且在对应的特征向量处取到。而 $\mathbf{S}_w^{-1/2}\mathbf{S}_b\mathbf{S}_w^{-1/2}$ 与 $\mathbf{S}_w^{-1}\mathbf{S}_b$ 是相似的（相差一个 $\mathbf{S}_w^{1/2}$ 的共轭变换），特征值相同。于是最大特征值对应的 $\mathbf{w}$ 就是 $\mathbf{S}_w^{-1}\mathbf{S}_b$ 的主特征向量，与 (7) 一致。

两条路的区别

求导那条路算出「驻点」，瑞利商这条路证明「这是全局最大点」。前者是必要条件，后者才是充分性。考试写前者通常够，但若被问「为什么不是最小点」，得靠后者——瑞利商在特征向量处取到最大值 $\lambda_{\max}$，而且除重根外取到的方式唯一（差一个正标量）。

2.5　例题：把数代进去

用表 1 的数据走一遍。两类均值

$$\bar{\mathbf{x}}_1 = \begin{pmatrix} 4.56 \\ 1.38 \end{pmatrix}, \qquad \bar{\mathbf{x}}_2 = \begin{pmatrix} 5.90 \\ 2.14 \end{pmatrix}, \qquad \bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 = \begin{pmatrix} -1.34 \\ -0.76 \end{pmatrix}. \tag{9}$$

类内散布矩阵（每个样本先减去本类均值，再算平方和）：

$$\mathbf{S}_w = \begin{pmatrix} 0.932 & 0.086 \\ 0.086 & 0.400 \end{pmatrix}, \qquad \det \mathbf{S}_w = 0.932 \times 0.400 - 0.086^2 = 0.3654. \tag{10}$$

求逆：

$$\mathbf{S}_w^{-1} = \frac{1}{0.3654}\begin{pmatrix} 0.400 & -0.086 \\ -0.086 & 0.932 \end{pmatrix} = \begin{pmatrix} 1.095 & -0.235 \\ -0.235 & 2.551 \end{pmatrix}. \tag{11}$$

注意对角元的巨大差异：2.551 是 1.095 的两倍多。这不是笔误——花瓣宽的类内方差（0.400）只有花瓣长（0.932）的四成，取逆之后，宽度的权重被放大了。

于是

$$\mathbf{S}_w^{-1}(\bar{\mathbf{x}}_2 - \bar{\mathbf{x}}_1) = \begin{pmatrix} 1.095 & -0.235 \\ -0.235 & 2.551 \end{pmatrix}\begin{pmatrix} 1.34 \\ 0.76 \end{pmatrix} = \begin{pmatrix} 1.288 \\ 1.623 \end{pmatrix}, \tag{12}$$

归一化得 $\hat{\mathbf{w}} = (0.622,\, 0.783)^{\top}$，与横轴夹角 51.6°。

类 1 的 $z = \mathbf{w}^{\top}\mathbf{x}$	3.96	3.41	4.44	3.61	4.16
类 2 的 $z = \mathbf{w}^{\top}\mathbf{x}$	5.31	5.30	5.40	5.35	5.36

两类得分区间 $[3.41, 4.44]$ 与 $[5.30, 5.40]$ 之间空了 0.86，把阈值放在中点 $z_0 = 4.63$，十个样本全部分对。此时 Fisher 准则的值为

$$J(\hat{\mathbf{w}}) = \frac{(\hat{\mathbf{w}}^{\top}(\bar{\mathbf{x}}_2 - \bar{\mathbf{x}}_1))^2}{\hat{\mathbf{w}}^{\top}\mathbf{S}_w\hat{\mathbf{w}}} = 7.40. \tag{13}$$

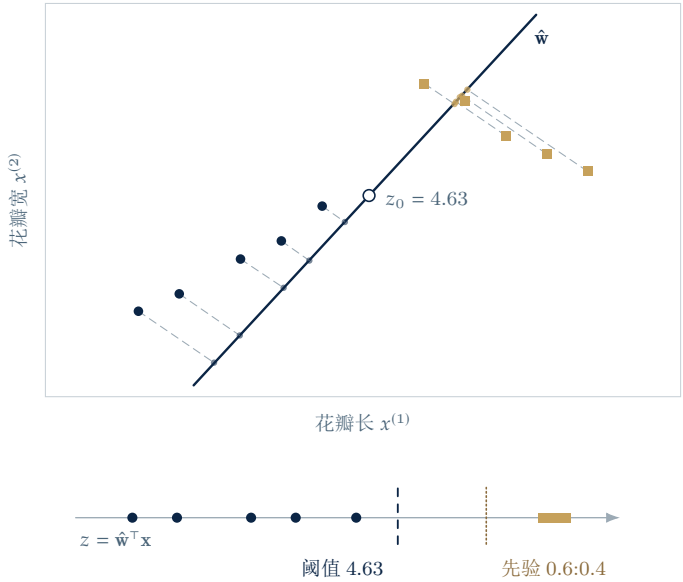


图 2　把二维压到一维。（上）两类样本与 Fisher 方向，细虚线是到投影轴的垂线，淡色圆点是落点。（下）投影后的得分轴：两类分别聚在 $[3.4, 4.4]$ 与 $[5.3, 5.4]$，中间空出一条 ≈ 0.86 的间隔。金色点线是先把类 1 的先验提高到 0.6 后的阈值（5.04）——它右移了 $\log(0.6/0.4) \approx 0.41$。

图 2 把整个流程画了出来。有两件事值得盯着看：

第一，判别线不是连接两类中心的那条线。中心连线与横轴夹 29.6°，判别线与横轴夹 51.6°，差了 22°。

第二，投影落点在下方的得分轴上并不对称——类 1 摊得开（3.41 到 4.44），类 2 挤成一团（5.30 到 5.40）。这是因为类 2 的样本在宽度上格外一致，投影后自然紧凑。

2.6　为什么不是中心连线

这是本节最值得停下来想的地方。直觉说：要分开两团，应该沿两团中心连线的方向看。为什么最优方向偏了 22°？

先说结论：因为**沿中心连线方向看，类内的散布可能很大**。决定「分不分得开」的不是两类中心隔多远，而是**隔得远，相对于类内有多散**。这正是 J 的分子分母之比在说的事。

用本讲的数算一下。三个候选方向的 J 值：

方向	类间 $\mathbf{w}^\top \mathbf{S}_b \mathbf{w}$	类内 $\mathbf{w}^\top \mathbf{S}_w \mathbf{w}$	J
沿横轴 $(1,0)$	4.49	0.932	4.82
沿中心连线（29.6°）	5.93	0.876	6.77
沿 Fisher 方向（51.6°）	5.10	0.689	7.40

中心连线把类间散度做到了最大（5.93），可它的类内散度也大（0.876）；Fisher 方向只放弃了一成半的类间散度（5.10），却把类内散度压到 0.689。比值上后者胜出。

补充　|　$\mathbf{S}_w^{-1}$ 到底在做什么

一句话：**它先把空间「拉直」，使每个方向上的类内散布都变成 1，再在拉直后的空间里找两类中心的方向。**

具体地，若 $\mathbf{S}_w$ 正定，令 $\mathbf{u} = \mathbf{S}_w^{-1/2}\mathbf{x}$（白化变换），则 $\mathbf{u}$ 的类内协方差是单位阵，此时 Fisher 准则退化为

$$J = \frac{\big(\mathbf{w}^\top(\bar{\mathbf{x}}_2 - \bar{\mathbf{x}}_1)\big)^2}{\mathbf{w}^\top \mathbf{S}_w \mathbf{w}} \xrightarrow[\mathbf{u}=\mathbf{S}_w^{1/2}\mathbf{w}]{} \frac{(\mathbf{u}^\top(\bar{\mathbf{u}}_2 - \bar{\mathbf{u}}_1))^2}{\|\mathbf{u}\|^2}, \tag{14}$$

这正是「$\mathbf{u}$ 与两类中心差同向」时最大，即 $\mathbf{u} \propto \bar{\mathbf{u}}_2 - \bar{\mathbf{u}}_1$，也就是 $\mathbf{w} \propto \mathbf{S}_w^{-1}(\bar{\mathbf{x}}_2 - \bar{\mathbf{x}}_1)$。

所以 (7) 里的 $\mathbf{S}_w^{-1}$ 不是代数技巧，而是**换了一副眼镜**：在白化后的空间里，「沿中心连线」重新变成了最优策略。图 3 画的就是这副眼镜。

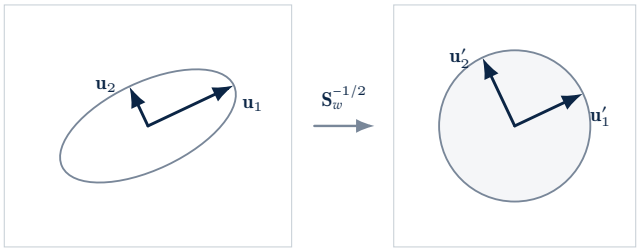


图 3　白化变换的几何意义。左图的两条箭头是椭圆的两条主轴（$\mathbf{S}_w$ 的特征向量方向，长度为其标准差），右图是它们被 $\mathbf{S}_w^{-1/2}$ 作用后的样子：椭圆成了单位圆，任何方向的类内散布都是 1。此时「沿两类中心连线」才真的是最优选择，因为所有方向的「噪声」已经一样大了。

2.7　阈值切在哪里

方向定了，还差一个偏移。若两类先验相同、且类内散布相同（LDA 的假设），最自然的切法是两类的**中点**：

$$z_0 = \frac{\hat{\mathbf{w}}^\top \bar{\mathbf{x}}_1 + \hat{\mathbf{w}}^\top \bar{\mathbf{x}}_2}{2} \quad \Longleftrightarrow \quad \hat{\mathbf{w}}^\top \left(\mathbf{x} - \frac{\bar{\mathbf{x}}_1 + \bar{\mathbf{x}}_2}{2} \right) = 0. \tag{15}$$

几何上，这条边界是过中点、以 $\hat{\mathbf{w}}$ 为法向的超平面（二维时就是那条判别线的垂线）。

若先验不等，$\hat\phi_1 \neq \hat\phi_2$，边界要朝先验小的那一侧平移。§4 会推出完整的式子，这里先给结论：

$$z_0 = \frac{\hat{\mathbf{w}}^\top \bar{\mathbf{x}}_1 + \hat{\mathbf{w}}^\top \bar{\mathbf{x}}_2}{2} + \log \frac{\hat\phi_1}{\hat\phi_2}. \tag{16}$$

先验 $\hat\phi_1$ 越大，阈值越靠近类 2，判定越倾向于类 1。图 2 下方那条金色点线就是 $\hat\phi_1 : \hat\phi_2 = 0.6 : 0.4$ 的情形，右移了 $\log 1.5 \approx 0.41$。

> **注意　|　平移量带量纲**
>
> (16) 里的 $\log(\hat\phi_1/\hat\phi_2)$ 是纯数，而 z 的量纲由 $\mathbf{w}$ 的长度决定。所以这个式子只在 $\|\mathbf{w}\| = 1$（或 $\mathbf{w}$ 有固定约定）时成立。若把 $\mathbf{w}$ 放大十倍，阈值也要跟着放大十倍。这个坑在 §4.2 会以「尺度一致性」的名字再出现一次。

3　一组方向：二类到 K 类

3.1　一个方向不够用

二分类时，一维的投影轴上只有「左」和「右」两个侧，正好对应两个类。三个类就不行了：一条直线把平面分成两半，一刀最多切出一种「与其余不同」。要让三个类各归各位，至少需要两个方向——投影到二维，用两条直线围出一个扇形。

图 4 把这件事画了出来。上图是三个类在平面上的分布，实线是第一个判别方向 $\mathbf{w}_1$；下图是把所有点投影到 $\mathbf{w}_1$ 上之后的样子。类 2 被干净地推到了一端，可是类 1 与类 3 在中间纠缠在一起——它们在这条方向上的得分区间重叠了。

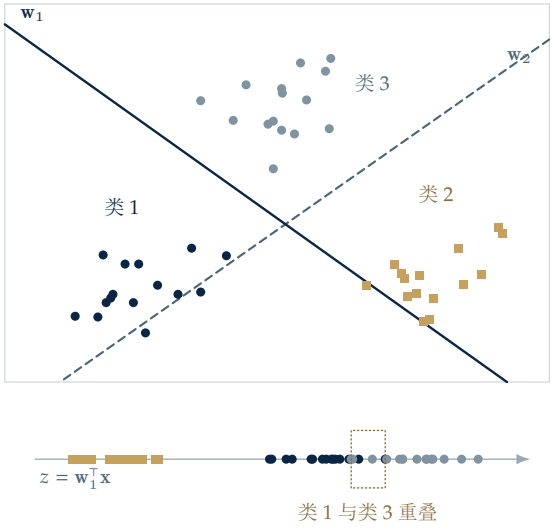


图 4　三个类，一个方向不够。上图中的两条线分别是第一、第二判别方向；下图是投影到 $\mathbf{w}_1$ 上的结果：类 2 被推到最左端，但类 1 与类 3 的得分区间（$[4.63, 5.09]$）重叠，无论阈值放在哪里都会判错一部分。把 $\mathbf{w}_2$ 也用上，投影到二维平面，三类才能被三条直线围出的区域分开。

于是问题变成：**要几个方向，分别取什么**？答案由两部分组成——散布矩阵（度量「挤」与「开」）和一个约束优化问题（求这组方向）。下一小节先把度量写下来。

3.2 三个散布矩阵

设样本 $(\mathbf{x}_i, y_i)$，$i = 1, \dots, N$，$\mathbf{x}_i \in \mathbb{R}^D$，$y_i \in \{1, \dots, K\}$。记第 c 类的样本数 N_c、类均值 $\bar{\mathbf{x}}_c$、总均值 $\bar{\mathbf{x}}$：

$$N_c = \#\{i : y_i = c\}, \qquad \bar{\mathbf{x}}_c = \frac{1}{N_c} \sum_{i:y_i=c} \mathbf{x}_i, \qquad \bar{\mathbf{x}} = \frac{1}{N} \sum_{c=1}^{K} N_c \bar{\mathbf{x}}_c. \tag{17}$$

三个散布矩阵（scatter matrix）定义为

$$\mathbf{S}_w = \sum_{c=1}^{K} \sum_{i:y_i=c} (\mathbf{x}_i - \bar{\mathbf{x}}_c)(\mathbf{x}_i - \bar{\mathbf{x}}_c)^\top = \sum_{c=1}^{K} N_c \mathbf{S}_c, \qquad \mathbf{S}_c = \frac{1}{N_c} \sum_{i:y_i=c} (\mathbf{x}_i - \bar{\mathbf{x}}_c)(\mathbf{x}_i - \bar{\mathbf{x}}_c)^\top, \tag{18}$$

$$\mathbf{S}_b = \sum_{c=1}^{K} N_c (\bar{\mathbf{x}}_c - \bar{\mathbf{x}})(\bar{\mathbf{x}}_c - \bar{\mathbf{x}})^\top, \tag{19}$$

$$\mathbf{S}_t = \sum_{i=1}^{N} (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top. \tag{20}$$

名字里的 w、b、t 分别是 within（类内）、between（类间）、total（总）。它们都是「未归一化的平方和」，不带 $1/N$ 或 $1/(N-1)$，所以单位是「特征的平方乘样本数」。

> **定理 3.1** | **勾股分解**
>
> $$\mathbf{S}_t = \mathbf{S}_w + \mathbf{S}_b. \tag{21}$$

证明. 把每个样本相对总均值的偏差拆成「相对本类均值」加「本类均值相对总均值」：$\mathbf{x}_i - \bar{\mathbf{x}} = (\mathbf{x}_i - \bar{\mathbf{x}}_c) + (\bar{\mathbf{x}}_c - \bar{\mathbf{x}})$。对第 c 类求和，

$$\begin{aligned} \sum_{i:y_i=c} (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top &= \sum_{i:y_i=c} \big[(\mathbf{x}_i - \bar{\mathbf{x}}_c) + (\bar{\mathbf{x}}_c - \bar{\mathbf{x}})\big]\big[(\mathbf{x}_i - \bar{\mathbf{x}}_c) + (\bar{\mathbf{x}}_c - \bar{\mathbf{x}})\big]^\top \\ &= \sum_{i:y_i=c} (\mathbf{x}_i - \bar{\mathbf{x}}_c)(\mathbf{x}_i - \bar{\mathbf{x}}_c)^\top + N_c (\bar{\mathbf{x}}_c - \bar{\mathbf{x}})(\bar{\mathbf{x}}_c - \bar{\mathbf{x}})^\top. \end{aligned} \tag{22}$$

两个交叉项都含因子 $\sum_{i:y_i=c} (\mathbf{x}_i - \bar{\mathbf{x}}_c) = \mathbf{0}$（类内偏差之和为零），故消失。对 c 求和即得 (21)。 □

这个分解和方差分析里的「总平方和 = 组内 + 组间」是同一件事。它意味着：**总散布固定时，类内越小，类间就必然越大**——两个目标其实是同一个目标的两种说法。

补充　|　为什么必须带 N_c 权重

若图省事写成等权的 $\tilde{\mathbf{S}}_b = \sum_c (\bar{\mathbf{x}}_c - \bar{\mathbf{x}})(\bar{\mathbf{x}}_c - \bar{\mathbf{x}})^\top$，会有两个后果。其一，分解 (21) 不成立，后面「类内小等价于类间大」的说法就没了依据。其二，样本多的类与样本少的类被赋予了同样的发言权，方向会被小类拖走。本讲的数值校验里，等权与加权得到的首方向相差约 5°，看似不多，但边界会明显偏移。

二分类时两种写法只差一个常数：代入 $\bar{\mathbf{x}} = (N_1\bar{\mathbf{x}}_1 + N_2\bar{\mathbf{x}}_2)/N$ 可算出

$$\mathbf{S}_b = \frac{N_1 N_2}{N}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)^\top, \tag{23}$$

因为 J 是比值，同乘常数不影响最优方向。**多分类时不能省这个权重**。

3.3 目标函数：为什么不能照抄迹比

二分类的准则 (4) 是关于标量的比值。多分类时投影到 d 维，类内、类间散布变成 $d\times d$ 矩阵 $\mathbf{W}^\top\mathbf{S}_w\mathbf{W}$ 与 $\mathbf{W}^\top\mathbf{S}_b\mathbf{W}$，两个矩阵之间没有现成的「比值」。最直觉的写法是把标量换成迹：

$$\max_{\mathbf{W}} \frac{\operatorname{tr}(\mathbf{W}^\top\mathbf{S}_b\mathbf{W})}{\operatorname{tr}(\mathbf{W}^\top\mathbf{S}_w\mathbf{W})} \qquad \text{（错）} \tag{24}$$

这个写法是错的，而且错得很隐蔽——它在 $d = 1$ 时完全正确，一到 $d \ge 2$ 就退化。

命题 3.1　|　迹比问题没有最大值

设 $\lambda_1 \ge \lambda_2 \ge \cdots$ 为 $\mathbf{S}_w^{-1}\mathbf{S}_b$ 的广义特征值。则 (24) 的上确界为 λ_1，但取不到：任何 $d \ge 2$ 的 $\mathbf{W}$ 都只会实际用到第一个方向。

证明. 把 $\mathbf{W}$ 的两列记作 $\mathbf{w}_1, \mathbf{w}_2$，并令 $\mathbf{w}_2' = \varepsilon\mathbf{w}_2$。迹是可加的：

$$\frac{\mathbf{w}_1^\top\mathbf{S}_b\mathbf{w}_1 + \varepsilon^2\mathbf{w}_2^\top\mathbf{S}_b\mathbf{w}_2}{\mathbf{w}_1^\top\mathbf{S}_w\mathbf{w}_1 + \varepsilon^2\mathbf{w}_2^\top\mathbf{S}_w\mathbf{w}_2} \xrightarrow[\varepsilon\to 0]{} \frac{\mathbf{w}_1^\top\mathbf{S}_b\mathbf{w}_1}{\mathbf{w}_1^\top\mathbf{S}_w\mathbf{w}_1} \le \lambda_1. \tag{25}$$

取 $\mathbf{w}_1$ 为最优方向、ε 足够小，比值可以任意接近 λ_1。可是只要 $\varepsilon > 0$，第二列就贡献了一点分母却几乎不贡献分子，比值严格小于 λ_1。所以上确界是 λ_1 而非最大值——所谓「最优解」会把后几列压成零，第二维形同虚设。 □

数值上也能看到：本讲 §6.3 的校验里，两万个随机 $\mathbf{S}_w$-正交的 $\mathbf{W}$ 中，迹的最大值是 14.15，而 $\sum_k \lambda_k = 17.41$；若按迹比排序，最优的永远是「一维解」。

正确的写法：加约束。既然比值不好办，就固定分母、最大化分子：

$$\hat{\mathbf{W}} = \arg\max_{\mathbf{W}} \ \operatorname{tr}(\mathbf{W}^\top\mathbf{S}_b\mathbf{W}) \qquad \text{s.t.} \quad \mathbf{W}^\top\mathbf{S}_w\mathbf{W} = \mathbf{I}_d. \tag{26}$$

约束的意思是：把每个方向都归一化到「类内方差为 1」，再让类间方差之和最大。这等价于最大化各方向 Fisher 比值之和，也等价于

$$\max_{\mathbf{W}} \ \operatorname{tr}\big[(\mathbf{W}^{\top}\mathbf{S}_w\mathbf{W})^{-1}(\mathbf{W}^{\top}\mathbf{S}_b\mathbf{W})\big] \qquad \text{或} \qquad \max_{\mathbf{W}} \ \frac{|\mathbf{W}^{\top}\mathbf{S}_b\mathbf{W}|}{|\mathbf{W}^{\top}\mathbf{S}_w\mathbf{W}|}. \tag{27}$$

三种写法等价，依据是下面这条引理。

> **命题 3.2** ｜ **尺度无关**
>
> 设 $\mathbf{A}\in\mathbb{R}^{d\times d}$ 可逆，$\mathbf{V}=\mathbf{W}\mathbf{A}$。则 $\mathbf{W}$ 与 $\mathbf{V}$ 在 (27) 中的目标值相同。

证明. $(\mathbf{V}^{\top}\mathbf{S}_w\mathbf{V})^{-1}(\mathbf{V}^{\top}\mathbf{S}_b\mathbf{V}) = \mathbf{A}^{-1}(\mathbf{W}^{\top}\mathbf{S}_w\mathbf{W})^{-1}(\mathbf{W}^{\top}\mathbf{S}_b\mathbf{W})\mathbf{A}$，迹在相似变换下不变；又对任意方阵 $\mathbf{S}$ 有 $|\mathbf{A}^{\top}\mathbf{S}\mathbf{A}| = |\mathbf{A}|^2|\mathbf{S}|$，行列式比中分子分母同乘 $|\mathbf{A}|^2$ 也不变。 □

这条引理说明：**目标只依赖 $\mathbf{W}$ 的列空间，与各列的长度、夹角无关**。这正是「LDA 只定方向、不定尺度」的正式表述。于是可以任取 $\mathbf{A}=(\mathbf{W}^{\top}\mathbf{S}_w\mathbf{W})^{-1/2}$ 把约束归一化成 $\mathbf{W}^{\top}\mathbf{S}_w\mathbf{W}=\mathbf{I}_d$，目标值不变——三种写法就此打通。

3.4 求解：广义特征值问题

对 (26) 写拉格朗日函数，$\mathbf{\Lambda}$ 是 $d\times d$ 的对称乘子矩阵：

$$\mathcal{L}(\mathbf{W},\mathbf{\Lambda}) = \operatorname{tr}(\mathbf{W}^{\top}\mathbf{S}_b\mathbf{W}) - \operatorname{tr}\big(\mathbf{\Lambda}^{\top}(\mathbf{W}^{\top}\mathbf{S}_w\mathbf{W}-\mathbf{I}_d)\big). \tag{28}$$

对 $\mathbf{W}$ 求导并令其为零（利用 $\mathbf{S}_b,\mathbf{S}_w$ 的对称性），得

$$2\mathbf{S}_b\mathbf{W} - 2\mathbf{S}_w\mathbf{W}\mathbf{\Lambda} = \mathbf{0} \quad\Longrightarrow\quad \mathbf{S}_b\mathbf{W} = \mathbf{S}_w\mathbf{W}\mathbf{\Lambda}. \tag{29}$$

也就是说，$\mathbf{W}$ 的每一列都满足

$$\mathbf{S}_b\mathbf{w}_k = \lambda_k\mathbf{S}_w\mathbf{w}_k \qquad\Longleftrightarrow\qquad \mathbf{S}_w^{-1}\mathbf{S}_b\mathbf{w}_k = \lambda_k\mathbf{w}_k \quad (\mathbf{S}_w \text{ 可逆时}). \tag{30}$$

按 $\lambda_1\ge\lambda_2\ge\cdots$ 排列，取前 d 个特征向量组成 $\mathbf{W}$，再归一化使 $\mathbf{W}^{\top}\mathbf{S}_w\mathbf{W}=\mathbf{I}_d$，此时同时有

$$\mathbf{W}^{\top}\mathbf{S}_b\mathbf{W} = \operatorname{diag}(\lambda_1,\dots,\lambda_d), \qquad \operatorname{tr}(\mathbf{W}^{\top}\mathbf{S}_b\mathbf{W}) = \sum_{k=1}^{d}\lambda_k. \tag{31}$$

> **补充** ｜ **为什么最大化迹就能逐列取**
>
> 这是 Rayleigh–Ritz 原理的标准结论：在 $\mathbf{S}_w$-正交约束下，第一个方向取 λ_1 对应的特征向量；把它固定后，在剩余子空间里重复同样的论证得到 λ_2；依此类推。每一步都是「在剩余子空间里做 $d=1$ 的问题」，而 $d=1$ 的最优性已由 (7) 或瑞利商保证。最终迹等于 $\sum_{k\le d}\lambda_k$，恰是约束下的上界，故为全局最优。

3.5 最多只能用 $K-1$ 维

定理 3.2 ｜ 维数上限

$\operatorname{rank}(\mathbf{S}_b) \le K-1$。因此 $\mathbf{S}_w^{-1}\mathbf{S}_b$ 至多有 $K-1$ 个非零特征值，投影维数取 $d = \min(K-1, D)$ 就已用尽全部判别信息。

证明. 记 $\boldsymbol{\delta}_c = \bar{\mathbf{x}}_c - \bar{\mathbf{x}}$，则 $\mathbf{S}_b = \sum_{c=1}^{K} N_c \boldsymbol{\delta}_c \boldsymbol{\delta}_c^{\top}$。而

$$\sum_{c=1}^{K} N_c \boldsymbol{\delta}_c = \sum_{c=1}^{K} N_c \bar{\mathbf{x}}_c - \Big(\sum_{c=1}^{K} N_c\Big)\bar{\mathbf{x}} = N\bar{\mathbf{x}} - N\bar{\mathbf{x}} = \mathbf{0}. \tag{32}$$

这说明 $\{\boldsymbol{\delta}_c\}_{c=1}^{K}$ 这 K 个向量之间存在一个非平凡的线性关系，故其中至多 $K-1$ 个线性无关。$\mathbf{S}_b$ 的列空间由它们张成，秩不超过 $K-1$。秩之外的方向上分子恒为零，对 J 毫无贡献，取之无益。 □

等号成立的条件是 K 个类中心不落在维数不超过 $K-2$ 的仿射子空间里。若两个类的中心恰好重合，秩还会更低——这时再怎么投影也分不开它们，因为在这个模型里它们本来就是同一个点。

补充 ｜ 这个上限和 $\mathbf{S}_w$ 的秩是两回事

$\mathbf{S}_b$ 的秩受限于类别数，$\mathbf{S}_w$ 的秩受限于样本数：$\operatorname{rank}(\mathbf{S}_w) \le N-K$（每类减去一个均值，损失 K 个自由度）。所以即使 K 很大，只要 $N-K<D$，$\mathbf{S}_w$ 就奇异，$\mathbf{S}_w^{-1}$ 不存在。两个上限要分开记：$K-1$ 管「能取几个方向」，$N-K$ 管「能不能算出来」。

4 判定：最近质心、判别函数与 GDA

投影只给出坐标，判类还需要规则。这一节先写出规则（三种等价的说法），再解释它为什么恰好长成这个线性样子——答案藏在一组概率假设里。

4.1 三种等价的说法

说法一：投影空间做欧氏最近质心。把 $\mathbf{x}$ 投到 $\mathbf{W}^{\top}\mathbf{x}$，再与各类投影后的均值 $\mathbf{W}^{\top}\bar{\mathbf{x}}_c$ 比距离：

$$\hat{y} = \arg\min_{c} \|\mathbf{W}^{\top}\mathbf{x} - \mathbf{W}^{\top}\bar{\mathbf{x}}_c\|^2. \tag{33}$$

说法二：原空间做马氏最近质心。

$$\hat{y} = \arg\min_{c} (\mathbf{x} - \bar{\mathbf{x}}_c)^{\top}\mathbf{S}_w^{-1}(\mathbf{x} - \bar{\mathbf{x}}_c). \tag{34}$$

命题 4.1　|　两种说法一致

当 $d = \operatorname{rank}(\mathbf{S}_b)$ 且 $\mathbf{W}$ 满足 $\mathbf{W}^\top \mathbf{S}_w \mathbf{W} = \mathbf{I}_d$ 时，(34) 与投影空间的最近质心判定给出完全相同的类别。

理由（一句话版）. 令 $\mathbf{u} = \mathbf{S}_w^{-1/2}\mathbf{x}$ 为白化坐标，则 $\mathbf{W}^\top\mathbf{x}$ 是 $\mathbf{u}$ 在某个 d 维子空间 V 上的正交投影，而 V 恰好张成所有白化类中心 $\mathbf{S}_w^{-1/2}\boldsymbol{\delta}_c$。于是 $\|\mathbf{u}-\bar{\mathbf{u}}_c\|^2 = \|P_V(\mathbf{u}-\bar{\mathbf{u}}_c)\|^2 + \|P_{V^\perp}(\mathbf{u}-\bar{\mathbf{u}}_c)\|^2$，第二项中 $\bar{\mathbf{u}}_c$ 在 V 内，其正交补分量对所有 c 都等于同一个向量 $P_{V^\perp}\mathbf{u}$，与 c 无关，argmin 不受影响。第一项正是投影空间的欧氏距离。 □

说法三：线性判别函数。 把 (34) 展开，丢掉与 c 无关的 $-\frac{1}{2}\mathbf{x}^\top\mathbf{S}_w^{-1}\mathbf{x}$，再加上先验项，得到

$$\boxed{\delta_c(\mathbf{x}) = \mathbf{x}^\top \mathbf{S}_w^{-1}\bar{\mathbf{x}}_c - \tfrac{1}{2}\bar{\mathbf{x}}_c^\top \mathbf{S}_w^{-1}\bar{\mathbf{x}}_c + \log\hat{\phi}_c} \qquad \hat{y} = \arg\max_c\ \delta_c(\mathbf{x}). \tag{35}$$

δ_c 对 $\mathbf{x}$ 是线性的（二次项被丢掉了），所以 **K 类 LDA 仍然是线性分类器**：任意两类的边界是超平面

$$\delta_c(\mathbf{x}) - \delta_{c'}(\mathbf{x}) = \left(\mathbf{x} - \frac{\bar{\mathbf{x}}_c + \bar{\mathbf{x}}_{c'}}{2}\right)^\top \mathbf{S}_w^{-1}(\bar{\mathbf{x}}_c - \bar{\mathbf{x}}_{c'}) + \log\frac{\hat{\phi}_c}{\hat{\phi}_{c'}} = 0. \tag{36}$$

其法向是 $\mathbf{S}_w^{-1}(\bar{\mathbf{x}}_c - \bar{\mathbf{x}}_{c'})$，与二分类的 $\mathbf{S}_w^{-1}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)$ 完全一致。等先验时边界过两中心连线的中点；先验不等则沿该法向平移。K 类的整体划分是若干超平面切出的凸区域。

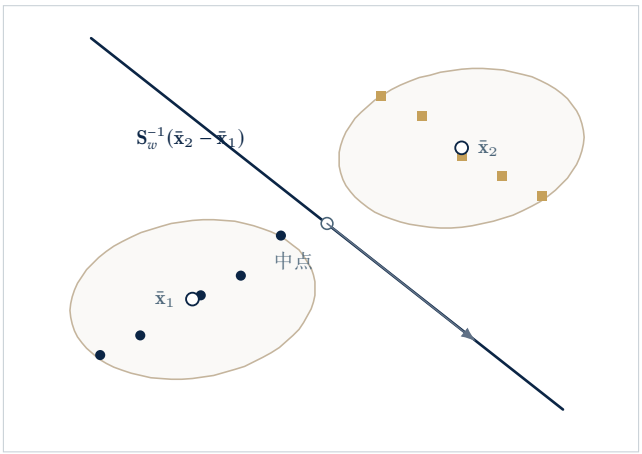


图 5　例题的解。两类各画了一个 2σ 等概率椭圆——它们形状完全相同、只是中心不同，这正是「共享协方差」假设的几何含义。实线是等先验下的边界：过中点、垂直于 $\mathbf{S}_w^{-1}(\bar{\mathbf{x}}_2 - \bar{\mathbf{x}}_1)$。注意边界并不垂直于两中心的连线，原因与 §2.6 相同。

4.2 尺度一致性

> **注意 | 改了 S_w 就要整体改**
>
> $\mathbf{S}_w$ 有两种常见约定：本讲的「平方和」与「除以 N 的平均」。前者数值是后者的 N 倍。若把 (35) 中的 $\mathbf{S}_w$ 换成 $\mathbf{S}_w/N$，第一项与第二项都会乘上 N，而 $\log\hat{\phi}_c$ 不会——先验项与判别项的相对权重就错了，判定结果会变。
>
> 要改约定就整体改：或者全部用平方和、先验项照写；或者全部用平均协方差、把先验项乘以 N（等价于把 δ_c 除以 N 后再加先验）。**不要只改一边。**

4.3 从贝叶斯公式到共享协方差

前面从「几何」出发：找方向、比散布。现在换一副眼镜，从「概率」出发：假设每一类长什么样，再用贝叶斯公式反推它属于谁。两条路会走到同一个地方——这不是巧合，而是 LDA 背后那个隐含假设的必然结果。

设类先验为 $p(y=c)=\phi_c$，类条件密度为 $p(\mathbf{x}\mid y=c)$。由贝叶斯公式，

$$p(y=c\mid\mathbf{x})=\frac{p(\mathbf{x}\mid y=c)\,\phi_c}{\sum_{c'=1}^{K}p(\mathbf{x}\mid y=c')\,\phi_{c'}}. \tag{37}$$

分母对所有 c 相同，所以「后验最大」等价于「分子最大」：

$$\hat{y}=\arg\max_{c}\,\big[\log p(\mathbf{x}\mid y=c)+\log\phi_c\big]. \tag{38}$$

这一步没有做任何假设。接下来才是关键：**假定 $p(\mathbf{x}\mid y=c)$ 是什么形状**。

假设每一类都是多元正态，且**所有类共用同一个协方差矩阵**：

$$\mathbf{x}\mid y=c\ \sim\ \mathcal{N}(\boldsymbol{\mu}_c,\boldsymbol{\Sigma}),\qquad p(\mathbf{x}\mid y=c)=\frac{1}{(2\pi)^{D/2}|\boldsymbol{\Sigma}|^{1/2}}\exp\Big[-\tfrac{1}{2}(\mathbf{x}-\boldsymbol{\mu}_c)^{\top}\boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu}_c)\Big]. \tag{39}$$

取对数：

$$\log p(\mathbf{x}\mid y=c)=-\tfrac{D}{2}\log(2\pi)-\tfrac{1}{2}\log|\boldsymbol{\Sigma}|-\tfrac{1}{2}(\mathbf{x}-\boldsymbol{\mu}_c)^{\top}\boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu}_c). \tag{40}$$

前两项与 c 无关，在 $\arg\max$ 里可以丢掉。把二次型展开：

$$(\mathbf{x}-\boldsymbol{\mu}_c)^{\top}\boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu}_c)=\mathbf{x}^{\top}\boldsymbol{\Sigma}^{-1}\mathbf{x}-2\mathbf{x}^{\top}\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_c+\boldsymbol{\mu}_c^{\top}\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_c, \tag{41}$$

其中 $\mathbf{x}^{\top}\boldsymbol{\Sigma}^{-1}\mathbf{x}$ 又与 c 无关，同样丢掉。剩下

$$\delta_c(\mathbf{x})=\mathbf{x}^{\top}\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_c-\tfrac{1}{2}\boldsymbol{\mu}_c^{\top}\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_c+\log\phi_c. \tag{42}$$

与 (35) 逐项对照

(42) 与多类 LDA 的判别函数 (35) 形状完全相同，只是 $\mathbf{S}_w^{-1}$ 换成了 $\boldsymbol{\Sigma}^{-1}$、$\bar{\mathbf{x}}_c$ 换成了 $\boldsymbol{\mu}_c$。而极大似然估计给出的正是

$$\hat{\boldsymbol{\mu}}_c = \bar{\mathbf{x}}_c, \qquad \hat{\boldsymbol{\Sigma}} = \frac{1}{N}\sum_{c=1}^{K}\sum_{i:y_i=c}(\mathbf{x}_i-\bar{\mathbf{x}}_c)(\mathbf{x}_i-\bar{\mathbf{x}}_c)^{\top} = \frac{1}{N}\mathbf{S}_w. \tag{43}$$

所以「**LDA 的方向**」与「**GDA 的方向**」**是同一条**，差别只在出发点：LDA 从类间/类内之比出发，GDA 从概率假设出发。

这里有个容易被忽略的细节：$\boldsymbol{\Sigma} = \mathbf{S}_w/N$ 意味着 (35) 里的 $\mathbf{S}_w$ 恰好是 $\boldsymbol{\Sigma}$ 的 N 倍。代入 (42) 会看到每一项都乘上 N——这正是 §4.2 那条警告的来源。**概率视角天然给出了正确的尺度**：协方差是「平均」的，散布矩阵是「求和」的，两者差一个 N。

补充　|　「共享协方差」到底假设了什么

它假设所有类的形状、大小、朝向都一样，只是位置不同。几何上，就是各类的等概率轮廓是同一族平移的椭圆（图 5 正是这样画的）。这个假设很强，但它换来了两个好处：判别函数对 $\mathbf{x}$ 线性，以及参数个数大幅减少——只需估 K 个均值加一个 $D\times D$ 的协方差，而不是 K 个协方差。

4.4 松开假设：QDA

如果把「共享」去掉，允许每一类有自己的 $\boldsymbol{\Sigma}_c$，那么 $\log|\boldsymbol{\Sigma}_c|$ 不再与 c 无关，二次项 $\mathbf{x}^{\top}\boldsymbol{\Sigma}_c^{-1}\mathbf{x}$ 也不再能丢：

$$\delta_c^{\mathrm{QDA}}(\mathbf{x}) = -\tfrac{1}{2}\log|\boldsymbol{\Sigma}_c| - \tfrac{1}{2}(\mathbf{x}-\boldsymbol{\mu}_c)^{\top}\boldsymbol{\Sigma}_c^{-1}(\mathbf{x}-\boldsymbol{\mu}_c) + \log\phi_c. \tag{44}$$

这就是**二次判别分析**（QDA）。边界由 $\delta_c = \delta_{c'}$ 给出，是两个二次型相等，一般是一条二次曲线（二维时可能是椭圆、双曲线或抛物线）。

QDA 更灵活，但需要估计 K 个协方差矩阵，参数个数从 $\frac{K(K-1)}{2}(D+1)$ 涨到 $\frac{K(K-1)}{2}\big(D+\frac{D(D+1)}{2}\big)$。样本少时估计方差大，反而不如 LDA。实践中常见的折中是「收缩」：用 $\boldsymbol{\Sigma}_c \leftarrow (1-\alpha)\boldsymbol{\Sigma}_c + \alpha\boldsymbol{\Sigma}$ 把类协方差往共享协方差拉，$\alpha\in[0,1]$ 是平滑强度。

4.5 生成式与判别式的分工

LDA 与逻辑回归常被拿来对比，因为两者的决策边界都是超平面，但走的路不同。

对比项	LDA（生成式）	逻辑回归（判别式）
建模对象	$p(\mathbf{x} \mid y=c)$ 与 ϕ_c	直接建模 $p(y \mid \mathbf{x})$
隐含假设	各类高斯、共享协方差	对数几率线性
参数个数	$(K-1)(D+1)$ 左右	$(K-1)(D+1)$
样本效率	假设成立时更好	假设不成立时更稳
典型失效	类别形状差异大、非高斯	边界非线性、交互项强

经验规律：**假设对时，生成式用更少样本达到更高精度；假设错时，判别式更抗造。**这条规律不是定理，但在大量实际问题上反复出现。

5　与 PCA 的分野：有监督的降维

5.1　同一份数据，两个方向

LDA 常与主成分分析（PCA）并提，因为两者都在做同一件事：找一个（组）方向，把高维数据压到低维。但它们的判据截然不同。

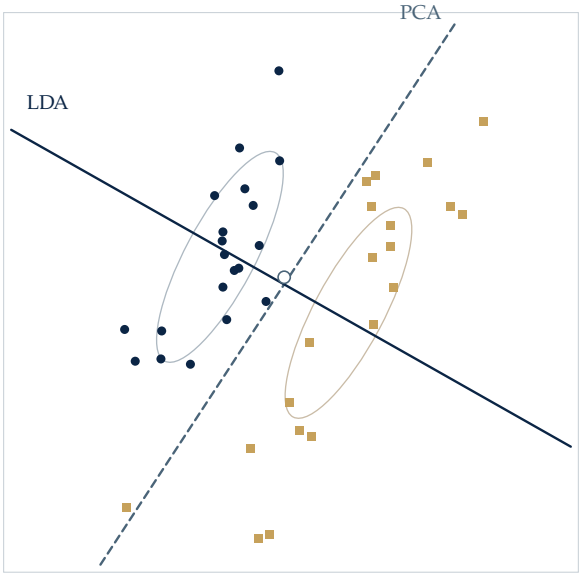


图 6　同一份数据上的两个方向。两团数据沿 62° 方向被拉长，所以 PCA 选了这条「方差最大」的方向；而两类的中心几乎在水平方向上错开，LDA 选了近似垂直于拉长方向的那条。两者夹角 86°，Fisher 准则的取值相差约 480 倍（0.010 对 4.78）。

图 6 是一个极端的例子，但它说明的问题很普遍：**方差大的方向不一定是有用的方向**。在这份数据上，PCA 把全部精力花在了「摊得最开」的方向，而这个方向上两类几乎完全重叠。

5.2 三个区别

	PCA	LDA
优化目标	投影后总方差最大，即 $\mathbf{W}^\top \mathbf{S}_t \mathbf{W}$ 的迹最大	投影后类间/类内之比最大，见 (26)
是否用标签	不用，无监督	用，有监督
维数上限	$\min(D, N)$	$\min(K-1, D)$
典型用途	压缩、去噪、可视化	分类前的降维、可视化
失效场景	判别信息藏在低方差方向	类内散布奇异、类别形状差异大

维数上限这一条值得单独说。PCA 最多能取到 D 维（受样本数限制），因为它对方向没有偏好；LDA 最多只有 $K-1$ 维，因为再多也没有判别信息可用（§3.5）。所以当 D 很大而 K 很小时，LDA 的降维是*本质性*的——它把 D 维压到 $K-1$ 维，而且这 $K-1$ 维包含了全部分类所需的信息。

> **补充 | 能不能先 PCA 再 LDA**
>
> 可以，而且在实际问题里很常见。当 D 很大（比如图像）导致 $\mathbf{S}_w$ 奇异时，先用 PCA 把维数降到 $D' < N-K$，再在 D' 维上做 LDA，是一种标准的补救手段（§6.5 第 2 条）。
>
> 但要清楚这样做的代价：PCA 阶段是无监督的，它可能已经把判别信息丢掉了。如果先验地知道判别信息集中在高方差方向，这个做法没问题；否则应优先考虑正则化的 LDA（给 $\mathbf{S}_w$ 加岭），而不是盲目先降维。

6 实现、校验与边界

6.1 五步算法

把前面的推导整理成可以直接实现的形式。输入是数据矩阵 $\mathbf{X} \in \mathbb{R}^{N\times D}$ 与标签 $\mathbf{y}$，输出是投影矩阵 $\mathbf{W}$、类均值、类先验。

Step 1. 算类统计量：N_c、$\bar{\mathbf{x}}_c$、$\bar{\mathbf{x}}$。

Step 2. 算两个散布矩阵：$\mathbf{S}_w = \sum_c \sum_{i:y_i=c} (\mathbf{x}_i - \bar{\mathbf{x}}_c)(\mathbf{x}_i - \bar{\mathbf{x}}_c)^\top$，$\mathbf{S}_b = \sum_c N_c (\bar{\mathbf{x}}_c - \bar{\mathbf{x}})(\bar{\mathbf{x}}_c - \bar{\mathbf{x}})^\top$。

Step 3. Cholesky 分解 $\mathbf{S}_w = \mathbf{L}\mathbf{L}^\top$（要求 $\mathbf{S}_w$ 正定）。

Step 4. 对称化：构造 $\mathbf{M} = \mathbf{L}^{-1}\mathbf{S}_b\mathbf{L}^{-\top}$，对它做 `eigh` 得特征值 λ_k 与特征向量 $\mathbf{v}_k$。

Step 5. 回代：$\mathbf{W} = \mathbf{L}^{-\top}[\mathbf{v}_1, \dots, \mathbf{v}_d]$，自动满足 $\mathbf{W}^\top \mathbf{S}_w \mathbf{W} = \mathbf{I}_d$。

第 4 步的 $\mathbf{M}$ 是实对称的（$\mathbf{S}_b$ 对称，$\mathbf{L}^{-1}$ 合同变换保持对称），所以可以用 `eigh` 而

不是 `eig`——前者返回实特征值、正交特征向量，且更稳定。

> **补充 | 为什么不直接对 $\mathrm{S}_w^{-1}\mathrm{S}_b$ 做特征分解**
>
> 因为它不对称。不对称矩阵的特征向量一般不正交，也不满足 $\mathbf{W}^{\top}\mathbf{S}_w\mathbf{W}=\mathbf{I}_d$；数值上还要求逆，$\mathbf{S}_w$ 接近奇异时误差会放大。白化之后问题变成一个对称矩阵的特征分解，既稳又快。

6.2 参考实现

下面这段代码只依赖 NumPy，二十行左右，可直接跑。

```
import numpy as np

def lda_fit(X, y, d=None):
    classes, yi = np.unique(y, return_inverse=True)
    K, D = len(classes), X.shape[1]
    Nc = np.bincount(yi, minlength=K).astype(float)
    means = np.stack([X[yi == c].mean(0) for c in range(K)])   # (K, D)
    xbar = Nc @ means / Nc.sum()
    Xc = X - means[yi]                          # center by own class mean
    Sw = Xc.T @ Xc                              # (D, D)
    dmu = means - xbar
    Sb = (dmu * Nc[:, None]).T @ dmu            # (D, D)
    L = np.linalg.cholesky(Sw)
    M = np.linalg.solve(L, Sb)
    M = np.linalg.solve(L, M.T).T               # L^-1 Sb L^-T
    ev, V = np.linalg.eigh((M + M.T) / 2)
    order = np.argsort(ev)[::-1]
    d = min(K - 1, D) if d is None else d
    W = np.linalg.solve(L.T, V[:, order[:d]])   # W' Sw W = I
    return W, ev[order[:d]], means, Nc / Nc.sum()

def lda_predict(X, W, means, prior):
    d2 = ((X[:, None, :] @ W - means @ W) ** 2).sum(-1)
    return np.argmin(d2 - 2 * np.log(prior), axis=1)
```

预测阶段只需要 $\mathbf{W}$、类均值与先验；若要算完整的判别函数 δ_c，还得保留 $\mathbf{S}_w$（或它的 Cholesky 因子）以构造线性系数 $\mathbf{S}_w^{-1}\bar{\mathbf{x}}_c$。

6.3 数值校验

光看代码跑通不算数，得逐条对上理论。表 2 是在 $K=4$、$D=10$、各类 60/40/30/50 个样本、共享协方差的数据上做的检查（NumPy 2.4.2，固定随机种子，$N=180$）。

表 2 LDA 实现的性质校验（固定种子，非泛化性能评估）

检查项	结果
$\mathbf{S}_w + \mathbf{S}_b = \mathbf{S}_t$ 的最大偏差	2.8×10^{-13}
$\operatorname{rank}(\mathbf{S}_b)$ / 非零广义特征值个数	$3 = K - 1$ / 恰 3 个
$\mathbf{W}^\top \mathbf{S}_w \mathbf{W} - \mathbf{I}_d$ 的最大元素	5.6×10^{-16}
$\mathbf{W}^\top \mathbf{S}_b \mathbf{W}$ 的非对角元最大绝对值	1.2×10^{-15}
$\sum_k \lambda_k$ 与 $\operatorname{tr}(\mathbf{W}^\top \mathbf{S}_b \mathbf{W})$	17.41 / 17.41
2 万个随机 $\mathbf{S}_w$-正交 $\mathbf{W}$ 的最大迹	14.15 < 17.41
2 万个随机方向的最大 J	8.46 < 9.90
投影最近质心 vs 马氏最近质心（$d = 3$）	180/180 一致
同上（$d = 2$）	177/180
同上（$d = 1$）	135/180
训练准确率（$d = 3$ / $d = 2$ / $d = 1$）	99.4% / 97.8% / 75.6%

前五行是恒等式，偏差都在机器精度量级，说明推导与实现一致。第六、七行是随机搜索的对照：在所有满足约束的 $\mathbf{W}$ 里随机采两万个，没有一个超过特征值解，这与「$\sum_k \lambda_k$ 是约束下的上界」吻合（但随机搜索本身不构成证明）。最后三行说明一件实践中的事：**把维数从 $K-1$ 砍到 1，准确率掉了二十多个百分点**——降维可视化好看，但不能拿它当完整 LDA 的决策依据。

6.4 复杂度

- 训练：算两个散布矩阵 $O(ND^2)$，Cholesky $O(D^3)$，对称特征分解 $O(D^3)$，总计 $O(ND^2 + D^3)$；空间 $O(D^2)$。
- 预测：单样本 $O(Dd)$（算 d 个投影坐标再比 K 个距离）；整批 $O(N_{\text{new}} K d)$。
- 若只要判别函数而不降维，预测是 $O(KD)$，与 d 无关。

当 D 远大于 N 时，$O(D^3)$ 会成为瓶颈，此时通常先做一次 PCA 或随机投影把 D 压下来——但要注意 §5 说的信息损失问题。

6.5 七条前提与失效场景

LDA 的公式很短，但它的前提不短。下面七条，按在实践里踩坑的频率排序。

1. 共享协方差。 $\mathbf{S}_w$ 把所有类的协方差揉成一份，等价于假设各类「同形同尺度」。若各类差异大（比如某一类特别松散），这份平均会被大类或大散布类主导，方向偏向它。

诊断：逐类看 $|\mathbf{S}_c|$ 与 $\operatorname{tr}(\mathbf{S}_c)$ 的量级。*处理*：改用 QDA，或先对每类白化再合并，或用收缩估计把 $\mathbf{S}_c$ 往 $\mathbf{S}_w$ 拉。

2. S_w 奇异。$\mathbf{S}_w$ 的秩至多 $N-K$。当 $N-K<D$（小样本高维）或特征强共线时，$\mathbf{S}_w$ 不满秩，Cholesky 直接失败、$\mathbf{S}_w^{-1}$ 不存在。

处理：加岭 $\mathbf{S}_w \leftarrow \mathbf{S}_w+\lambda\mathbf{I}$（$\lambda>0$ 是正则强度，与特征值记号无关），或先用 PCA 降到 $D'<N-K$ 维。$\lambda\to\infty$ 时 $\mathbf{S}_w+\lambda\mathbf{I}\approx\lambda\mathbf{I}$，方向退化成 $\mathbf{S}_b$ 的主特征向量——也就是「只看类中心差的 PCA」。

3. 对特征尺度敏感。$\mathbf{S}_w$ 与 $\mathbf{S}_b$ 都按原始单位计算，量纲大的特征会主导特征值。把「米」换成「毫米」，判别方向就会变。

处理：先标准化。但标准化参数只能来自训练集——这条与上一讲的「泄漏」是同一个问题。

4. 对离群点敏感。均值与协方差都是非鲁棒统计量，一个离群点就能显著改变 $\mathbf{S}_b$ 与 $\mathbf{S}_w$。

处理：稳健标准化（用中位数与四分位距代替均值与标准差），或先剔除可疑点，或改用基于秩的方法。

5. 类别不平衡。$\mathbf{S}_b$ 里的 N_c 让大类主导方向，$\mathbf{S}_w$ 亦然；先验项 $\log\hat{\phi}_c$ 又让大类更容易被选中。若关心宏平均或 F1 而非总体准确率，这套默认行为是错的。

处理：改用等权 $\mathbf{S}_b$ 与等先验，或对损失加权。

6. 数据泄漏。$\mathbf{S}_w$、$\mathbf{S}_b$、$\bar{\mathbf{x}}_c$ 都是训练集统计量。用全量数据估完再划分训练/测试，评估会虚高。

处理：把「估均值与散布」当成模型的一部分，放进交叉验证的每一折里。

7. 不要把它当非线性方法。类别边界由超平面切出。异或型数据、同心球型数据，LDA 必然失败——这与共享协方差的 GDA 失败的方式完全相同。

诊断：把数据投到前两个判别方向上画散点，若两类在二维平面上仍然犬牙交错，说明线性边界不够用。处理：加特征（平方项、交互项）、用核 LDA，或换非线性模型。

> **注意 | 一个常见误解**
>
> 「LDA 假设数据服从正态分布」这句话不完全对。LDA 的判别函数只需要各类的均值与共享协方差，不要求正态；正态假设是在推导「δ_c 是后验对数」时才用到的。换句话说，**即使数据不正态，$\hat{\mathbf{w}}\propto\mathbf{S}_w^{-1}(\bar{\mathbf{x}}_1-\bar{\mathbf{x}}_2)$ 仍是一个合理的方向**，只是它不再有「最优贝叶斯分类器」的解释。

7 小结

7.1 五句话

1. **LDA 就是一个方向加一个阈值。**方向由 $\mathbf{S}_w^{-1}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)$ 给出，阈值放在两类得分的中点（先验不等时平移）。
2. **这个方向不是中心连线。**$\mathbf{S}_w^{-1}$ 先把空间白化，让所有方向的类内散布都变成 1，再在白化空间里沿中心连线看——几何上等价，直觉上完全不同。
3. **多类时是一个广义特征值问题。**$\mathbf{S}_b\mathbf{W} = \mathbf{S}_w\mathbf{W}\mathbf{\Lambda}$，取前 d 个特征向量并归一化成 $\mathbf{W}^\top\mathbf{S}_w\mathbf{W} = \mathbf{I}_d$。
4. **最多 $K-1$ 维。**$\operatorname{rank}(\mathbf{S}_b) \le K-1$，因为类中心偏差的加权和为零。这个上限与 $\operatorname{rank}(\mathbf{S}_w) \le N-K$ 是两个独立的上限，管的事情不同。
5. **它与 GDA 是同一个模型。**$\mathbf{\Sigma} = \mathbf{S}_w/N$，共享协方差的高斯假设恰好生产出线性判别函数。松开共享假设就得到 QDA。

7.2 一张图

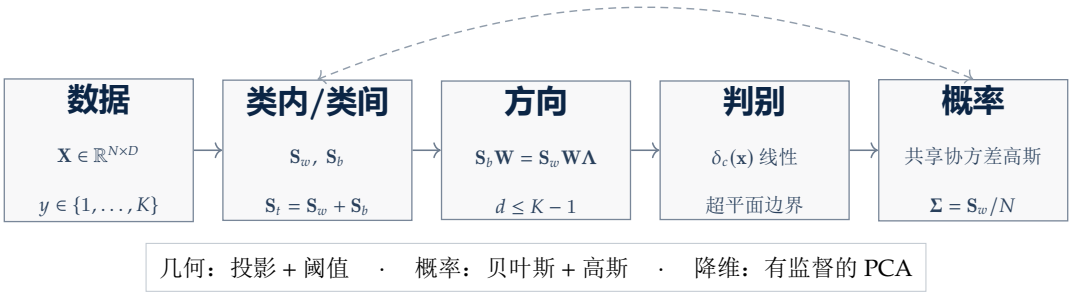


图 7 本讲的知识地图。横向是一条流水线：从数据到散布矩阵，到方向，到判别函数，最后到概率解释。中间那条弧线是本讲的主旨——几何与概率两条路，终点是同一个模型。

7.3 接下来

这一讲停在「线性边界」上。往下走有三条路：

- **换成概率输出。**LDA 只能给类别；若想要 $p(y=1 \mid \mathbf{x})$，就走向逻辑回归。它的边界仍是线性的，但不再假设类条件分布（§4.5）。
- **换成非线性边界。**QDA 是最省事的一步（二次曲面）；再往前是核方法——把 $\mathbf{x}$ 映射到高维，让线性边界在原空间里变成曲线。
- **换成「最大间隔」的视角。**支持向量机不问「类内多散」，只问「边界离最近的点有多远」。这是另一种完全不同的判据，但同样落在 $\mathbf{w}^\top\mathbf{x} + b$ 这个骨架上。

习题

A 组•基础

A1. 用表 1 的数据，手算 $\bar{\mathbf{x}}_1, \bar{\mathbf{x}}_2$ 与 $\mathbf{S}_w$，验证 $\det \mathbf{S}_w = 0.3654$。

A2. 接着上题，算出 $\mathbf{S}_w^{-1}(\bar{\mathbf{x}}_2 - \bar{\mathbf{x}}_1)$ 并归一化，验证它等于 $(0.622, 0.783)^\top$，与横轴夹角 $51.6°$。

A3. 计算十个样本的投影得分 $z = \hat{\mathbf{w}}^\top \mathbf{x}$，验证两类得分区间分别是 $[3.41, 4.44]$ 与 $[5.30, 5.40]$，并算出中点阈值。

A4. 对 A3 的数据，若先验改为 $\hat{\phi}_1 : \hat{\phi}_2 = 0.6 : 0.4$，阈值移到哪里？判定结果有没有变化？

A5. 验证 $\mathbf{S}_t = \mathbf{S}_w + \mathbf{S}_b$：用表 1 的数据算出三个 2×2 矩阵，逐元素核对。

B 组•提高

B1. 证明：只要 $\mathbf{S}_w$ 正定，$J(\mathbf{w})$ 在 $\mathbf{w} \propto \mathbf{S}_w^{-1}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)$ 处取到全局最大值，且最大值等于 $(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)^\top \mathbf{S}_w^{-1}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)$（二分类、$\mathbf{S}_b$ 用不带系数的写法）。

B2. 证明 $\mathbf{S}_b$ 的秩不超过 $K - 1$，并构造一个例子说明等号可以取到、也可以取不到。

B3. 证明：在约束 $\mathbf{W}^\top \mathbf{S}_w \mathbf{W} = \mathbf{I}_d$ 下，$\operatorname{tr}(\mathbf{W}^\top \mathbf{S}_b \mathbf{W}) \le \sum_{k=1}^{d} \lambda_k$，其中 λ_k 是 $\mathbf{S}_w^{-1}\mathbf{S}_b$ 的广义特征值（降序）。

B4. 设 $\mathbf{S}_w = \mathbf{I}$，$\mathbf{S}_b$ 如 (19)。写出此时的 $\hat{\mathbf{w}}$，并解释它与「最近质心分类器」的关系。

B5. 证明：若两类先验不等，则 (36) 给出的边界沿 $\mathbf{S}_w^{-1}(\bar{\mathbf{x}}_2 - \bar{\mathbf{x}}_1)$ 方向平移了 $\log(\hat{\phi}_1/\hat{\phi}_2)$ 除以 $\|\mathbf{S}_w^{-1}(\bar{\mathbf{x}}_2 - \bar{\mathbf{x}}_1)\|$ 的距离。

C 组•动手

C1. 实现 §6.2 的代码，在两类鸢尾数据上验证 $J(\hat{\mathbf{w}}) = 7.40$；再随机采 10^4 个单位方向，确认没有哪个方向的 J 更大。

C2. 生成 $K = 3$、$D = 2$、每类 50 个样本的三团高斯数据，做 LDA，把两个判别方向画在散点上，并把投影后的二维散点画在右侧。观察三类是否被分开。

C3. 在同一份数据上分别做 PCA 与 LDA，画出两个方向。构造一份数据使两者夹角超过 $60°$，并解释为什么。

C4. 取 $D = 200$、$N = 60$ 的高维小样本数据，直接调用 `np.linalg.cholesky` 会报错。

改用 $\mathbf{S}_w+\lambda\mathbf{I}$，画出 λ 从 10^{-4} 到 10^{2} 时首个判别方向与「$\mathbf{S}_b$ 主特征向量」的夹角变化。

提示

- **A1**：先算两类均值，再对每个样本减去本类均值，最后把十个外积相加。
- **A4**：阈值是 $\hat{\mathbf{w}}^\top\frac{\bar{\mathbf{x}}_1+\bar{\mathbf{x}}_2}{2}+\log\frac{0.6}{0.4}$，注意第二项是纯数，要加在 z 上。
- **B1**：用瑞利商，或直接用 Cauchy–Schwarz 不等式。
- **B2**：等号取到的例子：K 个类中心构成正单纯形；取不到的例子：两个类中心重合。
- **B3**：把 $\mathbf{W}$ 用 $\mathbf{S}_w$-标准正交基展开，逐项用 λ_k 放缩。
- **B5**：把 (36) 写成 $\mathbf{w}^\top(\mathbf{x}-\mathbf{x}_0)=0$ 的形式，读出 $\mathbf{x}_0$。
- **C4**：λ 很大时 $\mathbf{S}_w+\lambda\mathbf{I}\approx\lambda\mathbf{I}$，方向趋于 $\mathbf{S}_b$ 的主特征向量。

A 公式速查

A.1 多元正态与马氏距离

D 维正态密度

$$\mathcal{N}(\mathbf{x};\boldsymbol{\mu},\boldsymbol{\Sigma})=\frac{1}{(2\pi)^{D/2}|\boldsymbol{\Sigma}|^{1/2}}\exp\Big[-\tfrac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^\top\boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu})\Big]. \tag{45}$$

指数上那个二次型就是**马氏距离的平方**。它与欧氏距离的差别是「先把各方向按标准差归一化，再量距离」——这正是白化的作用。

A.2 三个常用的矩阵事实

(1) **合同变换保秩**：$\operatorname{rank}(\mathbf{AB})\le\min(\operatorname{rank}\mathbf{A},\operatorname{rank}\mathbf{B})$，故 $\operatorname{rank}(\mathbf{S}_b)=\operatorname{rank}(\sum_c N_c\boldsymbol{\delta}_c\boldsymbol{\delta}_c^\top)\le K-1$。

(2) **相似变换保特征值**：$\mathbf{AB}$ 与 $\mathbf{BA}$ 的非零特征值相同（$\mathbf{A}$ 可逆时完全相同）。这就是 $\mathbf{S}_w^{-1}\mathbf{S}_b$ 与 $\mathbf{S}_w^{-1/2}\mathbf{S}_b\mathbf{S}_w^{-1/2}$ 特征值一致的依据。

(3) **迹的循环性**：$\operatorname{tr}(\mathbf{AB})=\operatorname{tr}(\mathbf{BA})$。约束优化里把 $\operatorname{tr}(\boldsymbol{\Lambda}^\top\mathbf{W}^\top\mathbf{S}_w\mathbf{W})$ 整理成 $\operatorname{tr}(\mathbf{W}^\top\mathbf{S}_w\mathbf{W}\boldsymbol{\Lambda})$ 就靠它。

A.3 瑞利商

对实对称矩阵 $\mathbf{A}$，函数 $R(\mathbf{u})=\dfrac{\mathbf{u}^\top\mathbf{A}\mathbf{u}}{\mathbf{u}^\top\mathbf{u}}$ 的最大值等于 $\mathbf{A}$ 的最大特征值，在对应特征向量处取到；最小值对应最小特征值。这是 §2.4「第二条路」的全部依据。

A.4 记号对照

本讲	常见别名	说明
$\mathbf{S}_w$	S_w、within-class scatter	类内散布（平方和）
$\mathbf{S}_b$	S_B、between-class scatter	类间散布（带 N_c 权重）
$\mathbf{S}_t$	S_T、total scatter	总散布
$\delta_c(\mathbf{x})$	discriminant function	判别函数
$\boldsymbol{\Sigma}$	pooled covariance	共享协方差（$=\mathbf{S}_w/N$）

B 延伸阅读

[1] R. A. Fisher. The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, 7(2):179–188, 1936.

LDA 的原始文献，用的正是鸢尾花数据。文字古朴，思路清晰。

[2] C. M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.

第 4.1–4.3 节：判别函数、Fisher 判别、概率生成模型。图 4.6 与本讲图 2 是同一种画法。

[3] T. Hastie, R. Tibshirani, J. Friedman. *The Elements of Statistical Learning*, 2nd ed. Springer, 2009.

第 4.3 节：LDA 与 QDA 的比较、正则化判别分析。对「共享协方差」的讨论最清楚。

[4] K. Fukunaga. *Introduction to Statistical Pattern Recognition*, 2nd ed. Academic Press, 1990.

第 3 章：散布矩阵与特征提取的系统处理，含 $K-1$ 维上限的多种证明。

[5] 周志华. 《机器学习》. 清华大学出版社, 2016.

第 3.4 节：LDA 的广义特征值推导，中文表述最简洁的一本。

CyArk