机器学习基础 · 讲义系列

奇异值分解

从几何直觉到低秩近似

内容提要　奇异值分解（SVD）把任意一个矩阵拆成“旋转—拉伸—旋转”三步，把一个看似只能处理方阵的工具，推广到了所有矩阵。本讲义从单位圆的形变讲起，逐步给出 SVD 的定义、存在性证明、基本性质与低秩逼近的 Eckart–Young 定理，并把它与最小二乘、主成分分析、图像压缩、推荐系统联系起来。全文的数值例子都可以手工验算，代码示例基于 NumPy。

目　录

1　导读：为什么是奇异值分解　1

1.1　三个看似无关的问题　1

1.2　SVD 给出的统一答案　1

1.3　学习目标　2

1.4　记号约定　2

1.5　阅读建议　2

2　预备知识　3

2.1　内积、长度与正交　3

2.2　矩阵是一个线性映射　4

2.3　正交矩阵：只旋转，不拉伸　4

2.4　对称矩阵与谱定理　5

2.5　最关键的一块砖：$A^{\mathrm{T}}A$ 总是半正定的　6

3　几何直观：矩阵把圆变成了椭圆　6

3.1　一个 2×2 的例子　7

3.2　为什么一定是椭圆　8

3.3　三步分解：旋转—拉伸—旋转　8

3.4　退化情形：当椭圆被压扁　8

4　奇异值分解的定义　9

4.1　完整形式与约化形式　9

4.2　手算一个 3×2 的例子　11

4.3　外积形式：把矩阵拆成秩一矩阵之和　13

5　存在性：为什么 SVD 一定存在　14

5.1　证明路线图　14

5.2　第一步：$A^{\mathrm{T}}A$ 的特征分解　14

5.3　第二步：构造左奇异向量　15

5.4 第三步：补全并验证 15
5.5 秩、零空间与奇异值 16
5.6 唯一性：哪些东西是确定的 17

6 基本性质：范数、秩与条件数 17

6.1 奇异值与特征值的关系 17
6.2 三种矩阵范数 18
6.3 四个基本子空间 19
6.4 条件数与病态问题 20
6.5 行列式与迹 20

7 低秩逼近：Eckart–Young 定理 21

7.1 为什么追求低秩 21
7.2 定理的陈述 22
7.3 谱范数情形的证明 22
7.4 Frobenius 范数情形的证明 23
7.5 误差、能量与秩的选择 24
7.6 一个算例：图像压缩 25
7.7 低秩逼近的局限 26

8 伪逆与最小二乘 26

8.1 超定方程为什么常常无解 27
8.2 最小二乘的几何：把 b 投影到列空间 27
8.3 伪逆：把逆推广到所有矩阵 27
8.4 为什么不用正规方程 29
8.5 截断 SVD 与正则化 29

9 SVD 与主成分分析 30

9.1 PCA 想解决什么问题 30
9.2 第一步：中心化 31
9.3 第二步：对 X 做 SVD 31
9.4 第三步：解释方差与选择主成分个数 31
9.5 不中心化会发生什么 32

10 怎么算：从双对角化到随机化算法 **33**

10.1 为什么不能直接对 A 转置乘 A 求特征值 33

10.2 Golub–Kahan 双对角化 33

10.3 幂迭代：只要最大的那一个 34

10.4 随机化 SVD：用随机投影找列空间 34

10.5 该选哪条路线 35

11 应用案例 **36**

11.1 图像压缩 36

11.2 推荐系统：潜在因子模型 36

11.3 潜在语义分析 36

11.4 降噪与信号分离 37

11.5 其他值得一提的应用 37

12 十个常见误区 **38**

13 本章小结 **39**

13.1 一张表记住全部核心公式 40

13.2 三句话总结 40

13.3 与后续内容的连接 40

14 习题 **41**

1 导读：为什么是奇异值分解

如果在一门机器学习课里只允许你记住一种矩阵分解，那应该就是奇异值分解（Singular Value Decomposition，简称 SVD）。它几乎出现在所有需要“从大矩阵里提取主要结构”的地方：图像压缩、推荐系统、数据降维、文本主题分析、系统辨识、网络嵌入。更重要的是，它把线性代数里几个看似分散的概念——秩、范数、投影、最小二乘、条件数——串成了一条线。

本节先不谈定义，而是从三个具体问题出发，说明这些问题为什么最后都会指向同一个答案。

1.1 三个看似无关的问题

问题一：能不能用更少的数字存下一张照片？ 一张 512×512 的灰度照片，本质上是 $512\times512=262144$ 个灰度值。若每个值用 1 字节存储，需要 256 KB。可是照片里有大片平滑的天空、重复的砖墙纹理，真正“变化”的部分远少于像素个数。我们能不能只用两三万个数字把它存下来，而肉眼几乎看不出差别？

问题二：能不能猜出一个用户会给某部电影打几分？ 一个视频网站有一百万用户、五万部电影，评分矩阵有 5×10^{10} 个格子，而实际存在的评分不到 1%。剩下的 99% 是空的。如何从这 1% 里推断出其余的评分，从而做推荐？

问题三：能不能把 100 维的数据画在纸上？ 每个样本有 100 个特征，而人眼只能看二维平面。我们希望找两个方向，把数据投影上去，既让点尽量散开，又尽量保留原来样本之间的远近关系。

这三个问题表面上属于图像处理、推荐系统、数据可视化三个不同领域，但它们共享同一个数学结构：

- 数据（或矩阵）的规模很大，但**有效的自由度很小**；
- 我们希望用一个“简单”的对象去逼近它；
- 这里的“简单”，具体含义是**低秩**——能用少量秩一矩阵的叠加表示。

1.2 SVD 给出的统一答案

对任意一个 $m\times n$ 的实矩阵 A，SVD 把它写成

$$A = U\Sigma V^{\mathrm{T}} = \sum_{i=1}^{r}\sigma_i \boldsymbol{u}_i\boldsymbol{v}_i^{\mathrm{T}}, \tag{1}$$

其中 $r=\operatorname{rank}(A)$，$\sigma_1\ge\sigma_2\ge\cdots\ge\sigma_r>0$ 称为**奇异值**，$\boldsymbol{u}_i$ 与 $\boldsymbol{v}_i$ 分别是两两正交的单位向量。式 (1) 的右端是 r 个 **秩一矩阵**（一个列向量乘一个行向量）的加权和，权重就是奇异值。

这个式子同时回答了上面三个问题：

1. 如果只保留前 k 项，得到的矩阵 $A_k = \sum_{i=1}^{k} \sigma_i \boldsymbol{u}_i \boldsymbol{v}_i^{\mathrm{T}}$ 是所有秩不超过 k 的矩阵中，在平方误差意义下**最接近** A 的那一个（Eckart–Young 定理，见第 7 节）。图像压缩由此而来。
2. 奇异值的衰减速度刻画了矩阵的“有效秩”。若前 k 个奇异值就占了全部奇异值平方和的 99%，说明这个矩阵在信息上几乎是 k 秩的。推荐系统由此而来。
3. $\boldsymbol{u}_i$ 与 $\boldsymbol{v}_i$ 给出两套正交坐标，分别张成矩阵的列空间与行空间。数据降维由此而来。

一句话概括　SVD 把“任意矩阵”分解为“正交变换 → 沿坐标轴拉伸 → 正交变换”，拉伸的长度就是奇异值。所有关于矩阵“主要成分”的问题，本质上都是在问：哪些拉伸最长。

1.3 学习目标

读完这份讲义，你应当能够：

1. 说清 SVD 的几何含义，并能对 2×2、3×2 的小矩阵手工算出完整的 SVD；
2. 复述并理解存在性证明的思路：为什么 $A^{\mathrm{T}}A$ 的特征分解能构造出 A 的 SVD；
3. 掌握奇异值与秩、谱范数、Frobenius 范数、条件数之间的关系；
4. 陈述 Eckart–Young 定理，并理解“最佳低秩逼近”中“最佳”的确切含义；
5. 用 SVD 表示伪逆，说明它为什么比正规方程更适合求解最小二乘；
6. 说明 SVD 与主成分分析的关系，并指出“不中心化就做 SVD”会错在哪里；
7. 了解实际计算 SVD 的几条路线（双对角化、幂迭代、随机化算法），知道什么时候不该显式构造 $A^{\mathrm{T}}A$。

1.4 记号约定

本讲义尽量保持记号统一，见表 1。有一处冲突需要特别提醒：在 SVD 的语境里，σ_i 约定俗成地表示**奇异值**；而在统计学的语境里，σ^2 常表示方差。本讲义中，凡涉及方差一律写作 s^2 或 $\mathrm{Var}(\cdot)$，以免混淆。

1.5 阅读建议

第 2 节是预备知识，熟悉线性代数的读者可以快速扫过，但请务必确认自己能独立复述命题 2.6（$A^{\mathrm{T}}A$ 半正定）——它是整个存在性证明的支点。第 3 节给出几何图像，建议对照图 1 亲手画一遍。第 4 至第 6 节是核心内容。第 7 节之后进入应用，可以按兴趣选读，但第 12 节的常见误区建议所有人都看一遍。

每节末尾的“自检”问题不需要动笔，能在心里答上来就说明这一节过关了。

表 1: 主要记号

记号	含义	记号	含义
$A \in \mathbb{R}^{m\times n}$	m 行 n 列实矩阵	$\operatorname{rank}(A)$	矩阵的秩
A^{T}	转置	$\|A\|_2$	谱范数（最大奇异值）
$\boldsymbol{x} \in \mathbb{R}^n$	列向量	$\|A\|_F$	Frobenius 范数
$\langle \boldsymbol{x}, \boldsymbol{y}\rangle = \boldsymbol{x}^{\mathrm{T}}\boldsymbol{y}$	内积	$\|A\|_*$	核范数（奇异值之和）
$\|\boldsymbol{x}\|_2$	欧氏长度	$\kappa(A)$	条件数 σ_1/σ_r
I_n	n 阶单位阵	A^+	Moore–Penrose 伪逆
$\operatorname{diag}(d_1,\dots,d_n)$	对角矩阵	$\operatorname{span}\{\cdot\}$	张成的子空间

2 预备知识

SVD 的证明只用到四样东西：内积与长度、矩阵作为线性映射、正交矩阵、对称矩阵的谱定理。这一节把它们快速复习一遍，重点不在定义，而在那些后面会反复使用的性质。

2.1 内积、长度与正交

对 $\boldsymbol{x},\boldsymbol{y} \in \mathbb{R}^n$，定义内积 $\langle \boldsymbol{x}, \boldsymbol{y}\rangle = \boldsymbol{x}^{\mathrm{T}}\boldsymbol{y} = \sum_{i=1}^{n} x_i y_i$，由此诱导出长度 $\|\boldsymbol{x}\|_2 = \sqrt{\langle \boldsymbol{x}, \boldsymbol{x}\rangle}$。

> **命题 2.1** （Cauchy–Schwarz 不等式）
> 对任意 $\boldsymbol{x},\boldsymbol{y} \in \mathbb{R}^n$，有 $|\langle \boldsymbol{x}, \boldsymbol{y}\rangle| \le \|\boldsymbol{x}\|_2\|\boldsymbol{y}\|_2$，等号成立当且仅当 $\boldsymbol{x}$ 与 $\boldsymbol{y}$ 线性相关。

有了内积，就可以谈论夹角：$\cos\theta = \langle \boldsymbol{x}, \boldsymbol{y}\rangle/(\|\boldsymbol{x}\|_2\|\boldsymbol{y}\|_2)$。当 $\langle \boldsymbol{x}, \boldsymbol{y}\rangle = 0$ 时称 $\boldsymbol{x}$ 与 $\boldsymbol{y}$ **正交**，记作 $\boldsymbol{x} \perp \boldsymbol{y}$。正交最重要的推论是勾股定理的推广：

$$\boldsymbol{x} \perp \boldsymbol{y} \quad \Longrightarrow \quad \|\boldsymbol{x}+\boldsymbol{y}\|_2^2 = \|\boldsymbol{x}\|_2^2 + \|\boldsymbol{y}\|_2^2. \tag{2}$$

更一般地，若 $\boldsymbol{x}_1,\dots,\boldsymbol{x}_k$ 两两正交，则 $\|\sum_i \boldsymbol{x}_i\|_2^2 = \sum_i \|\boldsymbol{x}_i\|_2^2$。这个式子会在证明 SVD 的范数性质时反复出现——它把“向量和的长度”化成了“长度的平方和”，是正交性最实用的地方。

一组两两正交且长度均为 1 的向量称为**标准正交组**。n 个 n 维标准正交向量构成 $\mathbb{R}^n$ 的一组**标准正交基**。

命题 2.2 （正交展开）

若 $\boldsymbol{v}_1, \dots, \boldsymbol{v}_n$ 是 $\mathbb{R}^n$ 的标准正交基，则任意 $\boldsymbol{x} \in \mathbb{R}^n$ 可写成

$$\boldsymbol{x} = \sum_{i=1}^{n} \langle \boldsymbol{x}, \boldsymbol{v}_i \rangle \boldsymbol{v}_i, \qquad \text{且} \qquad \|\boldsymbol{x}\|_2^2 = \sum_{i=1}^{n} \langle \boldsymbol{x}, \boldsymbol{v}_i \rangle^2. \tag{3}$$

这条性质的含义是：在标准正交基下，“求坐标”只需要做内积，不需要解线性方程组。SVD 之所以好用，很大程度上是因为 U 和 V 的列都是标准正交的。

2.2 矩阵是一个线性映射

一个 $m \times n$ 矩阵 A 可以看作映射 $\mathbb{R}^n \to \mathbb{R}^m$，$\boldsymbol{x} \mapsto A\boldsymbol{x}$。这个映射是线性的：$A(\alpha \boldsymbol{x} + \beta \boldsymbol{y}) = \alpha A\boldsymbol{x} + \beta A\boldsymbol{y}$。

同一个乘积 $A\boldsymbol{x}$ 有两种读法，都很有用：

- **按列组合**：若 $A = [\mathbf{a}_1, \dots, \mathbf{a}_n]$，则 $A\boldsymbol{x} = \sum_{j=1}^{n} x_j \mathbf{a}_j$。即 $A\boldsymbol{x}$ 是 A 的各列以 x_j 为系数的线性组合。这说明 A 的**列空间** $\operatorname{col}(A) = \{A\boldsymbol{x} : \boldsymbol{x} \in \mathbb{R}^n\}$ 就是所有可能的输出构成的集合。
- **按行内积**：$A\boldsymbol{x}$ 的第 i 个分量等于 A 的第 i 行与 $\boldsymbol{x}$ 的内积。这把“矩阵作用”翻译成了“一组测量”。

矩阵乘法对应映射的复合：$(AB)\boldsymbol{x} = A(B\boldsymbol{x})$。因此“把 A 分解成几个简单矩阵的乘积”，等价于“把 A 所代表的变换拆成几个简单变换的接连作用”。这正是 SVD 的出发点。

2.3 正交矩阵：只旋转，不拉伸

定义 2.1 （正交矩阵）

方阵 $Q \in \mathbb{R}^{n \times n}$ 若满足 $Q^{\mathrm{T}}Q = QQ^{\mathrm{T}} = I_n$，则称为**正交矩阵**。

命题 2.3 （正交矩阵的等价刻画）

对 $Q \in \mathbb{R}^{n \times n}$，下列命题等价：

1. $Q^{\mathrm{T}}Q = I_n$；
2. Q 的列向量构成 $\mathbb{R}^n$ 的标准正交基；
3. 对任意 $\boldsymbol{x}$，$\|Q\boldsymbol{x}\|_2 = \|\boldsymbol{x}\|_2$（保长度）；
4. 对任意 $\boldsymbol{x}, \boldsymbol{y}$，$\langle Q\boldsymbol{x}, Q\boldsymbol{y} \rangle = \langle \boldsymbol{x}, \boldsymbol{y} \rangle$（保内积）。

证明. (1) $\Leftrightarrow$ (2)：$Q^{\mathrm{T}}Q$ 的第 (i,j) 元恰好是 Q 的第 i 列与第 j 列的内积，故 $Q^{\mathrm{T}}Q = I$ 等价于各列两两正交且长度为 1。

(1) $\Rightarrow$ (3)：$\|Q\boldsymbol{x}\|_2^2 = (Q\boldsymbol{x})^{\mathrm{T}}(Q\boldsymbol{x}) = \boldsymbol{x}^{\mathrm{T}}Q^{\mathrm{T}}Q\boldsymbol{x} = \boldsymbol{x}^{\mathrm{T}}\boldsymbol{x} = \|\boldsymbol{x}\|_2^2$。

(3) $\Rightarrow$ (4)：由极化恒等式 $\langle \boldsymbol{x}, \boldsymbol{y}\rangle = \frac{1}{4}(\|\boldsymbol{x}+\boldsymbol{y}\|^2 - \|\boldsymbol{x}-\boldsymbol{y}\|^2)$，保长度即保内积。

(4) $\Rightarrow$ (1)：取 $\boldsymbol{x} = \mathbf{e}_i, \boldsymbol{y} = \mathbf{e}_j$，得 Q 的列两两正交且单位长。 □

正交矩阵的行列式只能是 ± 1，因为 $\det(Q)^2 = \det(Q^{\mathrm{T}})\det(Q) = \det(I) = 1$。$\det Q = 1$ 时 Q 是**旋转**，$\det Q = -1$ 时是**旋转复合一次反射**。两者都不改变长度和夹角，区别只在“手性”是否翻转。

> **为什么正交变换这么重要** 正交变换是“刚性”的：它把球面映成球面，把正方体映成同样大小的正方体。在数值计算中，用正交矩阵做变换不会放大误差——这一点在第 8 节讨论数值稳定性时会再次用到。SVD 的全部“压缩”都发生在对角矩阵 Σ 上，而 U 和 V 只负责换个角度看问题。

2.4 对称矩阵与谱定理

定义 2.2 （对称矩阵）
若 $A^{\mathrm{T}} = A$，则称 A 为**对称矩阵**。

对称矩阵是线性代数里性质最好的一类矩阵。它们一定可以被正交对角化，这就是谱定理。

定理 2.4 （谱定理）
设 $A \in \mathbb{R}^{n\times n}$ 对称，则存在正交矩阵 Q 与实对角矩阵 $\Lambda = \mathrm{diag}(\lambda_1, \dots, \lambda_n)$，使得

$$A = Q\Lambda Q^{\mathrm{T}} = \sum_{i=1}^{n} \lambda_i \, \mathbf{q}_i \mathbf{q}_i^{\mathrm{T}}, \tag{4}$$

其中 $\mathbf{q}_i$ 是 Q 的第 i 列。换言之，对称矩阵的特征值全为实数，且可以取到 n 个两两正交的单位特征向量。

谱定理的证明超出本讲义范围（需要用到 Schur 分解或变分原理），但它的结论必须记牢：**对称矩阵在某个标准正交基下就是对角矩阵**。这正是 SVD 想要对一般矩阵做的事情——只可惜一般矩阵做不到，只能退而求其次，用两组不同的标准正交基（U 和 V）。

定义 2.3 （半正定）
对称矩阵 A 若对任意 $\boldsymbol{x}$ 都有 $\boldsymbol{x}^{\mathrm{T}}A\boldsymbol{x} \geq 0$，则称 A 为**半正定**的；若对任意 $\boldsymbol{x} \neq \mathbf{0}$ 都有 $\boldsymbol{x}^{\mathrm{T}}A\boldsymbol{x} > 0$，则称为**正定**的。

命题 2.5
对称矩阵 A 半正定，当且仅当它的所有特征值非负。

证明. 若 $A = Q\Lambda Q^{\mathrm{T}}$ 半正定，取 $\boldsymbol{x} = Q\mathbf{e}_i$，则 $\boldsymbol{x}^{\mathrm{T}}A\boldsymbol{x} = \mathbf{e}_i^{\mathrm{T}}\Lambda\mathbf{e}_i = \lambda_i \geq 0$。反之若所有 $\lambda_i \geq 0$，则对

任意 $\boldsymbol{x}$，令 $\boldsymbol{y} = Q^{\mathrm{T}}\boldsymbol{x}$，有 $\boldsymbol{x}^{\mathrm{T}}A\boldsymbol{x} = \boldsymbol{y}^{\mathrm{T}}\Lambda\boldsymbol{y} = \sum_i \lambda_i y_i^2 \geq 0$。 □

2.5 最关键的一块砖：$A^{\mathrm{T}}A$ 总是半正定的

> **命题 2.6**
> 对任意实矩阵 $A \in \mathbb{R}^{m\times n}$，矩阵 $A^{\mathrm{T}}A \in \mathbb{R}^{n\times n}$ 是对称半正定的，并且
>
> $$A^{\mathrm{T}}A\boldsymbol{x} = \boldsymbol{0} \quad \Longleftrightarrow \quad A\boldsymbol{x} = \boldsymbol{0}. \tag{5}$$
>
> 因此 $\operatorname{null}(A^{\mathrm{T}}A) = \operatorname{null}(A)$，从而 $\operatorname{rank}(A^{\mathrm{T}}A) = \operatorname{rank}(A)$。

证明. 对称性：$(A^{\mathrm{T}}A)^{\mathrm{T}} = A^{\mathrm{T}}(A^{\mathrm{T}})^{\mathrm{T}} = A^{\mathrm{T}}A$。

半正定：对任意 $\boldsymbol{x}$，有 $\boldsymbol{x}^{\mathrm{T}}(A^{\mathrm{T}}A)\boldsymbol{x} = (A\boldsymbol{x})^{\mathrm{T}}(A\boldsymbol{x}) = \|A\boldsymbol{x}\|_2^2 \geq 0$。

式 (5)：若 $A^{\mathrm{T}}A\boldsymbol{x} = \boldsymbol{0}$，两边左乘 $\boldsymbol{x}^{\mathrm{T}}$ 得 $\|A\boldsymbol{x}\|_2^2 = \boldsymbol{x}^{\mathrm{T}}A^{\mathrm{T}}A\boldsymbol{x} = 0$，故 $A\boldsymbol{x} = \boldsymbol{0}$；反方向显然。于是两个矩阵的零空间相同，由秩—零化度定理 $\operatorname{rank}(A) = n - \dim\operatorname{null}(A) = n - \dim\operatorname{null}(A^{\mathrm{T}}A) = \operatorname{rank}(A^{\mathrm{T}}A)$。 □

这块砖的用处 $A^{\mathrm{T}}A$ 对称半正定，所以它有 n 个非负实特征值，并且可以被正交对角化。把这 n 个特征值开平方，就得到 A 的奇异值；对应的特征向量就是 SVD 中的右奇异向量。换句话说，**SVD 的存在性，本质上就是谱定理作用在 $A^{\mathrm{T}}A$ 上的结果。**

一个容易忽略的细节 $A^{\mathrm{T}}A$ 与 AA^{T} 的特征值**非零部分**相同（都等于奇异值的平方），但它们的**阶数**可能不同：$A^{\mathrm{T}}A$ 是 n 阶，AA^{T} 是 m 阶。当 $m \neq n$ 时，较大的那一个必然多出若干个零特征值。这一点在第 6 节讨论秩时还会用到。

自检

1. 若 Q 正交，证明 Q^{T} 也正交，且 $Q^{-1} = Q^{\mathrm{T}}$。
2. 举一个 2×2 对称矩阵，它的两个特征值一正一负；再举一个半正定但不可逆的例子。
3. 不用谱定理，直接验证：若 $A^{\mathrm{T}}A\boldsymbol{x} = \lambda\boldsymbol{x}$ 且 $\boldsymbol{x} \neq \boldsymbol{0}$，则 $\lambda = \|A\boldsymbol{x}\|^2/\|\boldsymbol{x}\|^2 \geq 0$。

3 几何直观：矩阵把圆变成了椭圆

在给出严格定义之前，先建立一幅图像。这幅图像值得你记住很多年。

3.1 一个 2×2 的例子

取

$$A = \begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix}. \tag{6}$$

考虑单位圆 $S^1 = \{\boldsymbol{x} \in \mathbb{R}^2 : \|\boldsymbol{x}\|_2 = 1\}$ 在 A 作用下的像 $AS^1 = \{A\boldsymbol{x} : \|\boldsymbol{x}\| = 1\}$。直接算几个点：

$\boldsymbol{x}$	$(1,0)^{\mathrm{T}}$	$(0,1)^{\mathrm{T}}$	$\frac{1}{\sqrt{2}}(1,1)^{\mathrm{T}}$	$\frac{1}{\sqrt{2}}(1,-1)^{\mathrm{T}}$
$A\boldsymbol{x}$	$(3,4)^{\mathrm{T}}$	$(0,5)^{\mathrm{T}}$	$\frac{1}{\sqrt{2}}(3,9)^{\mathrm{T}}$	$\frac{1}{\sqrt{2}}(3,-1)^{\mathrm{T}}$
$\|A\boldsymbol{x}\|_2$	5	5	$\sqrt{45} \approx 6.708$	$\sqrt{5} \approx 2.236$

四个方向中，最长的是 $\sqrt{45}$，最短的是 $\sqrt{5}$。事实上可以证明（第 6 节），$\|A\boldsymbol{x}\|_2$ 在单位圆上的最大值就是 $\sqrt{45}$，最小值就是 $\sqrt{5}$，且分别在 $\boldsymbol{x} = \frac{1}{\sqrt{2}}(1,1)^{\mathrm{T}}$ 与 $\boldsymbol{x} = \frac{1}{\sqrt{2}}(1,-1)^{\mathrm{T}}$ 处取到。这两个方向就是椭圆的**主轴**。

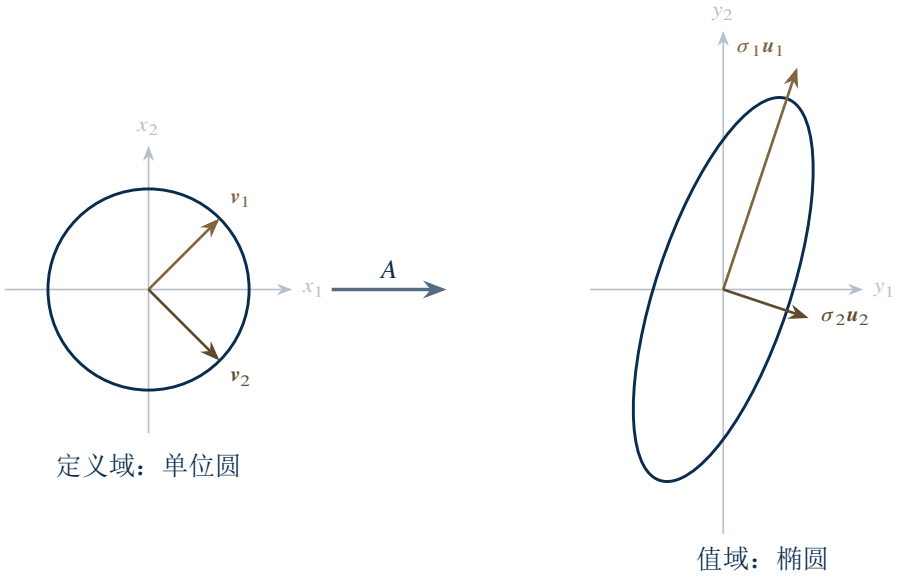


图 1: 2×2 矩阵把单位圆映成椭圆。椭圆的两条半轴长度分别是两个奇异值 $\sigma_1 = 3\sqrt{5} \approx 6.708$ 与 $\sigma_2 = \sqrt{5} \approx 2.236$，半轴方向分别是 $\boldsymbol{u}_1$ 与 $\boldsymbol{u}_2$。注意左右两图的比例尺不同：左图的圆半径与右图的短半轴在视觉上相近，只是为了排版方便。

图 1 揭示了一件重要的事：**任意可逆的 2×2 矩阵都把单位圆变成椭圆**（退化情形下变成线段）。椭圆的形状完全由两个半轴的长度和方向决定，而这两者正是我们要找的奇异值和奇异向量。

3.2 为什么一定是椭圆

这不是巧合。设 $\boldsymbol{x}$ 在单位圆上，$\boldsymbol{y} = A\boldsymbol{x}$。椭圆是“到两个定点距离之和为常数”的点集，但更直接的说法是：椭圆是单位圆在仿射变换下的像。任何满秩方阵都是可逆线性变换，它把圆映成椭圆；这个结论在 n 维下同样成立——单位球面被映成**椭球面**。

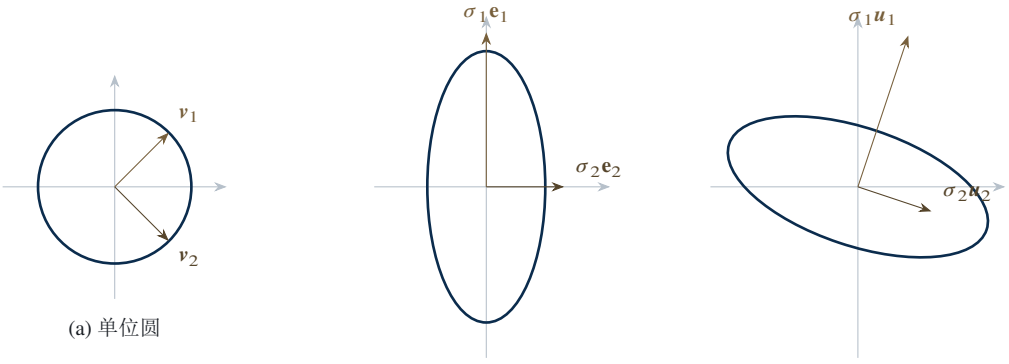
椭球的主轴长度，衡量了矩阵在不同方向上“拉伸”了多少。最大的拉伸倍数就是 $\|A\|_2$，最小的拉伸倍数（A 可逆时）就是 $1/\|A^{-1}\|_2$。二者的比值就是条件数。一台机器如果某个方向几乎被压扁（$\sigma_r \approx 0$），那么它在这个方向上就“几乎不可逆”，这也是病态问题的几何来源。

3.3 三步分解：旋转—拉伸—旋转

既然 A 把单位圆变成椭圆，我们就可以反过来，把 A 的作用拆成三步：先转一下，让椭圆的主轴对齐坐标轴；再沿坐标轴拉伸；最后转回去。这三步恰好对应

$$A = U\Sigma V^{\mathrm{T}}, \tag{7}$$

其中 V^{T} 与 U 是正交变换（旋转或反射），Σ 是对角矩阵（沿坐标轴拉伸）。



(a) 单位圆　(b) 沿坐标轴拉伸　(c) 整体旋转

图 2: SVD 的三步分解。V^{T} 先把 (a) 中的正交方向 $\boldsymbol{v}_1, \boldsymbol{v}_2$ 转到坐标轴方向 (b)；Σ 沿坐标轴分别拉伸 σ_1 与 σ_2 倍；U 再把整个椭球旋到 (c) 所示的最终朝向。图中为示意比例，未按 A 的真实奇异值 6.708 : 2.236 绘制。

> **一句话记住 SVD**　$A\boldsymbol{x} = (U\Sigma V^{\mathrm{T}})\boldsymbol{x}$ 的意思是：把 $\boldsymbol{x}$ 用 $\boldsymbol{v}_1, \dots, \boldsymbol{v}_n$ 这组正交坐标表示，沿每个坐标轴拉伸 σ_i 倍，再用 $\boldsymbol{u}_1, \dots, \boldsymbol{u}_m$ 这组正交坐标表示出来。V^{T} 负责“换到输入坐标系”，U 负责“换到输出坐标系”，Σ 负责“拉伸”。

3.4 退化情形：当椭圆被压扁

如果 $\sigma_2 = 0$，椭圆退化成一条线段，A 不可逆，$\mathrm{rank}(A) = 1$。此时 $\boldsymbol{v}_2$ 满足 $A\boldsymbol{v}_2 = \boldsymbol{0}$，即 $\boldsymbol{v}_2$ 落在 A 的零空间里。方向 $\boldsymbol{v}_2$ 上的一切信息都被压没了。

这不是病态，而是低秩矩阵的常态。图像、评分矩阵、文档—词频矩阵，它们的奇异值谱往往是“少数几个很大，其余迅速趋近于零”。第 7 节会说明，这正是低秩逼近能够奏效的原因。

自检

1. 对式 (6) 的 A，验证 $\|A\boldsymbol{x}\|_2$ 在 $\boldsymbol{v}_1 = \frac{1}{\sqrt{2}}(1,1)^{\mathrm{T}}$ 处取到最大值 $\sqrt{45}$。（提示：设 $\boldsymbol{x} = (\cos\theta, \sin\theta)^{\mathrm{T}}$，把 $\|A\boldsymbol{x}\|_2^2$ 写成 θ 的函数。）
2. 若 A 是正交矩阵，AS^1 是什么形状？它的奇异值是多少？
3. 若 A 把单位圆压成一条线段，$\det A$ 等于多少？

4 奇异值分解的定义

几何直觉已经给出了 SVD 的轮廓，这一节把它写成严格的定义，并用一个 3×2 的例子把每一步都算出来。

4.1 完整形式与约化形式

定义 4.1 （奇异值分解）

设 $A \in \mathbb{R}^{m\times n}$，$\operatorname{rank}(A) = r \geq 1$。若存在正交矩阵 $U \in \mathbb{R}^{m\times m}$、$V \in \mathbb{R}^{n\times n}$ 以及矩阵 $\Sigma \in \mathbb{R}^{m\times n}$，使得

$$A = U\Sigma V^{\mathrm{T}}, \tag{8}$$

其中 Σ 只有对角元 $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$ 非零、其余元素全为零，则称式 (8) 为 A 的**奇异值分解**（SVD）。

定义 4.2 （奇异值与奇异向量）

在上述分解中：

- $\sigma_1, \ldots, \sigma_r$ 称为 A 的**奇异值**（singular values）；
- U 的第 i 列 $\boldsymbol{u}_i$ 称为**左奇异向量**；
- V 的第 i 列 $\boldsymbol{v}_i$ 称为**右奇异向量**。

约定奇异值按降序排列，且只统计非零的那些，因此“r 个奇异值”指的就是 r 个正奇异值。

注 4.3 （关于 Σ 的形状）

当 $m \neq n$ 时，Σ 不是方阵，而是与 A 同型的长方形矩阵：当 $m > n$ 时，它是上面 n 行构成对角块、下面 $m-n$ 行全为零；当 $m < n$ 时，它是左边 m 列构成对角块、右边 $n-m$ 列全为零。矩阵 Σ 中零的个数远多于非零的个数——这正是 SVD 的“压缩”所在。

在实际使用中，完整形式往往显得臃肿：U 的后面 $m-r$ 列与 V 的后面 $n-r$ 列乘上零之后根本不起作用。于是有了下面两种更常用的写法。

定义 4.4 （约化 SVD 与截断 SVD）

沿用上面的记号，设 $U_r = [\boldsymbol{u}_1, \dots, \boldsymbol{u}_r]$，$V_r = [\boldsymbol{v}_1, \dots, \boldsymbol{v}_r]$，$\Sigma_r = \mathrm{diag}(\sigma_1, \dots, \sigma_r)$，则

$$A = U_r \Sigma_r V_r^{\mathrm{T}} \tag{9}$$

称为 A 的**约化 SVD**（thin SVD 或 economy SVD）。若只取前 $k < r$ 项，

$$A_k = U_k \Sigma_k V_k^{\mathrm{T}} = \sum_{i=1}^{k} \sigma_i \boldsymbol{u}_i \boldsymbol{v}_i^{\mathrm{T}} \tag{10}$$

则称为 A 的**截断 SVD**（truncated SVD），其中 $U_k = [\boldsymbol{u}_1, \dots, \boldsymbol{u}_k]$，$V_k = [\boldsymbol{v}_1, \dots, \boldsymbol{v}_k]$。

表 2: SVD 的三种写法

	完整 SVD	约化 SVD	截断 SVD
表达式	$A = U\Sigma V^{\mathrm{T}}$	$A = U_r\Sigma_r V_r^{\mathrm{T}}$	$A_k = U_k\Sigma_k V_k^{\mathrm{T}}$
U 的尺寸	$m \times m$	$m \times r$	$m \times k$
Σ 的尺寸	$m \times n$	$r \times r$	$k \times k$
V 的尺寸	$n \times n$	$n \times r$	$n \times k$
是否精确	是	是	否（除非 $k \geq r$）
主要用途	理论推导	计算、压缩存储	降维、去噪、逼近

从表 2 可以看出，约化 SVD 与完整 SVD 是同一个分解的不同“裁剪”，而截断 SVD 是有损的：它主动丢掉了后面 $r-k$ 个分量。第 7 节会说明，这种丢弃在所有可能的丢弃方式中是**最优**的。

4.2 手算一个 3×2 的例子

为了让定义落地，我们把下面这个矩阵从里到外算一遍：

$$A=\begin{pmatrix}1 & 0\\ 0 & 1\\ 1 & 1\end{pmatrix}\in\mathbb{R}^{3\times 2}. \tag{11}$$

U、Σ、V 三个矩阵全是未知量，直接解方程无从下手。通用的做法是 **先假设分解已经成立，倒推出它必须满足什么**，再把倒推出的条件当作计算步骤。

设 $A=U\Sigma V^{\mathrm{T}}$ 成立。两边右乘第 i 个右奇异向量 $\boldsymbol{v}_i$，利用 $V^{\mathrm{T}}\boldsymbol{v}_i=\mathbf{e}_i$：

$$A\boldsymbol{v}_i=U\Sigma\mathbf{e}_i=\sigma_i\boldsymbol{u}_i. \tag{12}$$

这是整件事的核心关系：A **把** $\boldsymbol{v}_i$ **映成** $\sigma_i\boldsymbol{u}_i$——方向不变，长度被拉伸 σ_i 倍。再在式 (12) 两边左乘 A^{T}，并代入 $A^{\mathrm{T}}=V\Sigma^{\mathrm{T}}U^{\mathrm{T}}$：

$$A^{\mathrm{T}}A\boldsymbol{v}_i=\sigma_iA^{\mathrm{T}}\boldsymbol{u}_i=\sigma_iV\Sigma^{\mathrm{T}}U^{\mathrm{T}}\boldsymbol{u}_i=\sigma_iV\Sigma^{\mathrm{T}}\mathbf{e}_i=\sigma_i^2\boldsymbol{v}_i. \tag{13}$$

这一步把 U 完全消掉，只剩下关于 A 本身的式子。

倒推出的三个必要条件　如果 $A=U\Sigma V^{\mathrm{T}}$ 真的成立，那么

$\boldsymbol{v}_i$ 必须是 $A^{\mathrm{T}}A$ 的特征向量——是 $A^{\mathrm{T}}A$，不是 A；

相应的特征值必须是 σ_i^2，即奇异值是特征值开平方；

$\boldsymbol{u}_i=A\boldsymbol{v}_i/\sigma_i$，由式 (12) 直接解出。

三个未知量于是都有了着落，剩下的只是按依赖顺序执行：算 $A^{\mathrm{T}}A$（第 1 步）→ 求特征值（第 2 步）与特征向量（第 3 步）→ 开平方得 σ_i（第 4 步）→ 回代得 $\boldsymbol{u}_i$（第 5 步）→ 补齐 U 剩下的一列（第 6 步）→ 验证（第 7 步）。

必须提醒：以上推出的只是**必要条件**。“若 SVD 存在，则 $\boldsymbol{v}_i$ 是特征向量”不能反过来说成“随便取一组特征向量就能拼出 SVD”。第 7 步的验证正是在补这个逻辑缺口，第 5 节的定理 5.3 则把它补得完全严格。

第一步：算 $A^{\mathrm{T}}A$。 为什么不直接对 A 求特征值？因为 A 是 3×2 的长方阵，特征值根本无从谈起——只有方阵才有特征值。而 $A^{\mathrm{T}}A$ 是 2×2 的对称半正定矩阵，由谱定理一定能正交对角化，这恰好是倒推结论 (1) 所需要的对象。

$$A^{\mathrm{T}}A=\begin{pmatrix}1 & 0 & 1\\ 0 & 1 & 1\end{pmatrix}\begin{pmatrix}1 & 0\\ 0 & 1\\ 1 & 1\end{pmatrix}=\begin{pmatrix}2 & 1\\ 1 & 2\end{pmatrix}. \tag{14}$$

第二步：求 $A^{\mathrm{T}}A$ 的特征值。 这些特征值就是 σ_i^2 的候选值。特征多项式为 $\det(A^{\mathrm{T}}A-\lambda I)=(2-\lambda)^2-1=(\lambda-1)(\lambda-3)$，故特征值为 $\lambda_1=3$，$\lambda_2=1$。两者都为正，说明 $\operatorname{rank}(A)=2$，A 是列满秩的。

第三步：求单位特征向量。 它们直接就是 V 的列。对 $\lambda_1=3$：解 $(A^{\mathrm{T}}A-3I)\boldsymbol{x}=\mathbf{0}$。把 $A^{\mathrm{T}}A-3I$ 代进去就是 $-x_1+x_2=0$，即 $x_1=x_2$，故 $\boldsymbol{x}\propto(1,1)^{\mathrm{T}}$，单位化后 $\boldsymbol{v}_1=\frac{1}{\sqrt{2}}(1,1)^{\mathrm{T}}$。

对 $\lambda_2=1$：解 $(A^{\mathrm{T}}A-I)\boldsymbol{x}=\mathbf{0}$，即 $x_1+x_2=0$，故 $\boldsymbol{x}\propto(1,-1)^{\mathrm{T}}$，单位化后 $\boldsymbol{v}_2=\frac{1}{\sqrt{2}}(1,-1)^{\mathrm{T}}$。

两者内积为零，验证了谱定理的结论。

第四步：奇异值是特征值的平方根。 这一步不是新定义，只是倒推结论 (2) 的翻译：$\sigma_i^2=\lambda_i$。

$$\sigma_1=\sqrt{\lambda_1}=\sqrt{3}\approx 1.732,\qquad \sigma_2=\sqrt{\lambda_2}=1. \tag{15}$$

第五步：用 $\boldsymbol{u}_i=A\boldsymbol{v}_i/\sigma_i$ 算左奇异向量。 这是式 (12) 的反解，不是新公式：既然 $A\boldsymbol{v}_i=\sigma_i\boldsymbol{u}_i$，两边除以 σ_i 即可。注意除法合法的前提是 $\sigma_i>0$——这也解释了为什么零奇异值对应的 $\boldsymbol{u}$ 无法由这个式子得到，只能靠下一步补全。

$$A\boldsymbol{v}_1=\frac{1}{\sqrt{2}}\begin{pmatrix}1\\1\\2\end{pmatrix},\qquad \boldsymbol{u}_1=\frac{A\boldsymbol{v}_1}{\sigma_1}=\frac{1}{\sqrt{2}\cdot\sqrt{3}}\begin{pmatrix}1\\1\\2\end{pmatrix}=\frac{1}{\sqrt{6}}\begin{pmatrix}1\\1\\2\end{pmatrix}, \tag{16}$$

$$A\boldsymbol{v}_2=\frac{1}{\sqrt{2}}\begin{pmatrix}1\\-1\\0\end{pmatrix},\qquad \boldsymbol{u}_2=\frac{A\boldsymbol{v}_2}{\sigma_2}=\frac{1}{\sqrt{2}}\begin{pmatrix}1\\-1\\0\end{pmatrix}. \tag{17}$$

第六步：补全 U 的第三列。 U 必须是 3×3 的正交矩阵，而第 5 步只造出两列，还差一个与 $\boldsymbol{u}_1,\boldsymbol{u}_2$ 都正交的单位向量。标准做法是对 $\{\boldsymbol{u}_1,\boldsymbol{u}_2,\mathbf{e}_1\}$ 做 Gram–Schmidt：取 $\mathbf{e}_1=(1,0,0)^{\mathrm{T}}$，减去它在 $\boldsymbol{u}_1,\boldsymbol{u}_2$ 上的投影分量，

$$\begin{aligned}\mathbf{w}&=\mathbf{e}_1-(\mathbf{e}_1^{\mathrm{T}}\boldsymbol{u}_1)\boldsymbol{u}_1-(\mathbf{e}_1^{\mathrm{T}}\boldsymbol{u}_2)\boldsymbol{u}_2\\&=(1,0,0)^{\mathrm{T}}-\tfrac{1}{6}(1,1,2)^{\mathrm{T}}-\tfrac{1}{2}(1,-1,0)^{\mathrm{T}}=\tfrac{1}{3}(1,1,-1)^{\mathrm{T}},\end{aligned} \tag{18}$$

其中用到 $\mathbf{e}_1^{\mathrm{T}}\boldsymbol{u}_1=1/\sqrt{6}$ 与 $\mathbf{e}_1^{\mathrm{T}}\boldsymbol{u}_2=1/\sqrt{2}$。归一化（$\|\mathbf{w}\|=1/\sqrt{3}$）得

$$\boldsymbol{u}_3=\frac{\mathbf{w}}{\|\mathbf{w}\|}=\frac{1}{\sqrt{3}}\begin{pmatrix}1\\1\\-1\end{pmatrix}, \tag{19}$$

可直接验证 $\boldsymbol{u}_3^{\mathrm{T}}\boldsymbol{u}_1=\boldsymbol{u}_3^{\mathrm{T}}\boldsymbol{u}_2=0$ 且 $\|\boldsymbol{u}_3\|=1$。

注 4.5

在 $\mathbb{R}^3$ 里还有个更快的办法：叉积。$\boldsymbol{u}_1 \times \boldsymbol{u}_2$ 与两者都正交，归一化即得 $\boldsymbol{u}_3$（算得 $(2,2,-2)^{\mathrm{T}}/\sqrt{12} = (1,1,-1)^{\mathrm{T}}/\sqrt{3}$，与上面一致）。但叉积只在三维可用，Gram–Schmidt 对任意维数都成立，是通用做法。

$\boldsymbol{u}_3$ 取正号还是负号都合法（见 5.6 节）。本讲义取 $(1,1,-1)^{\mathrm{T}}/\sqrt{3}$，此时 $\det U = +1$，U 是纯旋转；取反号则 $\det U = -1$，变成反射。

第七步：写出三个矩阵并验证。 把前面得到的列按顺序排好：

$$U = \begin{pmatrix} \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ \frac{2}{\sqrt{6}} & 0 & -\frac{1}{\sqrt{3}} \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \sqrt{3} & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix}, \quad V = \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{pmatrix}. \tag{20}$$

验证这一步不能省：到此为止只证明了“若 SVD 存在则必是这个形式”，还没有证明“这个形式确实是 SVD”。逐元素核对 $U\Sigma V^{\mathrm{T}}$ 与 A——验证 $(1,1)$ 元与 $(3,2)$ 元（其余元素同理）：

$$(U\Sigma V^{\mathrm{T}})_{11} = \left(\tfrac{1}{\sqrt{2}}\right)\left(\tfrac{1}{\sqrt{2}}\right) + \left(\tfrac{1}{\sqrt{2}}\right)\left(\tfrac{1}{\sqrt{2}}\right) = 1, \tag{21}$$

$$(U\Sigma V^{\mathrm{T}})_{32} = \left(\tfrac{2}{\sqrt{2}}\right)\left(\tfrac{1}{\sqrt{2}}\right) + 0 \cdot \left(-\tfrac{1}{\sqrt{2}}\right) = 1. \tag{22}$$

与 A 的对应元素一致。Σ 的第三行全为零，恰好对应 $\operatorname{rank}(A) = 2 < 3$。

这个例子说明了什么 A 把 $\mathbb{R}^2$ 中的单位圆映成 $\mathbb{R}^3$ 中的椭圆，椭圆所在平面由 $\boldsymbol{u}_1, \boldsymbol{u}_2$ 张成，半轴长度是 $\sqrt{3}$ 和 1。第三个方向 $\boldsymbol{u}_3$ 垂直于这个平面，整个平面在 $\boldsymbol{u}_3$ 方向上的“厚度”为零——这就是 $\sigma_3 = 0$ 的几何含义。任何 $m \times n$ 矩阵的像都落在 $\operatorname{span}\{\boldsymbol{u}_1, \dots, \boldsymbol{u}_r\}$ 这个 r 维子空间里。

4.3 外积形式：把矩阵拆成秩一矩阵之和

把 $A = U\Sigma V^{\mathrm{T}}$ 按列展开，可以得到最常用的一种写法：

$$A = \sum_{i=1}^{r} \sigma_i \boldsymbol{u}_i \boldsymbol{v}_i^{\mathrm{T}}. \tag{23}$$

每一项 $\boldsymbol{u}_i \boldsymbol{v}_i^{\mathrm{T}}$ 是一个 $m \times n$ 矩阵，它的每一列都是 $\boldsymbol{u}_i$ 的倍数，每一行都是 $\boldsymbol{v}_i^{\mathrm{T}}$ 的倍数，因此秩为 1。式 (23) 说的是：**任何矩阵都可以写成若干个秩一矩阵的加权和，权重就是奇异值。**

这个视角非常有用。它把矩阵的“信息量”分解成一个个独立的层：第一层 $\sigma_1 \boldsymbol{u}_1 \boldsymbol{v}_1^{\mathrm{T}}$ 贡献最大，第二层次之，依此类推。奇异值下降得越快，说明少数几层就能撑起整个矩阵，这就是“低秩”的量化含义。

5 存在性：为什么 SVD 一定存在

定义只是说“如果存在这样的分解，就叫它 SVD”，还没有回答它是否真的存在。这一节给出构造性证明：不仅证明存在，还顺便给出了计算方法。

5.1 证明路线图

证明分三步，每一步只用一个工具：

1. **对 $A^{\mathrm{T}}A$ 用谱定理。**由命题 2.6，$A^{\mathrm{T}}A$ 对称半正定，于是有 n 个非负实特征值和一组标准正交特征向量 $\boldsymbol{v}_1, \dots, \boldsymbol{v}_n$。
2. **构造 $\boldsymbol{u}_i$。**对前 r 个正特征值，令 $\boldsymbol{u}_i = A\boldsymbol{v}_i/\sigma_i$，并证明它们恰好是单位正交的。
3. **补全并验证。**把 $\{\boldsymbol{u}_1, \dots, \boldsymbol{u}_r\}$ 扩充成 $\mathbb{R}^m$ 的标准正交基，然后验证 $A = U\Sigma V^{\mathrm{T}}$ 在基向量上成立。

这个证明的美妙之处在于：它不需要任何高深工具，只需要“对称矩阵可正交对角化”这一条，剩下的都是计算。

5.2 第一步：$A^{\mathrm{T}}A$ 的特征分解

> **引理 5.1**
> 设 $A \in \mathbb{R}^{m\times n}$，$\operatorname{rank}(A) = r$。则 $A^{\mathrm{T}}A$ 的特征值可以排成
>
> $$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_r > 0 = \lambda_{r+1} = \cdots = \lambda_n, \tag{24}$$
>
> 对应的单位特征向量 $\boldsymbol{v}_1, \dots, \boldsymbol{v}_n$ 构成 $\mathbb{R}^n$ 的标准正交基，且 $A^{\mathrm{T}}A\boldsymbol{v}_i = \lambda_i \boldsymbol{v}_i$。此外，$\boldsymbol{v}_{r+1}, \dots, \boldsymbol{v}_n$ 张成 $\operatorname{null}(A)$。

证明. 由命题 2.6，$A^{\mathrm{T}}A$ 对称半正定，特征值全为非负实数。由谱定理，存在标准正交特征向量组 $\boldsymbol{v}_1, \dots, \boldsymbol{v}_n$。按特征值降序排列，正特征值的个数记为 r'。

对任意 i，$\lambda_i = 0$ 等价于 $A^{\mathrm{T}}A\boldsymbol{v}_i = \boldsymbol{0}$，由命题 2.6 的式 (5) 等价于 $A\boldsymbol{v}_i = \boldsymbol{0}$。因此零特征值对应的特征向量恰好张成 $\operatorname{null}(A)$，其个数为 $n - \operatorname{rank}(A) = n - r$。所以 $r' = r$。 □

> **注 5.1**
> 这个引理同时说明了两件事：奇异值的平方就是 $A^{\mathrm{T}}A$ 的特征值；右奇异向量就是 $A^{\mathrm{T}}A$ 的特征向量。这两条是后面所有计算的基础。

5.3 第二步：构造左奇异向量

引理 5.2

对 $i = 1, \dots, r$，定义

$$\boldsymbol{u}_i = \frac{A\boldsymbol{v}_i}{\sigma_i}, \qquad \sigma_i = \sqrt{\lambda_i} > 0. \tag{25}$$

则 $\boldsymbol{u}_1, \dots, \boldsymbol{u}_r$ 是 $\mathbb{R}^m$ 中的标准正交组。

证明. **长度**：由 $\boldsymbol{v}_i$ 是 $A^{\mathrm{T}}A$ 的单位特征向量，

$$\|A\boldsymbol{v}_i\|_2^2 = (A\boldsymbol{v}_i)^{\mathrm{T}}(A\boldsymbol{v}_i) = \boldsymbol{v}_i^{\mathrm{T}}A^{\mathrm{T}}A\boldsymbol{v}_i = \lambda_i\|\boldsymbol{v}_i\|_2^2 = \sigma_i^2, \tag{26}$$

故 $\|\boldsymbol{u}_i\|_2 = \|A\boldsymbol{v}_i\|_2/\sigma_i = 1$。

正交：对 $i \neq j$，

$$\boldsymbol{u}_i^{\mathrm{T}}\boldsymbol{u}_j = \frac{(A\boldsymbol{v}_i)^{\mathrm{T}}(A\boldsymbol{v}_j)}{\sigma_i\sigma_j} = \frac{\boldsymbol{v}_i^{\mathrm{T}}A^{\mathrm{T}}A\boldsymbol{v}_j}{\sigma_i\sigma_j} = \frac{\lambda_j\,\boldsymbol{v}_i^{\mathrm{T}}\boldsymbol{v}_j}{\sigma_i\sigma_j} = 0, \tag{27}$$

最后一步用了 $\boldsymbol{v}_i^{\mathrm{T}}\boldsymbol{v}_j = 0$。 □

注 5.2

这里用到了一个容易被忽略的事实：$A\boldsymbol{v}_i$ 与 $A\boldsymbol{v}_j$ 的正交性，是由 $\boldsymbol{v}_i$ 与 $\boldsymbol{v}_j$ 关于 $A^{\mathrm{T}}A$ 的正交性“传递”过来的。这种“把正交性从一个空间搬到另一个空间”的技巧，在矩阵分析里非常常见。

5.4 第三步：补全并验证

定理 5.3 （奇异值分解的存在性）

设 $A \in \mathbb{R}^{m\times n}$，$\operatorname{rank}(A) = r \geq 1$。则存在正交矩阵 $U \in \mathbb{R}^{m\times m}$、$V \in \mathbb{R}^{n\times n}$ 与 $m \times n$ 的对角矩阵 Σ，使得 $A = U\Sigma V^{\mathrm{T}}$。

证明. 取 $V = [\boldsymbol{v}_1, \dots, \boldsymbol{v}_n]$，其中 $\boldsymbol{v}_i$ 是引理 5.1 给出的标准正交特征向量，此时 V 是正交矩阵。

取 $\boldsymbol{u}_1, \dots, \boldsymbol{u}_r$ 如引理 5.2，它们构成 $\mathbb{R}^m$ 中的标准正交组。由 Gram–Schmidt 过程，可以把它扩充为 $\mathbb{R}^m$ 的标准正交基 $\boldsymbol{u}_1, \dots, \boldsymbol{u}_r, \boldsymbol{u}_{r+1}, \dots, \boldsymbol{u}_m$，令 $U = [\boldsymbol{u}_1, \dots, \boldsymbol{u}_m]$，则 U 也是正交矩阵。

令 $\Sigma \in \mathbb{R}^{m\times n}$ 的对角元为 $\sigma_1, \dots, \sigma_r$，其余为零。下面验证 $A = U\Sigma V^{\mathrm{T}}$。由于 $\{\boldsymbol{v}_1, \dots, \boldsymbol{v}_n\}$ 是 $\mathbb{R}^n$ 的一组基，只需验证两边作用在每个 $\boldsymbol{v}_j$ 上结果相同。

情形一：$j \leq r$。此时 $\sigma_j > 0$，有

$$U\Sigma V^{\mathrm{T}}\boldsymbol{v}_j = U\Sigma\mathbf{e}_j = U(\sigma_j\mathbf{e}_j) = \sigma_j\boldsymbol{u}_j = A\boldsymbol{v}_j, \tag{28}$$

最后一步正是 $\boldsymbol{u}_j$ 的定义。

情形二：$j > r$。此时 $\lambda_j = 0$，由引理 5.1，$\boldsymbol{v}_j \in \mathrm{null}(A)$，故 $A\boldsymbol{v}_j = \mathbf{0}$；而 $\Sigma \mathbf{e}_j = \mathbf{0}$，故 $U\Sigma V^{\mathrm{T}}\boldsymbol{v}_j = \mathbf{0}$。两边也相同。

两个线性映射在基上处处相同，故恒等，即 $A = U\Sigma V^{\mathrm{T}}$。 □

证明的结构 整个证明可以浓缩成一句话：**把 $A^{\mathrm{T}}A$ 的特征分解当作“原料”，用 $A\boldsymbol{v}_i/\sigma_i$ 造出另一半，再用基向量检验。**这个构造过程也提示了算法：只要能算 $A^{\mathrm{T}}A$ 的特征分解，就能算 SVD。当然，实际计算不会真这么做（原因见第　节），但思路是对的。

5.5 秩、零空间与奇异值

定理 5.4

设 $A = U\Sigma V^{\mathrm{T}}$ 是 $A \in \mathbb{R}^{m\times n}$ 的 SVD，则

$$\mathrm{rank}(A) = \#\{i : \sigma_i > 0\} = r. \tag{29}$$

证明. U 与 V 都是正交矩阵，因而可逆，左乘或右乘可逆矩阵不改变秩，故 $\mathrm{rank}(A) = \mathrm{rank}(\Sigma)$。而 Σ 只有前 r 个对角元非零，其余元素全为零，其秩显然为 r。 □

推论 5.5

在同样的记号下，

$$\mathrm{null}(A) = \mathrm{span}\{\boldsymbol{v}_{r+1}, \dots, \boldsymbol{v}_n\}, \qquad \dim \mathrm{null}(A) = n - r, \tag{30}$$

$$\mathrm{col}(A) = \mathrm{span}\{\boldsymbol{u}_1, \dots, \boldsymbol{u}_r\}, \qquad \dim \mathrm{col}(A) = r. \tag{31}$$

证明. 第一式已由引理 5.1 得到。第二式：任意 $\boldsymbol{x}$ 可写成 $\boldsymbol{x} = \sum_{j=1}^{n} c_j \boldsymbol{v}_j$，则 $A\boldsymbol{x} = \sum_{j=1}^{r} c_j \sigma_j \boldsymbol{u}_j$，落在他 $\mathrm{span}\{\boldsymbol{u}_1, \dots, \boldsymbol{u}_r\}$ 中；反过来取 $\boldsymbol{x} = \boldsymbol{v}_i/\sigma_i$（$i \le r$）即得 $\boldsymbol{u}_i$，故两者相等。 □

注 5.3

推论 5.5 给出了一个非常实用的结论：**矩阵的秩等于非零奇异值的个数**。在数值计算中，由于浮点误差，理论上为零的奇异值往往算出来是 10^{-16} 量级的小数，因此常把小于某个阈值（如 $\sigma_1 \cdot \max(m,n) \cdot \varepsilon_{\mathrm{mach}}$）的奇异值视为零。这就是“数值秩”的概念，第 10 节还会讨论。

5.6 唯一性：哪些东西是确定的

定理 5.6 （SVD 的唯一性）

奇异值 $\sigma_1, \dots, \sigma_r$ 由 A 唯一确定。若 $\sigma_1 > \cdots > \sigma_r > 0$ 且互不相同，则 $\boldsymbol{v}_i$ 与 $\boldsymbol{u}_i$（$i \le r$）在相差一个符号的意义下唯一；若存在重奇异值，则对应的奇异向量子空间唯一，但子空间内的正交基可以任意旋转。零奇异值对应的 $\boldsymbol{v}_j$（$j > r$）与 $\boldsymbol{u}_j$（$j > r$）完全不确定。

证明要点. 奇异值是 $A^{\mathrm{T}}A$ 的特征值的平方根，而特征值由 $A^{\mathrm{T}}A$ 唯一确定，故奇异值唯一。若 λ_i 是单重特征值，其特征子空间是一维的，单位向量只有 $\pm\boldsymbol{v}_i$ 两种取法。若 λ_i 是 q 重特征值，对应特征子空间是 q 维的，其中任意一组标准正交基都可以作为 $\boldsymbol{v}$ 的相应列，此时 $\boldsymbol{u}$ 也随之确定（因为 $\boldsymbol{u} = A\boldsymbol{v}/\sigma$）。零特征值对应的子空间是 $\mathrm{null}(A)$，与 $\mathrm{col}(A)$ 的正交补无任何约束关系，故完全任意。 □

符号不确定性会带来麻烦 同一个矩阵，NumPy 与 MATLAB 算出的 $\boldsymbol{u}_i$、$\boldsymbol{v}_i$ 可能差一个负号，甚至同一份代码在不同 BLAS 后端上也可能不同。如果你在比较两组奇异向量（比如做实验复现），不要直接比较向量本身，而应比较 $|\boldsymbol{u}_i^{\mathrm{T}}\hat{\boldsymbol{u}}_i|$，或者比较投影矩阵 $\boldsymbol{u}_i\boldsymbol{u}_i^{\mathrm{T}}$。另外，若 σ_i 有重根，连“第 i 个奇异向量”这个说法本身都没有意义——有意义的是那个不变子空间。

6 基本性质：范数、秩与条件数

这一节把 SVD 与线性代数里几个最重要的量联系起来。结论本身都很简洁，但每一个在后面都会反复出现。

6.1 奇异值与特征值的关系

命题 6.1

设 $A \in \mathbb{R}^{m\times n}$，奇异值为 $\sigma_1 \ge \cdots \ge \sigma_r > 0$，则

1. σ_i^2 是 $A^{\mathrm{T}}A$（也是 AA^{T}）的非零特征值；
2. 若 A 是 n 阶方阵，其特征值为 $\lambda_1, \dots, \lambda_n$（可能是复数），则 $|\lambda_i| \le \sigma_1$，且 $\prod_i |\lambda_i| \le \prod_i \sigma_i$；
3. 若 A 是对称矩阵，则 $\sigma_i = |\lambda_i|$，其中 λ_i 按绝对值降序排列；
4. 若 A 是正交矩阵，则所有奇异值都等于 1。

证明. (1) 由 $A^{\mathrm{T}}A = V\Sigma^{\mathrm{T}}\Sigma V^{\mathrm{T}}$ 即得：$A^{\mathrm{T}}A$ 与 $\Sigma^{\mathrm{T}}\Sigma$ 相似（更准确地说，是正交相似），故特征值相同，而 $\Sigma^{\mathrm{T}}\Sigma$ 的对角元正是 σ_i^2。

(3) 若 A 对称，由谱定理 $A = Q\Lambda Q^{\mathrm{T}}$，取 $U = Q$、$V = Q\,\mathrm{sgn}(\Lambda)$（把负特征值对应的列反号），即得 $A = U|\Lambda|V^{\mathrm{T}}$，故 $\sigma_i = |\lambda_i|$。

(4) 若 A 正交，则 $A^{\mathrm{T}}A = I$，特征值全为 1，故 $\sigma_i = 1$。

(2) 的证明需要用到特征值的变分刻画，这里从略；直观上，σ_1 是矩阵在 **任何**方向上的最大拉伸倍数，而 λ_1 只是某个特定方向上的拉伸倍数，自然有 $|\lambda_1| \le \sigma_1$。 □

奇异值不是特征值的绝对值 对一般的方阵，“$\sigma_i = |\lambda_i|$”是**错的**。例如 $A = \left(\begin{smallmatrix} 0 & 1 \\ 0 & 0 \end{smallmatrix}\right)$ 的特征值全为 0，但奇异值是 1 和 0。只有当 A 对称（或更一般地，正规）时，两者才有上述关系。正确的普遍关系是 $\sigma_i^2 = \lambda_i(A^{\mathrm{T}}A)$，而不是 $\lambda_i(A)^2$。

6.2 三种矩阵范数

定义 6.1 （矩阵范数）

对 $A \in \mathbb{R}^{m\times n}$，定义

$$\|A\|_2 = \max_{\|\boldsymbol{x}\|_2=1} \|A\boldsymbol{x}\|_2 \qquad \text{（谱范数，spectral norm），} \tag{32}$$

$$\|A\|_F = \Big(\sum_{i=1}^{m}\sum_{j=1}^{n} A_{ij}^2\Big)^{1/2} \qquad \text{（Frobenius 范数），} \tag{33}$$

$$\|A\|_* = \sum_{i=1}^{r} \sigma_i \qquad \text{（核范数，nuclear norm）.} \tag{34}$$

定理 6.2

设 $A = U\Sigma V^{\mathrm{T}}$，则

$$\|A\|_2 = \sigma_1, \qquad \|A\|_F = \Big(\sum_{i=1}^{r}\sigma_i^2\Big)^{1/2}, \qquad \|A\|_* = \sum_{i=1}^{r}\sigma_i. \tag{35}$$

证明. **谱范数**。对任意 $\boldsymbol{x}$，令 $\boldsymbol{y} = V^{\mathrm{T}}\boldsymbol{x}$。由于 V 正交，$\|\boldsymbol{y}\|_2 = \|\boldsymbol{x}\|_2$，且

$$\|A\boldsymbol{x}\|_2 = \|U\Sigma V^{\mathrm{T}}\boldsymbol{x}\|_2 = \|\Sigma\boldsymbol{y}\|_2 = \Big(\sum_{i=1}^{r}\sigma_i^2 y_i^2\Big)^{1/2} \le \sigma_1\Big(\sum_{i=1}^{n} y_i^2\Big)^{1/2} = \sigma_1\|\boldsymbol{x}\|_2. \tag{36}$$

取 $\boldsymbol{x} = \boldsymbol{v}_1$，则 $\boldsymbol{y} = \mathbf{e}_1$，$\|A\boldsymbol{v}_1\|_2 = \sigma_1$，故上界可取到。

Frobenius 范数。利用 $\|A\|_F^2 = \mathrm{tr}(A^{\mathrm{T}}A)$ 与迹的轮换不变性：

$$\|A\|_F^2 = \mathrm{tr}(V\Sigma^{\mathrm{T}}U^{\mathrm{T}}U\Sigma V^{\mathrm{T}}) = \mathrm{tr}(V\Sigma^{\mathrm{T}}\Sigma V^{\mathrm{T}}) = \mathrm{tr}(\Sigma^{\mathrm{T}}\Sigma V^{\mathrm{T}}V) = \mathrm{tr}(\Sigma^{\mathrm{T}}\Sigma) = \sum_{i=1}^{r}\sigma_i^2. \tag{37}$$

核范数。由定义 $\|A\|_* = \mathrm{tr}\left((A^{\mathrm{T}}A)^{1/2}\right)$，而 $(A^{\mathrm{T}}A)^{1/2} = V\Sigma V^{\mathrm{T}}$（在秩 r 的子空间上），故迹为 $\sum_i \sigma_i$。 □

三个范数在说什么 $\|A\|_2$ 只看**最大的那一个**奇异值，是“最坏情况”的放大倍数；$\|A\|_F$ 把所有奇异值**平方求和**，更像“平均能量”；$\|A\|_*$ 把所有奇异值**直接相加**，对大奇异值不如平方敏感，因此常被用作“低秩”的凸松弛——它比秩函数好优化得多。

注 6.2

$\|A\|_F$ 与 $\|A\|_2$ 满足 $\|A\|_2 \le \|A\|_F \le \sqrt{r}\,\|A\|_2$，因为 $\sigma_1^2 \le \sum_i \sigma_i^2 \le r\sigma_1^2$。这两个不等式在估计误差时经常用到。

6.3 四个基本子空间

线性代数有“四个基本子空间”之说：列空间、零空间、行空间、左零空间。SVD 把它们的一组标准正交基直接送到你手上。

定理 6.3 （四个基本子空间的正交基）

设 $A = U\Sigma V^{\mathrm{T}}$，$\operatorname{rank}(A) = r$，则

$$\operatorname{row}(A) = \operatorname{span}\{\boldsymbol{v}_1, \dots, \boldsymbol{v}_r\}, \qquad \dim \operatorname{row}(A) = r, \tag{38}$$

$$\operatorname{null}(A) = \operatorname{span}\{\boldsymbol{v}_{r+1}, \dots, \boldsymbol{v}_n\}, \qquad \dim \operatorname{null}(A) = n - r, \tag{39}$$

$$\operatorname{col}(A) = \operatorname{span}\{\boldsymbol{u}_1, \dots, \boldsymbol{u}_r\}, \qquad \dim \operatorname{col}(A) = r, \tag{40}$$

$$\operatorname{null}(A^{\mathrm{T}}) = \operatorname{span}\{\boldsymbol{u}_{r+1}, \dots, \boldsymbol{u}_m\}, \qquad \dim \operatorname{null}(A^{\mathrm{T}}) = m - r. \tag{41}$$

并且 $\operatorname{row}(A) \perp \operatorname{null}(A)$，$\operatorname{col}(A) \perp \operatorname{null}(A^{\mathrm{T}})$，$\mathbb{R}^n = \operatorname{row}(A) \oplus \operatorname{null}(A)$，$\mathbb{R}^m = \operatorname{col}(A) \oplus \operatorname{null}(A^{\mathrm{T}})$。

证明. 前两式即推论 5.5。第三式：$\operatorname{col}(A) = \{A\boldsymbol{x}\} = \{\sum_{i \le r} \sigma_i c_i \boldsymbol{u}_i\}$，其中 $c_i = \boldsymbol{v}_i^{\mathrm{T}}\boldsymbol{x}$ 可取任意值，故等于 $\operatorname{span}\{\boldsymbol{u}_1, \dots, \boldsymbol{u}_r\}$。第四式对 $A^{\mathrm{T}} = V\Sigma^{\mathrm{T}}U^{\mathrm{T}}$ 用第三式的结论即可。正交性来自 $\boldsymbol{v}_i$ 之间、$\boldsymbol{u}_i$ 之间的正交关系。 □

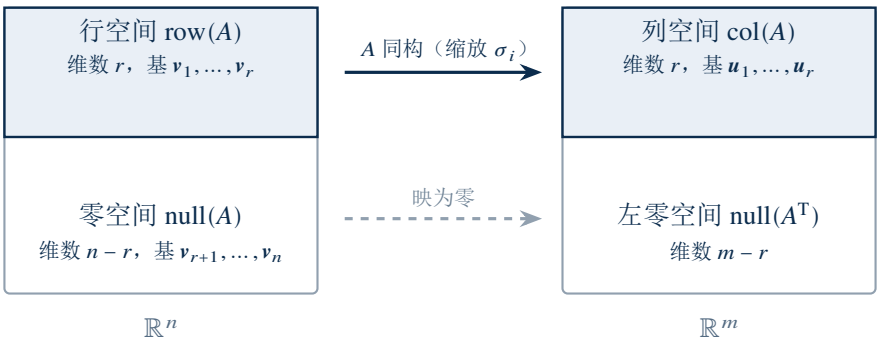


图 3: SVD 与四个基本子空间。A 把行空间一一映到列空间（在基的意义下只差缩放 σ_i），把零空间整个压成原点。两个空间的维数之和分别为 n 与 m。

图 3 值得多看一会儿。它解释了为什么 SVD 被称为“矩阵的解剖图”：A 这个映射的全部行为，被 r 个缩放因子和两组正交基完全描述干净了。

6.4 条件数与病态问题

定义 6.3 （条件数）

对可逆方阵 A，定义条件数

$$\kappa(A) = \|A\|_2 \|A^{-1}\|_2 = \frac{\sigma_1}{\sigma_r}. \tag{42}$$

对一般矩阵，用伪逆代替逆，$\kappa(A) = \sigma_1/\sigma_r$（$r = \operatorname{rank}(A)$）。

命题 6.4

对任意 A，$\kappa(A^{\mathrm{T}}A) = \kappa(A)^2$。

证明. $A^{\mathrm{T}}A$ 的奇异值是 A 的奇异值的平方，故 $\kappa(A^{\mathrm{T}}A) = \sigma_1^2/\sigma_r^2 = \kappa(A)^2$。 □

条件数衡量的是“椭圆有多扁”。$\kappa = 1$ 时椭圆的半轴一样长（所有方向拉伸相同，A 是正交矩阵的倍数）；κ 很大时椭圆被压成很细的一条，某些方向的输入几乎无法从输出中恢复。

条件数的实际含义 若 $\kappa(A) = 10^k$，则在双精度（约 16 位十进制有效数字）下，求解 $A\boldsymbol{x} = \boldsymbol{b}$ 大约会损失 k 位有效数字。$\kappa = 10^{12}$ 时，结果里只剩 4 位可信。这不是算法不够好，而是问题本身对扰动敏感——任何用有限精度计算的方法都躲不开。

6.5 行列式与迹

命题 6.5

设 A 为 n 阶方阵，则

$$|\det(A)| = \prod_{i=1}^{n} \sigma_i, \qquad \|A\|_F^2 = \operatorname{tr}(A^{\mathrm{T}}A) = \sum_{i=1}^{n} \sigma_i^2. \tag{43}$$

证明. $\det(A) = \det(U)\det(\Sigma)\det(V^{\mathrm{T}})$，而 $\det(U), \det(V) = \pm 1$，$\det(\Sigma) = \prod_i \sigma_i$（零奇异值使行列式为零，两边一致）。第二式即定理 6.2 的 Frobenius 部分。 □

注 6.4

$|\det A|$ 的几何意义是“体积放大倍数”：单位立方体经 A 作用后变成平行六面体，体积为 $\prod_i \sigma_i$。这个平行六面体在最长的方向被拉伸 σ_1 倍，在最扁的方向被压缩 σ_n 倍——条件数正是这两个倍数的比。

自检

1. 若 A 的所有奇异值相等且非零，A 一定是什么形式的矩阵？
2. 证明 $\|A\|_2 \le \|A\|_F \le \sqrt{r}\|A\|_2$。
3. 一个 3×3 矩阵的奇异值为 $100, 10, 0.1$，它的条件数是多少？若用双精度求解 $A\boldsymbol{x}=\boldsymbol{b}$，大约还剩几位有效数字？

7 低秩逼近：Eckart–Young 定理

前面反复提到“截断 SVD 是最优的低秩逼近”，这一节把它证明出来。这是 SVD 在工程上最重要的性质，没有之一。

7.1 为什么追求低秩

一个 $m\times n$ 矩阵需要 mn 个数才能存下。若它的秩为 k，用截断 SVD 存储只需要 $k(m+n+1)$ 个数：k 个奇异值，U_k 的 mk 个元素，V_k 的 nk 个元素。当 $k \ll \min(m,n)$ 时，这是数量级的节省。

低秩还有别的意义：

- **去噪**：真实信号往往是低秩的，噪声是满秩的。截断掉小奇异值，就滤掉了噪声。
- **泛化**：在推荐系统里，“用户—物品”矩阵若近似低秩，意味着用户的偏好可以由少数几个潜在因子解释，从而能预测缺失的评分。
- **压缩**：图像、音频、神经网络的权重，都可以用低秩矩阵近似存储。

问题在于：给定 k，怎样找一个秩不超过 k 的矩阵 B，使 $\|A-B\|$ 最小？Eckart–Young 定理的回答是：**直接截断 SVD，不用再找**。

7.2 定理的陈述

定理 7.1 （Eckart–Young，1936）

设 $A \in \mathbb{R}^{m\times n}$ 的 SVD 为 $A = \sum_{i=1}^{r} \sigma_i \boldsymbol{u}_i \boldsymbol{v}_i^{\mathrm{T}}$，对 $1 \le k < r$ 定义截断 SVD

$$A_k = \sum_{i=1}^{k} \sigma_i \boldsymbol{u}_i \boldsymbol{v}_i^{\mathrm{T}}. \tag{44}$$

则对任意满足 $\operatorname{rank}(B) \le k$ 的 $B \in \mathbb{R}^{m\times n}$，有

$$\|A - B\|_2 \ge \sigma_{k+1}, \tag{45}$$

$$\|A - B\|_F \ge \Big(\sum_{i=k+1}^{r} \sigma_i^2 \Big)^{1/2}, \tag{46}$$

且 $B = A_k$ 同时使两式取等号。换言之，A_k 既是谱范数意义下、也是 Frobenius 范数意义下的**最佳秩 k 逼近**。

定理里有两个独立的结论，分别对应两种“误差”的定义。谱范数关心最坏方向上的误差，F 范数关心总体平方误差。两者给出的最优解恰好是同一个 A_k，这一点并不平凡。

7.3 谱范数情形的证明

这个证明只需要一个巧妙的维数论证。

式 (45) 的证明. 设 B 满足 $\operatorname{rank}(B) \le k$。由于 B 是 $m \times n$ 矩阵，其零空间维数至少为 $n - k$：

$$\dim \operatorname{null}(B) = n - \operatorname{rank}(B) \ge n - k. \tag{47}$$

另一方面，考虑由前 $k+1$ 个右奇异向量张成的子空间 $W = \operatorname{span}\{\boldsymbol{v}_1, \dots, \boldsymbol{v}_{k+1}\}$，其维数为 $k+1$（因为对应的奇异值都为正，这些向量线性无关）。

两个子空间都住在 $\mathbb{R}^n$ 里，维数之和为 $(n-k) + (k+1) = n+1 > n$，故必有非零交叠：

$$\dim \big(\operatorname{null}(B) \cap W \big) \ge 1. \tag{48}$$

取交集中一个单位向量 $\mathbf{w}$。它有两个身份：

身份一：$\mathbf{w} \in \operatorname{null}(B)$，故 $B\mathbf{w} = \mathbf{0}$，于是 $(A - B)\mathbf{w} = A\mathbf{w}$。

身份二：$\mathbf{w} \in W$，故可写成 $\mathbf{w} = \sum_{i=1}^{k+1} c_i \boldsymbol{v}_i$，且 $\sum_{i=1}^{k+1} c_i^2 = \|\mathbf{w}\|^2 = 1$。

把 $A\mathbf{w}$ 用 SVD 展开：

$$A\mathbf{w} = \sum_{i=1}^{k+1} c_i A\boldsymbol{v}_i = \sum_{i=1}^{k+1} c_i \sigma_i \boldsymbol{u}_i. \tag{49}$$

由于 $\boldsymbol{u}_i$ 两两正交，

$$\|A\mathbf{w}\|_2^2 = \sum_{i=1}^{k+1} c_i^2 \sigma_i^2 \ge \sigma_{k+1}^2 \sum_{i=1}^{k+1} c_i^2 = \sigma_{k+1}^2. \tag{50}$$

（这里用了 $\sigma_i \geq \sigma_{k+1}$ 对 $i \leq k+1$ 成立。）

于是

$$\|A - B\|_2 = \max_{\|\boldsymbol{x}\|=1} \|(A-B)\boldsymbol{x}\|_2 \geq \|(A-B)\mathbf{w}\|_2 = \|A\mathbf{w}\|_2 \geq \sigma_{k+1}. \tag{51}$$

最后验证等号：$A - A_k = \sum_{i=k+1}^{r} \sigma_i \boldsymbol{u}_i \boldsymbol{v}_i^{\mathrm{T}}$，它的最大奇异值正是 σ_{k+1}，故 $\|A - A_k\|_2 = \sigma_{k+1}$。 □

> **证明的核心思想** 任意一个秩不超过 k 的矩阵，都必然“看不见”某个 $k+1$ 维的方向组合——它的零空间太大了，躲不开前 $k+1$ 个奇异方向张成的子空间。在那个躲不开的方向上，B 什么也做不了，只能让 A 自己去拉伸，于是误差至少是 σ_{k+1}。

7.4 Frobenius 范数情形的证明

F 范数的情形需要一个关于迹的不等式。

> **引理 7.2** （von Neumann 迹不等式）
> 对任意 $A, B \in \mathbb{R}^{m\times n}$，
> $$|\mathrm{tr}(A^{\mathrm{T}}B)| \leq \sum_{i=1}^{\min(m,n)} \sigma_i(A)\sigma_i(B). \tag{52}$$

证明思路. 令 $A = U\Sigma V^{\mathrm{T}}$，$B = P\Lambda Q^{\mathrm{T}}$ 为各自的 SVD，则

$$\mathrm{tr}(A^{\mathrm{T}}B) = \mathrm{tr}(V\Sigma U^{\mathrm{T}}P\Lambda Q^{\mathrm{T}}) = \mathrm{tr}\left(\Sigma\,(U^{\mathrm{T}}P)\,\Lambda\,(Q^{\mathrm{T}}V)\right). \tag{53}$$

记 $X = U^{\mathrm{T}}P$、$Y = Q^{\mathrm{T}}V$，两者都是正交矩阵。于是问题化为：对正交的 X, Y 与非负对角阵 Σ, Λ，证明 $|\mathrm{tr}(\Sigma X \Lambda Y)| \leq \sum_i \sigma_i \lambda_i$。这可以用重排不等式（Hardy–Littlewood–Pólya）证明，此处从略。 □

式 (46) 的证明. 设 $\mathrm{rank}(B) \leq k$，记 $a_i = \sigma_i(A)$，$b_i = \sigma_i(B)$。由于 $\mathrm{rank}(B) \leq k$，当 $i > k$ 时 $b_i = 0$。展开平方：

$$\begin{aligned}
\|A - B\|_F^2 &= \|A\|_F^2 - 2\,\mathrm{tr}(A^{\mathrm{T}}B) + \|B\|_F^2 \\
&\geq \sum_{i=1}^{r} a_i^2 - 2\sum_{i=1}^{k} a_i b_i + \sum_{i=1}^{k} b_i^2 \qquad \text{（引理 7.2）} \\
&= \sum_{i=k+1}^{r} a_i^2 + \sum_{i=1}^{k} (a_i - b_i)^2 \\
&\geq \sum_{i=k+1}^{r} a_i^2 .
\end{aligned} \tag{54}$$

最后一步因为平方项非负。对 $B = A_k$，有 $b_i = a_i$（$i \leq k$），式 (54) 的两个不等号同时取等号，故 $\|A - A_k\|_F^2 = \sum_{i>k} \sigma_i^2$，下界可达。 □

注 7.1

注意式 (54) 中间那个等式：

$$\|A - B\|_F^2 = \sum_{i>k} \sigma_i^2 + \sum_{i\le k} (\sigma_i - \sigma_i(B))^2 \tag{55}$$

在 $B = A_k$ 时成立。它说明：如果 B 的奇异值偏离 A 的前 k 个奇异值，误差只会更大。所以**最佳逼近不仅要“方向对”，还要“长度对”。**

7.5 误差、能量与秩的选择

有了定理 7.1，可以定义“前 k 个奇异值解释了多少信息”：

$$E(k) = \frac{\sum_{i=1}^{k} \sigma_i^2}{\sum_{i=1}^{r} \sigma_i^2} = 1 - \frac{\|A - A_k\|_F^2}{\|A\|_F^2}. \tag{56}$$

$E(k)$ 称为**累计能量比例**，取值在 $[0,1]$ 之间，越接近 1 说明前 k 项保留得越完整。

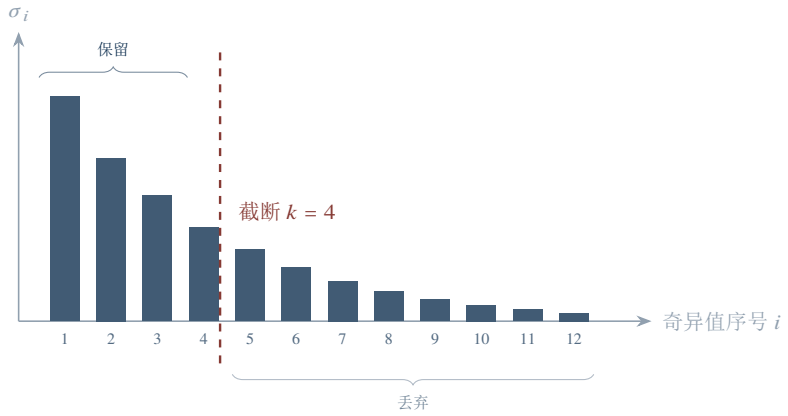


图 4: 一个典型的奇异值谱。奇异值快速衰减时，前几个分量就承载了绝大部分能量，后面的“长尾”往往对应噪声或细节。k 的选择就是在这个长尾上做截断。

图 4 画出了一个典型的奇异值谱。真实的图像、文本、评分矩阵都有类似的形状：少数几个奇异值很大，然后迅速掉进一个长尾。这正是低秩逼近能奏效的原因。

> **k 不能看测试集来选**　在实际任务中，k 是一个需要选择的超参数。常见做法有：取 $E(k) \ge 0.95$ 的最小 k；或者看谱图上的“肘部”；或者用交叉验证。但**绝不能**根据测试集上的表现来挑 k——那等于用测试集训练，得到的评估结果会偏乐观。这是机器学习评估中最常见的错误之一。

7.6 一个算例：图像压缩

设有一张 512×512 的灰度图，把它看作矩阵 A。用 SVD 压缩的存储方案是：只保留前 k 个奇异值及对应的奇异向量，需要的存储量为

$$\underbrace{k}_{\sigma_i} + \underbrace{512k}_{U_k} + \underbrace{512k}_{V_k} = k(1024+1) = 1025k \quad \text{个数.} \tag{57}$$

原图需要 $512^2 = 262144$ 个数。压缩比如下表所示。

表 3: 不同截断秩下的存储量与相对误差（512×512 图像）

k	存储量	占原图比例	压缩比	相对误差 $\|A - A_k\|_F / \|A\|_F$
10	10 250	3.9%	25.6 : 1	依图像而定
30	30 750	11.7%	8.5 : 1	依图像而定
50	51 250	19.6%	5.1 : 1	依图像而定
100	102 500	39.1%	2.6 : 1	依图像而定
256	262 400	100.1%	1.0 : 1	几乎为零

表 3 里“相对误差”一列写了“依图像而定”，是因为它完全取决于图像的奇异值谱，没有普适数值。对一张细节丰富的照片，$k = 50$ 可能仍有可见的块状模糊；对一张以大面积平滑区域为主的图像，$k = 20$ 就可能看不出差别。

下面是用 NumPy 做这件事的代码，不到十行：

```python
import numpy as np
from numpy.linalg import svd

A = ...                              # 512 x 512 grayscale image, values in [0,1]
U, s, Vt = svd(A, full_matrices=False)   # economy (thin) SVD

def approx(U, s, Vt, k):
    return (U[:, :k] * s[:k]) @ Vt[:k]   # same as U_k @ diag(s_k) @ V_k.T

for k in (10, 30, 50, 100):
    Ak = approx(U, s, Vt, k)
    err = np.linalg.norm(A - Ak) / np.linalg.norm(A)
    print(f"k={k:3d}  relative error = {err:.4f}")
```

> **注 7.2**
>
> 代码里 `U[:, :k] * s[:k]` 利用了 NumPy 的广播：形状 $(512, k)$ 的数组乘以形状 $(k,)$ 的数组，会按列逐列缩放。写成一个循环也完全可以，只是慢一些。

7.7 低秩逼近的局限

Eckart–Young 定理很强，但它的适用范围有明确的边界，用错地方会得出误导性的结论。

1. **“最佳”是相对于 F 范数和谱范数而言的。**如果误差的度量换成别的（例如逐元素绝对误差、加权误差、感知损失），A_k 未必最优。
2. **F 范数对大误差特别敏感。**因为误差是平方的，少数几个异常点就能主导整个目标。数据里有离群值时，SVD 低秩逼近会把它们“摊”到所有元素上，效果很差。这时应该用鲁棒 PCA 一类的方法。
3. **缺失数据不能直接做 SVD。**推荐系统里的评分矩阵有大量空缺，而 SVD 要求矩阵完整。把缺失当成 0 直接补全，会系统性地低估评分。正确做法是矩阵补全（matrix completion），它优化的是“只在已观测位置上”的误差，Eckart–Young 定理在这里**不适用**。
4. **计算成本随 k 增长。**当 k 接近 $\min(m,n)$ 时，截断 SVD 相对完整 SVD 没有优势，还不如直接算。

> **一个常见的误用**　有人把用户—物品评分矩阵的缺失项填 0，做 SVD，然后说“这就是协同过滤”。这是错的：填 0 相当于告诉算法“这个用户非常讨厌这部电影”，而事实上我们只是不知道他的态度。这样的模型会把预测值整体压低，而且秩越低偏差越大。正确的方法（如 FunkSVD、ALS）只对观测到的评分计算损失。

自检

1. 若 A 的奇异值为 $5, 3, 1$，写出 $\|A - A_1\|_2$、$\|A - A_1\|_F$ 与 $E(1)$。
2. 证明：若 $\operatorname{rank}(A) = r$，则不存在秩小于 r 的矩阵 B 使 $\|A - B\|_F = 0$。
3. 为什么说“A_k 同时是谱范数和 F 范数下的最优解”这件事并不显然？试构造一个反例说明：对一般的矩阵范数，两种意义下的最优解可能不同。

8 伪逆与最小二乘

SVD 最早、最经典的用途之一，是求解“方程比未知数多”的最小二乘问题。这一节说明为什么用 SVD 求解比用正规方程更可靠。

8.1 超定方程为什么常常无解

考虑线性方程组 $A\boldsymbol{x}=\boldsymbol{b}$，其中 $A\in\mathbb{R}^{m\times n}$ 且 $m>n$（方程个数多于未知数）。一般情况下，$\boldsymbol{b}$ 不会恰好落在 $\mathrm{col}(A)$ 里，方程组**无解**。

例如

$$\begin{pmatrix}1&0\\0&1\\1&1\end{pmatrix}\begin{pmatrix}x_1\\x_2\end{pmatrix}=\begin{pmatrix}1\\1\\3\end{pmatrix} \tag{58}$$

无解，因为前两个方程要求 $x_1=x_2=1$，代入第三个得 $2\neq 3$。三个方程在“争夺”两个未知数，不可能同时满足。

工程上的处理方式是退一步：不要求残差为零，只要求残差尽可能小。这就是最小二乘：

$$\boldsymbol{x}_{\mathrm{LS}}=\arg\min_{\boldsymbol{x}\in\mathbb{R}^n}\|A\boldsymbol{x}-\boldsymbol{b}\|_2^2. \tag{59}$$

8.2 最小二乘的几何：把 b 投影到列空间

$\|A\boldsymbol{x}-\boldsymbol{b}\|_2^2$ 最小，等价于 $A\boldsymbol{x}$ 是 $\boldsymbol{b}$ 在 $\mathrm{col}(A)$ 上的**正交投影**。理由很直观：如果 $A\boldsymbol{x}$ 不是投影点，那么沿着 $\mathrm{col}(A)$ 内的方向微调 $\boldsymbol{x}$，还能让距离更小。

于是可以写 $\boldsymbol{b}=A\boldsymbol{x}+\mathbf{e}$，其中 $\mathbf{e}\perp\mathrm{col}(A)$，即 $A^{\mathrm{T}}\mathbf{e}=\mathbf{0}$。两边左乘 A^{T}：

$$A^{\mathrm{T}}\boldsymbol{b}=A^{\mathrm{T}}A\boldsymbol{x}+A^{\mathrm{T}}\mathbf{e}=A^{\mathrm{T}}A\boldsymbol{x}. \tag{60}$$

这就是著名的**正规方程**（normal equation）。

> **定理 8.1**
> 若 A 列满秩（$\mathrm{rank}(A)=n$），则 $A^{\mathrm{T}}A$ 可逆，最小二乘问题 (59) 有唯一解
>
> $$\boldsymbol{x}_{\mathrm{LS}}=(A^{\mathrm{T}}A)^{-1}A^{\mathrm{T}}\boldsymbol{b}. \tag{61}$$

证明. $A^{\mathrm{T}}A$ 可逆性由命题 2.6：若 A 列满秩，则 $\mathrm{null}(A)=\{\mathbf{0}\}$，故 $\mathrm{null}(A^{\mathrm{T}}A)=\{\mathbf{0}\}$，$n$ 阶方阵满秩。唯一性：目标函数是严格凸二次函数 $f(\boldsymbol{x})=\boldsymbol{x}^{\mathrm{T}}A^{\mathrm{T}}A\boldsymbol{x}-2\boldsymbol{b}^{\mathrm{T}}A\boldsymbol{x}+\boldsymbol{b}^{\mathrm{T}}\boldsymbol{b}$，其 Hessian $2A^{\mathrm{T}}A$ 正定，唯一的驻点就是全局最小点。令梯度为零即得正规方程。 □

8.3 伪逆：把逆推广到所有矩阵

方阵可逆时 $\boldsymbol{x}=A^{-1}\boldsymbol{b}$；可逆性不成立时，我们希望有一个“替代品”，它在可逆的情形下退化为逆，在不可逆或非方阵时仍然给出合理的结果。

定义 8.1 （Moore–Penrose 伪逆）

设 $A = U\Sigma V^{\mathrm{T}}$ 是 $A \in \mathbb{R}^{m\times n}$ 的 SVD，$\operatorname{rank}(A) = r$。定义

$$A^{+} = V\Sigma^{+}U^{\mathrm{T}}, \qquad \Sigma^{+} = \operatorname{diag}\Big(\frac{1}{\sigma_1}, \dots, \frac{1}{\sigma_r}, 0, \dots, 0\Big) \in \mathbb{R}^{n\times m}, \tag{62}$$

称 A^{+} 为 A 的**伪逆**（pseudoinverse）。

也就是说：把非零奇异值取倒数，再转置一下位置。

命题 8.2 （伪逆的基本性质） **1.** 若 A 可逆，则 $A^{+} = A^{-1}$；

2. $AA^{+}A = A$，$A^{+}AA^{+} = A^{+}$；

3. AA^{+} 是到 $\operatorname{col}(A)$ 的正交投影，$A^{+}A$ 是到 $\operatorname{row}(A)$ 的正交投影；

4. $\operatorname{rank}(A^{+}) = \operatorname{rank}(A)$。

证明. (1) 若 A 可逆，则 $m = n = r$，Σ 与 Σ^{+} 互为逆，故 $A^{+} = V\Sigma^{-1}U^{\mathrm{T}} = (U\Sigma V^{\mathrm{T}})^{-1} = A^{-1}$。

(3) $AA^{+} = U\Sigma\Sigma^{+}U^{\mathrm{T}}$，而 $\Sigma\Sigma^{+}$ 是对角元前 r 个为 1、其余为 0 的 m 阶对角阵，故 $AA^{+} = U_r U_r^{\mathrm{T}}$，正是到 $\operatorname{span}\{\boldsymbol{u}_1, \dots, \boldsymbol{u}_r\} = \operatorname{col}(A)$ 的投影。同理 $A^{+}A = V_r V_r^{\mathrm{T}}$。

(2)(4) 直接由定义验证。 □

定理 8.3 （最小二乘的伪逆解）

对任意 $A \in \mathbb{R}^{m\times n}$ 与 $\boldsymbol{b} \in \mathbb{R}^{m}$，$\boldsymbol{x} = A^{+}\boldsymbol{b}$ 是问题 (59) 的 **极小范数最小二乘解**：它使残差最小，且在所有达到最小残差的解中，它的范数最小。若 A 列满秩，则它就是唯一的最小二乘解。

证明要点. 把 $\boldsymbol{b}$ 按 U 的列分解：$\boldsymbol{b} = \sum_{i=1}^{m} c_i \boldsymbol{u}_i$，其中 $c_i = \boldsymbol{u}_i^{\mathrm{T}}\boldsymbol{b}$。对任意 $\boldsymbol{x}$，写 $\boldsymbol{x} = \sum_{j=1}^{n} d_j \boldsymbol{v}_j$，则

$$A\boldsymbol{x} = \sum_{j=1}^{r} \sigma_j d_j \boldsymbol{u}_j, \qquad \|A\boldsymbol{x} - \boldsymbol{b}\|_2^2 = \sum_{j=1}^{r} (\sigma_j d_j - c_j)^2 + \sum_{i=r+1}^{m} c_i^2. \tag{63}$$

第二项与 $\boldsymbol{x}$ 无关，是第一项可以取到 0，只要 $d_j = c_j/\sigma_j$（$j \le r$）。于是所有最小二乘解都有形式 $\boldsymbol{x} = \sum_{j=1}^{r} \frac{c_j}{\sigma_j}\boldsymbol{v}_j + \sum_{j=r+1}^{n} d_j \boldsymbol{v}_j$，而后半部分的系数 d_j 任意。显然取 $d_j = 0$ 时 $\|\boldsymbol{x}\|_2$ 最小。这正是 $A^{+}\boldsymbol{b}$ 的展开式。 □

伪逆解的展开式

$$A^{+}\boldsymbol{b} = \sum_{i=1}^{r} \frac{\boldsymbol{u}_i^{\mathrm{T}}\boldsymbol{b}}{\sigma_i}\boldsymbol{v}_i.$$

每一项是“$\boldsymbol{b}$ 在第 i 个左奇异方向上的投影系数，除以 σ_i，再放到第 i 个右奇异方向上”。σ_i 越小，这一项被放大得越厉害——这正是病态问题的来源，也是后面要截断的原因。

8.4 为什么不用正规方程

从数学上看，$(A^{\mathrm{T}}A)^{-1}A^{\mathrm{T}}\boldsymbol{b}$ 与 $A^{+}\boldsymbol{b}$ 在精确算术下是同一个东西。但在浮点数下，两者的表现可能天差地别。

> **命题 8.4** （误差放大）
> 设 A 列满秩，$\boldsymbol{b}$ 有扰动 $\delta\boldsymbol{b}$，解相应变为 $\boldsymbol{x}+\delta\boldsymbol{x}$。则
>
> $$\frac{\|\delta\boldsymbol{x}\|_2}{\|\boldsymbol{x}\|_2} \le \kappa(A)\cdot\frac{\|\delta\boldsymbol{b}\|_2}{\|\boldsymbol{b}\|_2}. \tag{64}$$
>
> 若改用正规方程求解，扰动会被放大 $\kappa(A^{\mathrm{T}}A)=\kappa(A)^2$ 倍。

证明. 由 $\boldsymbol{x}=A^{+}\boldsymbol{b}$ 得 $\delta\boldsymbol{x}=A^{+}\delta\boldsymbol{b}$，故 $\|\delta\boldsymbol{x}\|\le\|A^{+}\|_2\|\delta\boldsymbol{b}\|=\frac{1}{\sigma_r}\|\delta\boldsymbol{b}\|$。又 $\|\boldsymbol{b}\|=\|A\boldsymbol{x}\|\le\sigma_1\|\boldsymbol{x}\|$，即 $\|\boldsymbol{x}\|\ge\|\boldsymbol{b}\|/\sigma_1$。两式相除即得。正规方程部分由 $\kappa(A^{\mathrm{T}}A)=\kappa(A)^2$（命题 6.4）。 □

> **条件数的平方为什么致命**　双精度浮点有大约 16 位十进制有效数字。若 $\kappa(A)=10^8$，用 SVD 求解还剩约 8 位可信；用正规方程则放大到 10^{16}，结果可能**一位有效数字都不剩**。更糟的是，$A^{\mathrm{T}}A$ 在计算过程中会丢失信息：原本不同的小奇异值，平方之后可能小于舍入误差，被直接抹成零，矩阵的秩看起来就变了。

> **实践建议**　解最小二乘时，优先用 `np.linalg.lstsq`（内部用 SVD 或 QR），而不是自己写 `inv(A.T @ A) @ A.T @ b`。后者在 A 病态时会给出完全错误的结果，而且不报任何错。判断是否需要担心：先算一下 `np.linalg.cond(A)`，若超过 10^8 就要警惕，超过 10^{12} 基本不能用。

8.5 截断 SVD 与正则化

病态问题的根源是那些很小的奇异值：它们对应的项 $(\boldsymbol{u}_i^{\mathrm{T}}\boldsymbol{b}/\sigma_i)\boldsymbol{v}_i$ 被放大了 $1/\sigma_i$ 倍，噪声因此被放大成灾。

最直接的处理是**截断**：只保留前 k 个奇异值，

$$\boldsymbol{x}_k=\sum_{i=1}^{k}\frac{\boldsymbol{u}_i^{\mathrm{T}}\boldsymbol{b}}{\sigma_i}\boldsymbol{v}_i. \tag{65}$$

这相当于假设“$\boldsymbol{b}$ 在小奇异方向上的分量都是噪声”。

另一种更平滑的做法是**岭回归**（Tikhonov 正则化）：

$$\boldsymbol{x}_\lambda=\arg\min_{\boldsymbol{x}}\|A\boldsymbol{x}-\boldsymbol{b}\|_2^2+\lambda\|\boldsymbol{x}\|_2^2=\sum_{i=1}^{r}\frac{\sigma_i}{\sigma_i^2+\lambda}\,(\boldsymbol{u}_i^{\mathrm{T}}\boldsymbol{b})\,\boldsymbol{v}_i, \tag{66}$$

其中 $\lambda>0$ 是正则化强度。注意过滤因子 $\frac{\sigma_i}{\sigma_i^2+\lambda}$ 的行为：当 $\sigma_i\gg\sqrt{\lambda}$ 时它接近 $1/\sigma_i$（几乎不改变），当 $\sigma_i\ll\sqrt{\lambda}$ 时它接近 σ_i/λ（强烈压制）。

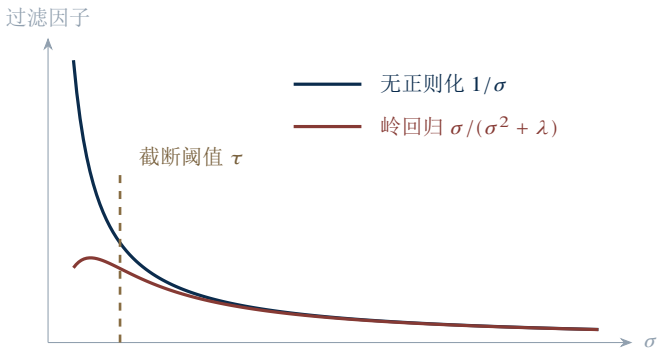


图 5: 三种处理小奇异值的方式。截断（虚线）是“保留或丢弃”的硬开关；岭回归（红色）是平滑的过渡，在 $\sigma \approx \sqrt{\lambda}$ 附近开始压制；无正则化（深蓝）在 $\sigma \to 0$ 时发散。

图 5 画出了三种策略的差异。截断简单但会引入不连续；岭回归平滑，代价是需要选择 λ。两者都是“用一点偏差换取大量方差 reduction”的典型例子，这正是机器学习中偏差—方差权衡的具体形态。

自检

1. 对 $A = \left(\begin{smallmatrix} 1 & 1 \\ 1 & 1 \\ 0 & 0 \end{smallmatrix}\right)$ 与 $\boldsymbol{b} = (2, 2, 1)^{\mathrm{T}}$，求 $A^{+}\boldsymbol{b}$ 与残差。
2. 证明 AA^{+} 是对称矩阵，且 $(AA^{+})^2 = AA^{+}$（即它是投影矩阵）。
3. 若 $\lambda \to 0$，式 (66) 退化成什么？若 $\lambda \to \infty$ 呢？

9 SVD 与主成分分析

主成分分析（PCA）是数据科学中使用最广的降维方法，而它与 SVD 的关系简单到令人意外：**PCA 就是对中心化后的数据矩阵做 SVD**。理解这一点，可以避免很多误用。

9.1 PCA 想解决什么问题

设数据矩阵 $X \in \mathbb{R}^{N \times D}$，$N$ 个样本、D 个特征，第 i 行是第 i 个样本。当 D 很大时，我们想找 $k \ll D$ 个新方向，把数据投影上去，使投影后的点尽量分散（保留最多的变异），同时尽量保持样本之间的相对距离。

“分散”用方差度量。所以问题可以写成：找一个单位向量 $\mathbf{p}_1$，使 $\|X\mathbf{p}_1\|_2^2$ 最大。

9.2 第一步：中心化

注意：PCA 要求数据**已经中心化**，即每一列的均值为零。若不中心化，第一主成分会指向数据的均值方向，而不是变异最大的方向（详见 9.5 节）。

设中心化后的矩阵仍记为 X，则样本协方差矩阵为

$$S = \frac{1}{N-1} X^{\mathrm{T}} X \in \mathbb{R}^{D \times D}. \tag{67}$$

9.3 第二步：对 X 做 SVD

设 $X = U\Sigma V^{\mathrm{T}}$，其中 $U \in \mathbb{R}^{N\times r}$、$\Sigma \in \mathbb{R}^{r\times r}$、$V \in \mathbb{R}^{D\times r}$（$r = \operatorname{rank}(X)$，通常 $r = \min(N-1, D)$）。则

$$S = \frac{1}{N-1} X^{\mathrm{T}} X = \frac{1}{N-1} V \Sigma^2 V^{\mathrm{T}}. \tag{68}$$

与协方差矩阵的特征分解 $S = Q\Lambda Q^{\mathrm{T}}$ 对比，立刻得到：

- **主成分方向**是 V 的列，即 X 的右奇异向量；
- **第 j 个主成分的方差**是 $\sigma_j^2/(N-1)$；
- **主成分得分**（每个样本在新坐标下的坐标）是 $U\Sigma$ 的列。

> **定理 9.1** （PCA 与 SVD 的等价性）
> 对中心化矩阵 X，其前 k 个主成分方向等于 X 的前 k 个右奇异向量，前 k 个主成分的方差之和等于 $\sum_{j=1}^{k} \sigma_j^2/(N-1)$，且
>
> $$\text{累计解释方差比例} = \frac{\sum_{j=1}^{k} \sigma_j^2}{\sum_{j=1}^{r} \sigma_j^2} = E(k), \tag{69}$$
>
> 与式 (56) 定义的“能量比例”完全一致。

这个定理说明：PCA 与低秩逼近是同一件事的两个说法。用主成分做降维后重构，得到的就是 $X_k = U_k \Sigma_k V_k^{\mathrm{T}}$，而它正是 X 的最佳秩 k 逼近。

> **为什么可以直接对 X 做 SVD，而不必算协方差矩阵**　计算 $D \times D$ 的协方差矩阵需要 $O(ND^2)$ 次运算，还需要 $O(D^2)$ 的存储；当 $D = 10^4$ 时，S 有 10^8 个元素。而直接对 X 做 SVD（用第 10 节的方法）可以只算前 k 个奇异三元组，代价是 $O(NDk)$。更重要的是：构造 $S = X^{\mathrm{T}}X$ 会把条件数平方，细小的方差方向会被数值误差吞掉。

9.4 第三步：解释方差与选择主成分个数

实践中常画“累计解释方差曲线”，选一个拐点。例如前 k 个主成分解释了 95% 的方差，就可以认为降到 k 维是合理的。

注 9.1

“解释 95% 的方差”不等于“保留了 95% 的信息”。方差只刻画二阶统计量，如果数据的结构体现在高阶矩上（例如明显的聚类），低方差方向也可能含有分类所需的信息。PCA 是无监督的，它不知道你后面要做什么任务。

9.5 不中心化会发生什么

例 9.2

设 $N = 100$ 个二维样本，全部集中在 $(100, 100)$ 附近，坐标的标准差为 1。数据大致是各向同性的（两个方向变异差不多）。

中心化后：均值为 0，协方差近似为 I，两个主成分方向任意（退化情形），解释方差各占一半。

不中心化：数据的均值本身是 $(100, 100)$，其范数约为 141，远远大于波动幅度 1。此时 $X^{\mathrm{T}}X$ 被均值项主导：

$$X^{\mathrm{T}}X = \sum_{i=1}^{N} \boldsymbol{x}_i \boldsymbol{x}_i^{\mathrm{T}} \approx N\,\boldsymbol{\mu}\boldsymbol{\mu}^{\mathrm{T}} + N\,S, \tag{70}$$

第一项的特征值约为 $N\|\boldsymbol{\mu}\|^2 \approx 100 \times 20000 = 2 \times 10^6$，第二项只有 $N \approx 100$。于是第一主成分几乎正好是 $\boldsymbol{\mu}/\|\boldsymbol{\mu}\| = (1, 1)^{\mathrm{T}}/\sqrt{2}$ 方向——它指向原点，而不是数据变异最大的方向。

这个例子说明：**不中心化的 PCA 得到的第一主成分，主要反映“数据离原点有多远”，而不是“数据在哪个方向上变化最大”**。对图像数据尤其要注意：像素值都是正数，不中心化时第一主成分往往就是“平均亮度”。

两个常见错误　**错误一**：把未中心化的矩阵直接做 SVD，然后称之为 PCA。这在数学上仍然是 SVD，但不是 PCA——它对应的是“未中心化的主成分分析”，解释的是均方值而非方差。

错误二：对已经中心化的数据再做一次标准化（除以标准差）却不说明。标准化会改变各特征的权重，得到的其实是“相关矩阵的 PCA”，与“协方差矩阵的 PCA”结果不同。两者没有对错，但必须写清楚。

自检

1. 若 X 已中心化且 $N = 50$，前两个奇异值为 10 和 5，求前两个主成分的方差与累计解释比例。
2. 为什么 X 的秩最多是 $\min(N - 1, D)$（在中心化之后）？
3. 如果把 PCA 的结果用于分类，选择 k 时应该看解释方差还是看分类准确率？两者的区别是什么？

10 怎么算：从双对角化到随机化算法

前面的定义和定理都是“数学上存在”，实际问题还要考虑“算得动、算得准”。这一节介绍三条主流路线，重点不在实现细节，而在**什么时候该用哪一条**。

10.1 为什么不能直接对 A 转置乘 A 求特征值

由第 5 节的构造，最“自然”的算法是：算 $A^{\mathrm{T}}A$，求它的特征分解，开平方得奇异值。这个算法在数学上完全正确，在数值上却很糟糕。

> **例 10.1**
> 设 A 的奇异值为 1 与 10^{-8}。双精度下，$A^{\mathrm{T}}A$ 的特征值是 1 与 10^{-16}。而 1 的浮点表示本身就有约 10^{-16} 的相对误差，计算 $A^{\mathrm{T}}A$ 的过程中还会引入新的舍入误差。结果是：10^{-16} 这个特征值完全被误差淹没，甚至可能算出负数，开平方直接失败。
> 用 SVD 直接算，10^{-8} 与 1 相差 8 个数量级，在双精度下可以清楚分辨。

一般地，若 $\kappa(A) = 10^{k}$，则 $\kappa(A^{\mathrm{T}}A) = 10^{2k}$。$k = 8$ 时 $\kappa(A^{\mathrm{T}}A) = 10^{16}$，已经超出双精度的分辨能力。这就是为什么所有主流库（LAPACK、NumPy、MATLAB）都用专门的双对角化算法，而不是“特征值 + 开方”。

10.2 Golub–Kahan 双对角化

这是 LAPACK 中 `gesdd` 的核心思路，分两步：

1. **双对角化**：用 Householder 变换从左右两侧交替作用，把 A 化成只有主对角线和超对角线非零的“双对角矩阵” B：

$$A = P\,B\,Q^{\mathrm{T}}, \qquad B = \begin{pmatrix} d_1 & e_1 & & \\ & d_2 & e_2 & \\ & & \ddots & \ddots \\ & & & d_n \end{pmatrix}. \tag{71}$$

   这一步是有限步的，不引入迭代误差，代价 $O(mn^2)$。

2. **对 B 做隐式 QR 迭代**：B 是稀疏的，QR 迭代可以保持双对角结构，每次迭代只需 $O(n)$ 的代价。收敛后得到 B 的 SVD，再与 P, Q 合并。

整体复杂度为 $O(mn^2)$（$m \geq n$），这是稠密矩阵 SVD 的标准代价。

10.3 幂迭代：只要最大的那一个

如果只需要最大的奇异值（以及对应的向量），没必要做完整分解。幂迭代利用一个简单的事实：反复用 $A^{\mathrm{T}}A$ 作用，最大特征值方向会逐渐占主导。

```python
import numpy as np

def power_svd(A, iters=500, tol=1e-10):
    n = A.shape[1]
    v = np.random.randn(n); v /= np.linalg.norm(v)
    sigma_old = 0.0
    for _ in range(iters):
        w = A.T @ (A @ v)          # same as A.T @ A @ v
        sigma = np.linalg.norm(w)  # sqrt of Rayleigh quotient
        v = w / sigma
        if abs(sigma - sigma_old) < tol * sigma:
            break
        sigma_old = sigma
    u = (A @ v) / sigma
    return sigma, u, v
```

收敛速度由奇异值之比决定：误差每步乘以 $(\sigma_2/\sigma_1)^2$。若 $\sigma_2/\sigma_1 = 0.9$，需要约 200 步才能把误差降到 10^{-9}；若比值是 0.5，十几步就够了。**奇异值衰减越快，幂迭代越快**——这与“低秩矩阵容易处理”的直觉一致。

> **注 10.2**
> 幂迭代的收敛速度依赖谱间隙 $\sigma_1 - \sigma_2$。若前两个奇异值非常接近，它会很慢。此时可以用“块幂迭代”（同时迭代多个向量）或 Lanczos 方法。实际库中的 `svds`（SciPy）用的是 Lanczos/Arnoldi，通常比朴素幂迭代快得多。

10.4 随机化 SVD：用随机投影找列空间

当矩阵非常大（比如 $10^6 \times 10^5$）却又近似低秩时，可以只算前 k 个分量。随机化算法由 Halko、Martinsson 与 Tropp 在 2011 年系统化，思路出奇地简单：

1. 生成一个 $n \times (k+p)$ 的随机矩阵 Ω（p 是过采样参数，常取 5 ~ 10），元素独立取自标准正态分布；
2. 计算 $Y = A\Omega$。这是一个“随机投影”，它把 A 的列空间压缩到 $k+p$ 维，大概率保留了主要方向；
3. 对 Y 做 QR 分解 $Y = QR$，Q 的列是 $\mathrm{col}(A)$ 的近似标准正交基；

4. 计算小矩阵 $B = Q^{\mathrm{T}}A$（尺寸 $(k+p)\times n$），对它做标准 SVD：$B = \tilde{U}\Sigma V^{\mathrm{T}}$；

5. 令 $U = Q\tilde{U}$，得到 $A \approx U\Sigma V^{\mathrm{T}}$。

关键在于第 4 步：真正的 SVD 只作用在一个 $(k+p)\times n$ 的小矩阵上，代价从 $O(mn^2)$ 降到 $O(mn(k+p))$。当 $k \ll n$ 时，这是数量级的加速。

随机化算法的代价与保证 代价：$O(mn\log k + (m+n)k^2)$，主要是两次矩阵乘法。保证：误差满足 $\|A - U\Sigma V^{\mathrm{T}}\|_2 \le (1+O(1))\sigma_{k+1}$（以高概率），即与最佳秩 k 逼近同阶。代价是“高概率”而非“一定”——随机算法总有小概率失败，实践中靠过采样 p 把失败概率压到极低。

10.5 该选哪条路线

表 4: 不同场景下的方法选择

场景	矩阵规模	推荐方法	复杂度
稠密、需要全部奇异值	10^3 以内	LAPACK 双对角化（`np.linalg.svd`）	$O(mn^2)$
稠密、只要前 k 个	10^3 ~ 10^4	截断 SVD（`scipy.sparse.linalg.svds`）	$O(mnk)$
稀疏、超大	10^6 以上	Lanczos / 随机化 SVD	$O(mnk)$
只要最大奇异值	任意	幂迭代	$O(mn)$/步
在线、数据流	任意	增量 SVD 或随机化	视实现

稀疏矩阵的陷阱 对稀疏矩阵做完整 SVD，得到的 U 和 V 几乎一定是稠密的。若原矩阵有 10^8 个非零元，而 U 是 $10^6\times 10^6$ 的稠密矩阵，存储直接爆掉（8 字节 $\times 10^{12}$）。这时必须只算前 k 个分量，并且用不显式存储 U 全体的接口。

自检

1. 若 $\sigma_1 = 1$、$\sigma_2 = 0.99$，幂迭代要把误差降到 10^{-6} 需要多少步？

2. 为什么随机化 SVD 要过采样（取 $k+p$ 而不是正好 k）？

3. 对一个 10000×100 的矩阵，完整 SVD 与只算前 10 个奇异值，代价大约相差多少倍？

11 应用案例

这一节把前面所有工具串起来，看几个真实场景里 SVD 是怎么用的。每个案例都强调同一件事：**先把问题翻译成“低秩 + 某个损失函数”，再决定用不用 SVD**。

11.1 图像压缩

原理已在第 7 节说明：把图像看作矩阵，截断 SVD 保留前 k 个分量。这里补充两个实践细节。

分块处理。对自然图像，整图 SVD 的效果往往不如分成 8×8 或 16×16 的小块分别做 SVD 再拼回去。原因是局部块的相关性更强、奇异值衰减更快，同样的 k 能保留更多能量。JPEG 用的 DCT 本质上也是这个思路。

彩色图像。对 RGB 三个通道分别做 SVD，或者先把图像转到 YCbCr 空间，对人眼不敏感的两个色度通道做更激进的截断。后者是 JPEG 的标准做法。

11.2 推荐系统：潜在因子模型

设评分矩阵 $R\in\mathbb{R}^{M\times N}$，$M$ 个用户、N 个物品，大部分元素缺失。假设用户的偏好由 k 个潜在因子决定，即

$$R_{ui}\approx \mathbf{p}_u^{\mathrm{T}}\mathbf{q}_i, \tag{72}$$

其中 $\mathbf{p}_u,\mathbf{q}_i\in\mathbb{R}^k$。用矩阵语言，就是 $R\approx PQ^{\mathrm{T}}$，$P\in\mathbb{R}^{M\times k}$，$Q\in\mathbb{R}^{N\times k}$，即 R 近似秩 k。

如果 R 是完整的，直接做截断 SVD 就得到最优的 P,Q（在 F 范数下）。但 R 有大量缺失，Eckart–Young 定理不适用——我们只能最小化

$$\min_{P,Q}\sum_{(u,i)\in\Omega}\left(R_{ui}-\mathbf{p}_u^{\mathrm{T}}\mathbf{q}_i\right)^2+\lambda\left(\|P\|_F^2+\|Q\|_F^2\right), \tag{73}$$

其中 Ω 是观测到的评分集合。这需要用交替最小二乘（ALS）或随机梯度下降求解，不能直接调用 SVD。

> **注 11.1**
>
> Netflix Prize（2006–2009）让这类方法广为人知。获胜方案并非纯 SVD，而是上百个模型的集成，但其中的核心组件确实是带正则化的矩阵分解。这个案例的教训是：**模型结构比单一算法的精妙更重要**。

11.3 潜在语义分析

文档—词频矩阵 $X\in\mathbb{R}^{D\times V}$（$D$ 篇文档、V 个词）极其稀疏且高维。直接用它算相似度，会遇到“同义词不匹配”的问题：查“汽车”找不到写着“轿车”的文档。

潜在语义分析（LSA）的做法是：对 X 做截断 SVD，$X \approx U_k \Sigma_k V_k^{\mathrm{T}}$，然后用 $U_k \Sigma_k$ 的第 i 行作为第 i 篇文档的 k 维表示。在这个低维空间里，“汽车”和“轿车”因为经常出现在相似的文档中，会有相近的坐标，相似度自然就高了。

这一步的实质是：**把“词—文档”共现关系压缩成 k 个潜在主题**，每个奇异向量对应一个主题，奇异值表示该主题的重要性。

11.4 降噪与信号分离

若观测矩阵 $Y = A + E$，其中 A 低秩（真实信号）、E 是随机噪声（满秩但奇异值小），则截断 SVD 可以近似恢复 A：

$$\hat{A} = Y_k \approx A. \tag{74}$$

噪声的奇异值分布通常比较均匀（没有明显的“大奇异值”），而信号的能量集中在少数几个方向上，两者在谱上分得开。这就是“奇异值谱上的信噪分离”。

> **降噪的边界**　这个论证成立的前提是“信号低秩、噪声不低秩，且信号能量占优”。若噪声本身有结构（例如周期性条纹、固定的背景纹理），它的奇异值也可能很大，截断反而会保留噪声、丢掉信号。用之前先看一眼奇异值谱，不要盲信。

11.5 其他值得一提的应用

- **线性回归的正则化**：岭回归、主成分回归都建立在 SVD 之上（见式 (66)）。
- **模型压缩**：把神经网络的大权重矩阵做低秩分解，减少参数量与计算量。
- **控制与系统辨识**：用 SVD 做平衡截断（balanced truncation），把高维动力系统降阶。
- **计算几何**：点云的主方向分析、平面拟合，本质都是对协方差矩阵做特征分解，也就是对数据矩阵做 SVD。

自检

1. 为什么推荐系统不能直接对评分矩阵做 SVD？把缺失值填 0 会带来什么偏差？
2. LSA 中，$U_k \Sigma_k$ 与 V_k 分别代表什么？为什么用 $U_k \Sigma_k$ 而不是 U_k？
3. 若噪声的奇异值也很大，截断 SVD 降噪会失败。举一个具体的例子。

12 十个常见误区

这一节收集了教学中反复出现的误解。每一条都给出正确说法与理由，建议逐条对照自己的理解检查一遍。

1. **“SVD 就是对方阵做特征值分解。”**
   不对。特征值分解要求矩阵是方阵，而且即使方阵也可能不可对角化（例如 $\left(\begin{smallmatrix}1 & 1\\ 0 & 1\end{smallmatrix}\right)$）；有特征值时还可能涉及复数。SVD 对**任意** $m \times n$ 实矩阵都存在，且只用到正交矩阵与实数，条件宽松得多。二者的联系是：SVD 是 $A^{\mathrm{T}}A$ 的特征分解“开平方”的产物，但 SVD 本身作用在 A 上。

2. **“奇异值可以是负数。”**
   不对。奇异值定义为 $\sigma_i = \sqrt{\lambda_i(A^{\mathrm{T}}A)}$，取的是非负平方根。特征值可以为负、为复数，奇异值永远 ≥ 0。这就是为什么对称矩阵满足 $\sigma_i = |\lambda_i|$ 而不是 $\sigma_i = \lambda_i$。

3. **“一个矩阵的 SVD 是唯一的。”**
   部分对，部分不对。奇异值唯一；奇异向量在单重奇异值时唯一到符号，在重奇异值时只有子空间唯一。所以不同软件算出的 $\boldsymbol{u}_i$ 可能差一个负号，甚至（重根时）差一个正交旋转。比较两组结果时，要比较 $|\boldsymbol{u}_i^{\mathrm{T}}\hat{\boldsymbol{u}}_i|$ 或投影矩阵，而不是逐元素比较。

4. **“算 SVD 就是算 $A^{\mathrm{T}}A$ 的特征值再开方。”**
   数学上对，工程上错。$\kappa(A^{\mathrm{T}}A) = \kappa(A)^2$，构造 $A^{\mathrm{T}}A$ 会让条件数平方。$\kappa(A) = 10^8$ 时，$A^{\mathrm{T}}A$ 的条件数达到 10^{16}，双精度下小奇异值完全丢失。实际库用的是双对角化加 QR 迭代（第 10 节）。

5. **“σ 就是标准差。”**
   看语境。在 SVD 里 σ_i 是奇异值；在统计里 σ 是标准差、σ^2 是方差。本讲义用 s^2 或 Var 表示方差以避免混淆。读论文时若看到 σ_i^2，要先确认它是“奇异值的平方”还是“方差”。

6. **“对数据矩阵做 SVD 就是 PCA。”**
   少了关键一步：中心化。未中心化的 SVD 分解的是“均方值”而不是“方差”，第一主成分会指向均值方向（例 9.2）。对图像数据尤其明显：像素非负，不中心化时第一主成分几乎就是平均亮度图。

7. **“截断秩 k 用测试集上的效果来选。”**
   绝对不行。这等于用测试集调参，评估结果会系统性偏乐观。正确做法是用训练集/验证集选 k，测试集只在最后用一次；或者用解释方差、谱图肘部等不依赖标签的准则。

8. **“稀疏矩阵也能直接做 SVD，反正库会处理。”**
   能算，但存不下。稀疏矩阵的 U、V 通常是稠密的。$10^6 \times 10^6$ 的稠密矩阵需要 8 TB（双精

度），直接爆内存。必须用只返回前 k 个分量的接口（如 `svds`），并清楚 U_k 仍可能是 $10^6 \times k$ 的稠密矩阵。

9. **“截断 SVD 是所有意义下的最优低秩逼近。”**
   只在谱范数与 F 范数下最优（Eckart–Young 定理）。若损失函数换成逐元素绝对误差、加权误差、或“只在观测位置上计算”的误差（推荐系统的情形），A_k 未必最优，甚至可能很糟。用之前先确认损失函数与定理匹配。

10. **“求伪逆时直接用 $1/\sigma_i$ 就行。”**
    要截断。当 σ_i 接近机器精度时，$1/\sigma_i$ 会放大噪声，得到巨大且无意义的解。实践中应设一个阈值 τ（如 $\tau = \sigma_1 \cdot \max(m,n) \cdot \varepsilon_{\text{mach}}$），把小于 τ 的奇异值当作零，或者改用岭回归（式 (66)）。

13 本章小结

13.1 一张表记住全部核心公式

表 5: SVD 核心公式速查

主题	公式
分解	$A = U\Sigma V^{\mathrm{T}} = \sum_{i=1}^{r} \sigma_i \boldsymbol{u}_i \boldsymbol{v}_i^{\mathrm{T}}$
奇异值	$\sigma_i = \sqrt{\lambda_i(A^{\mathrm{T}}A)}$，按降序排列
左奇异向量	$\boldsymbol{u}_i = A\boldsymbol{v}_i/\sigma_i$
秩	$\operatorname{rank}(A) = \#\{i : \sigma_i > 0\}$
谱范数	$\|A\|_2 = \sigma_1$
F 范数	$\|A\|_F = \left(\sum_i \sigma_i^2\right)^{1/2}$
核范数	$\|A\|_* = \sum_i \sigma_i$
条件数	$\kappa(A) = \sigma_1/\sigma_r$，且 $\kappa(A^{\mathrm{T}}A) = \kappa(A)^2$
行列式	$\lvert\det A\rvert = \prod_i \sigma_i$（方阵）
低秩逼近	$A_k = \sum_{i\le k} \sigma_i \boldsymbol{u}_i \boldsymbol{v}_i^{\mathrm{T}}$，$\|A - A_k\|_2 = \sigma_{k+1}$
F 范数误差	$\|A - A_k\|_F^2 = \sum_{i>k} \sigma_i^2$
能量比例	$E(k) = \sum_{i\le k} \sigma_i^2 \big/ \sum_i \sigma_i^2$
伪逆	$A^+ = V\Sigma^+ U^{\mathrm{T}}$，$A^+\boldsymbol{b} = \sum_{i\le r} \frac{\boldsymbol{u}_i^{\mathrm{T}}\boldsymbol{b}}{\sigma_i}\boldsymbol{v}_i$
岭回归	$\boldsymbol{x}_\lambda = \sum_i \frac{\sigma_i}{\sigma_i^2+\lambda}(\boldsymbol{u}_i^{\mathrm{T}}\boldsymbol{b})\boldsymbol{v}_i$
PCA 方差	第 j 个主成分方差 $= \sigma_j^2/(N-1)$（X 已中心化）

13.2 三句话总结

如果只记三句话

几何上：SVD 把任意矩阵拆成“旋转—拉伸—旋转”，拉伸的长度是奇异值，方向是奇异向量。

代数上：$A^{\mathrm{T}}A$ 的特征分解给出了右奇异向量和奇异值，$A\boldsymbol{v}_i/\sigma_i$ 给出了左奇异向量。

应用上：截断 SVD 是最优低秩逼近，一切“提取主要成分”“压缩”“去噪”“降维”的问题，都是它的变形。

13.3 与后续内容的连接

SVD 是后面许多主题的入口，读完之后可以顺着这几条线继续：

- **主成分分析**（第 9 节）：中心化数据的 SVD。
- **矩阵补全与推荐系统**：低秩假设 + 部分观测，SVD 的自然推广。
- **鲁棒 PCA**：把 A 分解成“低秩 + 稀疏”，应对离群点。
- **张量分解**：SVD 在高阶数组上的类比（CP 分解、Tucker 分解）。
- **核方法与非线性降维**：当线性假设不够时，先把数据映到高维再降维。
- **深度学习中的低秩结构**：LoRA 等参数高效微调方法，本质上是对权重更新矩阵做低秩约束。

14 习题

题目按难度分为四组。A 组用于检查计算是否熟练，B 组检查证明能力，C 组检查工程实现，D 组没有标准答案，用于讨论。

A 组：计算

A1. 求 $A = \left(\begin{smallmatrix} 2 & 0 \\ 0 & 1 \\ 0 & 1 \end{smallmatrix}\right)$ 的完整 SVD，并验证 $A^{\mathrm{T}}A = V\Sigma^{\mathrm{T}}\Sigma V^{\mathrm{T}}$。

A2. 求 $A = \left(\begin{smallmatrix} 1 & 1 \\ 1 & 1 \end{smallmatrix}\right)$ 的 SVD。它的秩是多少？写出它的两个奇异值。

A3. 对第 3 节的矩阵 $A = \begin{pmatrix} 3 & 0 \\ 4 & 5 \end{pmatrix}$，计算 $\|A\|_2$、$\|A\|_F$、$\kappa(A)$、$|\det A|$。

A4. 设 $A = U\Sigma V^{\mathrm{T}}$，其中 $U = I_3$，$\Sigma = \begin{pmatrix} 4 & 0 \\ 0 & 2 \\ 0 & 0 \end{pmatrix}$，$V = I_2$。求 A^{+}，并求 $\boldsymbol{x} = A^{+}\boldsymbol{b}$，$\boldsymbol{b} = (8, 4, 6)^{\mathrm{T}}$。残差是多少？

A5. 求 $A = \left(\begin{smallmatrix} 1 & 2 \\ 2 & 4 \end{smallmatrix}\right)$ 的 SVD 与最佳秩 1 逼近 A_1。计算 $\|A - A_1\|_F$。

A6. 某矩阵的奇异值为 $10, 5, 2, 1$。求 $k = 2$ 时的累计能量比例 $E(2)$ 与相对 F 范数误差 $\|A - A_2\|_F / \|A\|_F$。

B 组：证明

B1. 证明 $\|A\|_F^2 = \sum_{i=1}^{r} \sigma_i^2$，不引用定理 6.2，直接从 SVD 与迹的性质出发。

B2. 证明 A 与 A^{T} 有相同的非零奇异值。它们的左、右奇异向量有什么关系？

B3. 证明 $\kappa(A^{\mathrm{T}}A) = \kappa(A)^2$，并说明这个等式为什么导致“用正规方程求解会损失精度”。

B4. 证明：若 A 为 n 阶可逆方阵，则 $|\det A| = \prod_{i=1}^{n} \sigma_i$。

B5. 证明 $P = AA^{+}$ 是对称的、幂等的（$P^2 = P$），从而是一个正交投影算子。它的像空间是什么？

B6. 证明：若 $\operatorname{rank}(A) = r$，则不存在秩小于 r 的矩阵 B 使 $\|A - B\|_F = 0$。进一步说明：若只要求 $\|A - B\|_F \le \varepsilon$，$B$ 的秩最小可以是多少？

C 组：编程

C1. 读入一张灰度图（或自行生成一个 256×256 的矩阵），对 $k = 5, 10, 20, 50, 100$ 分别做截断 SVD，画出“k 与相对误差”的曲线，并保存几张重构图像对比。

C2. 实现幂迭代，求一个随机 200×100 矩阵的最大奇异值。画出误差随迭代次数的变化（对数纵轴），并与 `np.linalg.svd` 的结果比较。

C3. 构造一个病态最小二乘问题（例如用 SVD 造一个 $\kappa = 10^{10}$ 的矩阵），分别用正规方程与 `np.linalg.lstsq` 求解，比较两者的误差。解释差异的来源。

C4. 实现随机化 SVD（第 10 节的五步），与完整 SVD 比较：精度差多少？速度快多少？改变过采样参数 p，观察精度如何变化。

D 组：思考与讨论

D1. 奇异值的衰减速度为什么能刻画“有效秩”？举一个奇异值衰减很慢、但矩阵仍然“简单”的例子，说明这个直觉的局限。

D2. 把一张图像转置后再做 SVD，得到的奇异值与原来相同吗？左、右奇异向量如何变化？如果把图像旋转 90° 呢？

D3. 条件数大是否意味着矩阵“不好”？请分别从“求解线性方程组”“做低秩逼近”“做数据压缩”三个角度讨论。

D4. SVD、傅里叶变换、小波变换都可以用于压缩图像。它们在“用什么基表示信号”这一点上有何本质区别？为什么 JPEG 用 DCT 而不是 SVD？

延伸阅读

[1] G. H. Golub, C. F. Van Loan. *Matrix Computations*. 4th ed. Johns Hopkins University Press, 2013. 第 2.4 节讲 SVD 的构造与性质，第 8.6 节讲计算算法，是标准的参考书。

[2] L. N. Trefethen, D. Bau. *Numerical Linear Algebra*. SIAM, 1997. 第 4、5 讲对 SVD 的几何意义与数值性质讲得极为清楚，篇幅短，适合本科生。

[3] C. Eckart, G. Young.“The approximation of one matrix by another of lower rank.”*Psychometrika*, 1(3):211–218, 1936. 低秩逼近最优性的原始论文，篇幅只有八页，值得一读。

[4] N. Halko, P.-G. Martinsson, J. A. Tropp. “Finding structure with randomness: Probabilistic algorithms for constructing approximate matrix decompositions.”*SIAM Review*, 53(2):217–288, 2011. 随机化 SVD 的系统综述，第 4–5 节给出了完整的误差分析。

[5] G. Strang. *Introduction to Linear Algebra*. 5th ed. Wellesley-Cambridge Press, 2016. 第 7 章用大量几何图像解释 SVD，适合作为本讲义的配套读物。

[6] J. Shlens.“A tutorial on principal component analysis.”arXiv:1404.1100, 2014. 从 PCA 的角度讲 SVD，对理解第 9 节很有帮助。